



UNIVERSITÉ PARIS CITÉ

Master 2 Mathématiques et Informatique Appliquées à la Science des Données

Modélisation de la relation entre structuration environnementale, communautés phytoplanctoniques et distribution des Niveaux Trophiques Intermédiaires

Une étude en saison estivale dans le secteur Indien de l'Océan Austral

Rapport de stage

Rapport réalisé par

Elise NICOLAS

Encadrants

Marius MOLINET, David NERINI, Christophe GUINET, Cédric COTTE

Professeure référente

Aurélie FISHER

Septembre 2026

Résumé

Contexte. Le réchauffement climatique modifie la structure des communautés phytoplanctoniques de l’océan Austral, avec une possible diminution de la contribution des diatomées au profit du nano- et picophytoplancton. Ce changement pourrait allonger le réseau trophique et affecter la biomasse des Niveaux Trophiques Intermédiaires (NTI, zooplancton et micronecton), avec des répercussions en cascade sur l’ensemble des écosystèmes.

Objectif et méthode. La relation entre la biomasse des NTI, estimée par acoustique active (Nautical Area Scattering Coefficient, NASC, à 38 et 120 kHz) a été modélisée avec des Forêts aléatoires par un ensemble de variables environnementales (température, salinité, hydrodynamisme via le Finite-Time Lyapunov Exponent) et pigmentaires (neuf pigments photosynthétiques). L’étude porte sur le secteur indien de l’océan Austral, en saison estivale (janvier-mars), à partir des campagnes OBSAUSTRAL 2018, 2021, 2022 et 2023. Une attention particulière a été portée à la fiabilité de l’évaluation et l’interprétation du modèle : une comparaison entre validation croisée Monte-Carlo et validation par blocage spatio-temporel a été effectuée.

Résultats. Des cartes de prédictions de NASC ont été générées sur l’ensemble de la région pour chaque modèle de validation croisée. Malgré des écarts de performance importants entre les schémas de validation, les cartes obtenues sont similaires. Elles révèlent une structuration latitudinale inversée entre 38 et 120 kHz. Les domaines océanographiques fonctionnels (température/salinité) et la biomasse phytoplanctonique totale ressortent comme les plus importantes variables pour la prédiction du NASC et le microphytoplancton (diatomées, dinoflagellés) apparaît plus déterminant que le nano- et le picophytoplancton. La comparaison entre validation croisée Monte-Carlo et validation par blocage spatio-temporel révèle une fuite d’information substantielle dans le premier schéma, confirmée par une forte sensibilité au bruit. Chaque schéma de validation témoigne d’un plafond structurel des courbes d’apprentissage dont l’origine, limite informationnelle des covariables, densité d’échantillonnage, ou non-stationnarité spatiale non prise en compte, n’a pu être totalement départagée.

Conclusion et perspectives. Ces résultats suggèrent que la structuration environnementale (physico-chimique et hydrodynamique) prédomine sur la seule composition pigmentaire dans l’explication de la distribution du NASC par le Random Forest, sur la période et l’échelle considérées. Ils soulignent également la nécessité d’une évaluation méthodologiquement rigoureuse dans les modèles écologiques spatio-temporels. Des travaux futurs pourraient intégrer une méthode de sélection de variable plus étoffée, la complétion de données manquantes, un décalage temporel entre efflorescence phytoplanctonique et réponse des NTI, l’intégration explicite de la non-stationnarité, l’exploitation de données de bio-logging pour élargir la couverture spatio-temporelle, et recourir à des modèles de machine learning causal pour identifier les relations biologiques entre les variables étudiées.

Mots-clés : océan Austral, niveaux trophiques intermédiaires, acoustique active, phytoplancton, arbres de régression, validation croisée spatio-temporelle

Table des matières

1	Introduction	3
2	Matériel et pré-traitement des données	5
2.1	Zone d'étude et plan d'échantillonnage	5
2.2	Données d'acoustique active (OBSAUSTRAL) et construction du Nautical Area Scattering Coefficient (NASC)	5
2.2.1	Données d'acoustique active	5
2.2.2	Construction du Nautical Area Scattering Coefficient (NASC)	7
2.3	Concentrations de pigments photosynthétiques (PIGMeANN)	8
2.4	Données modèles de température et salinité (CMEMS) et calcul des Domaines Océanographiques Fonctionnels (FOD)	10
2.4.1	Données modèles de température et salinité (CMEMS)	10
2.4.2	Calcul des Domaines Océanographiques Fonctionnels (FOD)	11
2.5	Champs de courants modèles (CMEMS) et calcul du Finite Time Lyapunov Exponent (FTLE)	13
2.5.1	Données de Champs de courants modèles (CMEMS)	13
2.5.2	Calcul du Finite-Time Lyapunov Exponent	13
3	Méthode	15
3.1	Forêts Aléatoires	15
3.1.1	Algorithme	15
3.1.2	Forêts aléatoires et sur-apprentissage	15
3.2	Schéma de validation	15
3.3	Ajustement des hyperparamètres	15
3.4	Validation	15
3.4.1	validation des données	15
3.4.2	validation du protocole	15
3.4.3	validation du modèle	15
3.5	Evaluation du modèle	15
3.6	Interprétation post-hoc	15
3.6.1	Importance des variables	15
3.6.2	Source du biais	15
3.6.3	Suffisances des informations contenues par les covariables	15
4	Méthode	16
4.1	Forêts aléatoires	16
4.1.1	Algorithme	16
4.1.2	Complexité, sur-apprentissage et erreur OOB	16
4.2	Validation des données	16
4.2.1	Biais d'échantillonnage (dont densité jour/nuit)	16
4.2.2	Décalage de distribution entre jeux de données	16
4.3	Protocole et découpage des données	16
4.3.1	Prévention des fuites de données	16
4.3.2	Validation croisée par blocs (autocorrélation)	16
4.4	Ajustement des hyperparamètres	16
4.5	Évaluation des performances	16
4.5.1	Métriques et biais des prédictions	16
4.6	Validation du modèle	16
4.6.1	Sur-apprentissage et robustesse	16
4.6.2	Recherche de raccourcis (shortcut learning)	16
4.6.3	Domaine d'applicabilité	16

4.7	Interprétation post-hoc	16
4.7.1	Importance des variables (covariables corrélées)	16
4.7.2	Analyse des résidus et suffisance des covariables	16
5	Résultats	17
5.1	Structure et validation des données	17
5.2	Performances du modèle	17
5.3	Validité du modèle	17
5.4	Prédictions	17
5.5	Interprétation	17
6	Discussion	18
6.1	L'échantillonnage permet-il de répondre à la problématique ?	18
6.2	Les variables mesurées représentent-elles correctement les construits ?	18
6.3	Prédiction ou explicabilité ?	18
6.4	Contrainte des modèles prédictifs	18
6.5	Mise en relation des résultats associatifs avec la théorie de causalité et hypothèses	18

1 Introduction

Le phytoplancton désigne l'ensemble des organismes unicellulaires photosynthétiques (« phyto ») dépourvus de capacité de déplacement autonome contre le courant (« plancton »). Ces organismes soutiennent les écosystèmes marins en constituant le premier maillon de la chaîne alimentaire, aussi appelée réseau trophique. Ils jouent par ailleurs un rôle fondamental dans le cycle du carbone, en structurant, par leur taille, leur composition et leur abondance, les apports de carbone vers les fonds marins. On parle de communauté phytoplanctonique pour désigner un assemblage particulier d'organismes phytoplanctoniques dans un espace et à un temps donné [reynolds2006ecology].

Le réchauffement climatique induit des changements rapides dans l'océan Austral : l'eau se réchauffe et s'adoucit sous l'effet de la fonte des glaces, les champs de courants et de vents se modifient, la stratification de la colonne d'eau s'accroît, etc. [sallee2018] [abram2025Antarctic]. Ces changements ne sont pas sans conséquences pour les communautés phytoplanctoniques [deppeler2017southern]. Des études récentes montrent des changements de phénologie [thomalla2023Widespread][boyce2017environ] d'abondance [hayward2024Antarctic] et de structuration des communautés phytoplanctoniques [adrolis2026].

Dans l'océan Austral, ces communautés sont dominées par les diatomées, larges cellules phytoplanctoniques (microphytoplancton, 20-200 μm) à forte valeur énergétique [treguer1992] [heidemann2024drivers]. Les modifications induites par le réchauffement climatique tendraient à augmenter la biomasse phytoplanctonique [delcastillo2019greener] [adrolis2026] tout en diminuant la contribution relative des diatomées au profit du nano- et picophytoplancton, organismes à plus faible valeur énergétique [krumhardt2022climate][sari2025influence]. Les diatomées soutiennent un réseau trophique court et hautement productif [treguer1992]. Elles sont consommées par le grand zooplancton (copépodes, krill) et le micronecton (petits poissons), regroupés sous l'appellation de Niveaux Trophiques Intermédiaires (NTI). Ces organismes sont eux-mêmes consommés par de plus gros poissons pélagiques, à leur tour proies de plus grands prédateurs. Un changement de structuration des communautés phytoplanctoniques vers une plus forte proportion de petit phytoplancton favoriserait ainsi le développement d'un zooplancton de plus petite taille, lui-même consommé par des organismes plus petits [krumhardt2022climate]. Ainsi, on observerait un allongement du réseau trophique et donc une modification du transfert d'énergie à chacun de ses maillons jusqu'aux prédateurs supérieurs [mestre2020decadal] : on parle de cascade trophique. Un changement d'assemblage des communautés phytoplanctoniques impacterait donc l'ensemble de l'écosystème.

Caractériser ces changements est par conséquent nécessaire, mais difficile dans les écosystèmes pélagiques¹ : ces milieux étant très vastes et peu accessibles, leur échantillonnage à grande échelle est logistiquement coûteux. L'acoustique active constitue un moyen d'étude des NTI dans ces zones difficiles d'accès. Elle consiste à émettre une onde, à la réceptionner, puis à analyser le signal reçu (principe du sonar) [benoitbird2016ecological]. L'écho reçu résulte de la réflexion du son émis sur un objet (le fond marin, par exemple), un organisme, ou encore une discontinuité physique dans la colonne d'eau (changement de densité). La connaissance de la vitesse locale de propagation du son dans l'eau permet, à partir du délai de réception du signal et de son intensité, de renseigner la profondeur, l'abondance et d'inférer sur la composition taxonomique des organismes présents [benoitbird2016ecological]. Le Nautical Area Scattering Coefficient (NASC), calculé à partir des échos acoustiques reçus, permet de résumer la rétrodiffusion acoustique sur un ensemble de profondeur considérées en un certain point de l'espace [maclennan2002]. Il sert donc de proxy de la biomasse de NTI à cette localisation. L'océan Austral étant particulièrement vaste et difficile d'accès, les campagnes d'échantillonnages restent limitées et, dans ce contexte, il est particulièrement pertinent de développer des modèles prédictifs permettant de généraliser les estimations faites à partir des données déjà acquises.

1. Ensemble des organismes et de leur environnement vivant dans la colonne d'eau du large, c'est-à-dire en pleine eau, loin du fond et des côtes, par opposition au domaine benthique lié au fond marin.

Cette étude a cherché à développer un modèle prédictif de la biomasse des NTI en fonction de l'assemblage des communautés phytoplanctoniques et de l'activité de mésoéchelle. Plus précisément, nous avons modélisé le NASC avec des Forêts Aléatoires en fonction de 9 variables de concentration pigmentaires ($P_1, P_2, \dots, P_9$), 2 variables physiques, la température et salinité (FOD), et 1 variable capturant l'hydrodynamisme (FTLE). Ainsi, nous avons cherché à documenter la relation $NASC \sim FTLE + FOD + P_1 + P_2 + \dots + P_9$. Ce modèle, développé sur le secteur indien de l'océan Austral à partir de données d'acoustique active collectées lors des campagnes OBSAUSTRAL 2018, 2021, 2022 et 2023, a permis de créer des cartes prédictives de NASC sur l'ensemble de la région et de mettre en évidence les variables environnementales clés pour la prédiction. L'objectif étant d'informer les conséquences de la restructuration des communautés phytoplanctoniques sur les NTI du secteur Indien de l'océan Austral.

La section **Matériel** détaillera la nature des données utilisées (acoustique active, température, salinité, champs de courants et concentrations pigmentaires). La section **Méthode** présentera le calcul des variables d'intérêt NASC, FTLE et FOD. Cette section décrira ensuite brièvement la méthode Random Forest, le calcul de l'importance des variables et le pipeline d'apprentissage mis en place. La section **Résultat** présentera (1) les cartes de NASC prédites (2) les variables environnementales identifiées comme importantes pour la prédiction du NASC (3) l'interprétation du modèle. La **Discussion** portera sur la fiabilité du modèle, la difficulté liée à la nature même des données et la mise en perspective avec la littérature de l'effet structurant des variables environnementales considérées et de la nature des communautés phytoplanctoniques.

2 Matériel et pré-traitement des données

La biomasse de zooplancton et micronecton, l'assemblage des communautés phytoplanctoniques, l'environnement physique des organismes ne sont pas directement mesurables, ce sont des construits (*constructs*), c'est à dire des abstractions qui décrivent le phénomène théorique d'intérêt [edwards2000nature]. Pour étudier ces phénomènes, nous avons besoin de trouver des variables mesurables pouvant les décrire, c'est l'opérationnalisation du construit. Les choix des variables utilisées sont justifiés par la connaissances théorique des phénomènes étudiés, appuyés par la littérature. Les variables mesurables sont alors dites variables *proxy* pour les construits associés. [shmueli2010explain].

Les variables proxy sélectionnées sont les suivantes : (1) le Nautical Area Scattering Coefficient (NASC) approxime la biomasse du zooplancton et micronecton sur l'ensemble de la profondeur considérée ; (2) les concentrations pigmentaires ($P_1, \dots, P_9$) approximent l'assemblage des communautés phytoplanctoniques leur abondance totale ; (3) le Finite-Time Lyapunov Exponent (FTLE) approxime l'hydrodynamisme et (4) la température et la salinité rendent compte des conditions physico-chimiques du milieu.

Toutes les données utilisées pour cette étude sont des données secondaires, c'est-à-dire que le plan d'échantillonnage n'a pas été construit spécifiquement pour répondre à cette problématique.

2.1 Zone d'étude et plan d'échantillonnage

L'étude a été réalisée sur les années 2018, 2021, 2022 et 2023, en saison estivale (janvier-mars) afin de limiter la variabilité saisonnière, et de jour (calculé selon l'angle solaire), afin de limiter l'effet de la migration verticale journalière (DVM) ¹. La fenêtre d'étude a été fixée à $[45, 90]^\circ\text{E}$ de longitude et $[30, 60]^\circ\text{S}$ de latitude afin de cibler précisément le secteur indien de l'Océan Austral.

2.2 Données d'acoustique active (OBSAUSTRAL) et construction du Nautical Area Scattering Coefficient (NASC)

2.2.1 Données d'acoustique active

Les données d'acoustiques actives ont été collectées par transects ² lors des campagnes océanographiques OBSAUSTRAL/THEMISTO 2018, 2021, 2022, 2023 en saison estivale. Ils sont détaillés sur la figure 2.1 [flotteoceanographique_campagnes].

1. Déplacement synchronisé dans la colonne d'eau au rythme du cycle jour/nuit : les organismes résident en profondeur durant le jour et remontent vers la surface la nuit, principalement pour se nourrir tout en réduisant le risque de prédation visuelle en eaux éclairées. Ce phénomène est considéré comme le plus grand mouvement synchronisé de biomasse à l'échelle de la planète. [Bandara2021]

2. Le bateau se déplace et collecte en même temps des données, par opposition aux données "stations" collectées lorsque le bateau est en arrêt. Cela a un coût en terme de résolution des spectrogramme et d'interprétabilité mais permet d'obtenir une plus grande couverture spatiale.




Figure 2.1 – Carte des transects effectués par le Marion Dufresnes II lors des campagnes océanographiques OBSAUSTRAL/THEMISTO 2018, 2021, 2022 et 2023.

Deux fréquences d'émissions ont été sélectionnées : 38 kHz, afin de comparer nos résultats avec la littérature³ et 120 kHz, fréquence à laquelle les zooplanctons d'intérêts, Euphausiacés (krill) et Copépodes, sont les plus détectables (voir Annexe ??, figure ??). Les échogrammes (figures 2.2a et 2.2b) donnent un aperçu de la nature des données collectées et de la manière dont l'information contenue par le signal reçu (résolution, organismes visibles) est déterminée par la fréquence de l'onde émise. Une forte intensité de l'écho reçu traduit la présence d'une importante biomasse d'organisme à ce temps, localisation géographique et profondeur.

3. La méthode d'acoustique active ayant été développée par les pêcheries, la fréquence d'échosondeur de référence est 38kHz (fréquence à laquelle les poissons sont facilement détectables).




Figure 2.2 – Exemple d'échogramme obtenu le 2023-01-28 entre 18h et 00h aux fréquences (a) 38 kHz et (b) 120 kHz

2.2.2 Construction du Nautical Area Scattering Coefficient (NASC)

L'**Intensité de l'écho (Echo Level EL)** correspond au signal reçu par le transducteur lorsqu'une onde est émise dans la colonne d'eau puis réfléchi par un objet.

$$EL = SL - 2TL + DI + TS \quad (2.1)$$

où

- SL (Source Level) : intensité du son émise (dB) $SL = 10 \times \log_{10}(I/I_{ref})$ et $I_{ref} = \rho_{ref}^2 = 1\mu\text{Pa}$ (ρ_{ref} la pression de référence)
- TL (Transmission Loss) : perte de transmission⁴ $TL = 20 \log_{10}(R) + \alpha R$
- DI (Directivity Index) : indice de directivité du transducteur (dB)
- TS (Target Strength) : réflectivité de la cible

La **section efficace de rétrodiffusion** $\sigma_{bs} = 10^{\frac{TS}{10}}$ (m^2) caractérise la capacité de la cible à rétrodiffuser l'énergie acoustique.

Le **volume backscattering coefficient** s_v (en $\text{m}^2.\text{m}^{-3}$ ou m^{-1}) est la somme toutes les surfaces réfléchitives σ_{bs} de toutes les cibles acoustiques dans le volume d'échantillonnage V_0 , normalisées à 1m^3 .

$$s_v = \sum \sigma_{bs}/V \quad (2.2)$$

Il mesure la densité acoustique des organismes présents dans un volume d'eau. Un niveau de s_v élevé correspond à une quantité plus importante de rétrodiffusion acoustique dans le volume échantillonné. Ce qui est interprété comme un nombre important d'organismes présents dans la colonne d'eau ou un organisme de taille importante ou encore un organisme ayant des propriétés fortement

4. Le premier terme correspond à l'atténuation due à la dispersion de l'onde et le second terme correspondant à l'atténuation de la propagation du milieu (α le coefficient d'absorption en $\text{dB}.\text{m}^{-1}$)

rétrodiffusantes⁵. Par convention, on exprime souvent cette grandeur en échelle logarithmique sous le nom de Volume Backscattering Strength, noté S_v (dB re 1 m^{-1}) tel que $s_v = 10^{\frac{S_v}{10}}$.

Le **Nautical Area Scattering Coefficient (NASC)**, noté s_A , correspond au coefficient de rétrodiffusion acoustique par unité de surface nautique (en $\text{m}^2 \cdot \text{nmi}^{-2}$). Il résume la rétrodiffusion acoustique sur une couche d'eau donnée en intégrant entre deux profondeurs le volume backscattering coefficient s_v multiplié par un certain facteur (convention) :

$$s_A = 4\pi(1852)^2 \int_{z_1}^{z_2} s_v(z) dz \quad (2.3)$$

Dans le cadre de cette étude, la profondeur d'intégration z_1 a été fixé à 25 m pour limiter le bruit d'échantillonnage de surface⁶. Le choix de z_2 dépend de la fréquence de l'échosondeur : pour des fréquences de 38 kHz et 120 kHz, la colonne d'eau est échantillonnée respectivement jusqu'à une profondeur moyenne de 700 m et 300 m. En effet, à partir de ces profondeurs, beaucoup de données s_v sont manquantes (voir Annexe ??, figure ??). Les profils avec plus de 50% de valeurs manquantes ont été exclus du jeu de données. Les valeurs manquantes résiduelles ont été comblées : (1) par interpolation linéaire lorsque situées entre deux valeurs connues et (2) par prolongation de la valeur la plus proche, lorsque situées aux extrémités.

Ainsi, pour chaque profil de S_v , on calcule le NASC et obtenons un scalaire, qui résume le volume de rétrodiffusion acoustique sur l'ensemble de la couche d'eau considérée ([25-700]m pour 38kHz et [25-300]m pour 120kHz). La figure 2.3 présente le NASC en fonction du temps pour le transect 2023 OBSAUSRAL.




Figure 2.3 – NASC en fonction du temps le 2023-01-28, données d'acoustique active (transect) issues de la campagne océanographique OBSAUSRAL 2023 [flotteoceanographique_campagnes].

2.3 Concentrations de pigments photosynthétiques (PIGMeANN)

La couleur des océans dépend de leur composition en pigments et ces pigments sont contenus dans les organismes phytoplanctoniques. L'analyse de la couleur des océans à partir d'images satellite permet donc d'étudier les communautés phytoplanctoniques sur une échelle spatiale et temporelle large. L'algorithme PIGMeANN [sari2026regional] associe, à l'aide de réseaux neuronaux profonds, une empreinte spectrale⁷ à des mesures de concentrations de pigments phytoplanctoniques *in-situ*

5. De nombreux poissons pélagiques présentent des vessies natatoires gazeuses ou lipidiques, organes leur permettant d'ajuster leur flottabilité. A 38 kHz, ces organes ont des propriétés retro-diffusantes particulières : ils amplifient le signal

6. effet de "bullage" du bateau bruitant les données à des faibles profondeurs

7. Forme caractéristique du spectre de la lumière réfléchiée par l'eau, c'est-à-dire de la façon dont la réflectance varie selon la longueur d'onde. Chaque pigment absorbe la lumière à des longueurs d'onde précises : des communautés de composition pigmentaire différente produisent donc des spectres de forme différente.

obtenues par High Performance Liquid Chromatography (HPLC)⁸. Ainsi, cette méthode permet de prédire les concentrations de neuf pigments phytoplanctoniques sur l'ensemble de la ROI. Ils sont détaillés dans le tableau 2.1.

Pigment	Divinyl chloro- phyllé <i>a</i>	Chloro- phyllé <i>a</i>	Chloro- phyllé <i>b</i>	Zéaxan- thine	Fucoxan- thine	19'- hexanoyl- oxyfuco- xanthine	19'- butanoyl- oxyfuco- xanthine	Allo- xanthine	Péridinine
---------	---------------------------------------	----------------------------	----------------------------	------------------	-------------------	---	---	-------------------	------------

Table 2.1 – Neuf pigments photosynthétiques dont les concentrations sont estimées par l'algorithme PIGMeANN [sari2026regional].

La figure 2.4 illustre la prédiction par PIGMeANN de la Chlorophylle-a le 2023-01-26 sur le secteur étudié. Les zones non colorées correspondent sont des données manquantes. La forte couverture nuageuse de la région induit une absence de données satellitaires, et donc des concentrations prédites par PIGMeANN.




Figure 2.4 – Carte de prédiction de la concentration de Chlorophylle-a le 2023-01-26 sur le secteur indien du SO, prédictions issue de l'algorithme PIGMeANN développé par Sari el Dine [sari2026regional]. La présence de nuages gêne grandement la prédiction sur la zone totale.

Plutôt que les concentrations pigmentaires absolues, on s'intéresse aux concentrations relative, c'est-à-dire le ratio des concentrations de pigments sur la somme des concentrations pigmentaires totale (Chlorophylle-a exclue⁹) :

$$R_i = \frac{[\text{Pigment}_i]}{\sum_{j \neq \text{Chla}} [\text{Pigment}_j]} \quad (2.4)$$

La concentration relative R_i la plus importante à une certaine localisation et temps permet d'identifier hypothétiquement les classes taxonomique (Phytoplanctonique Functional Types, PFT) ou de taille (Phytoplanktonic Size Class, PSC) dominantes de la communauté, par association avec les connaissances théoriques développées dans la littérature [sari2025influence], [heidemann2024drivers] [Georges2014]. Ces correspondances sont détaillées dans le tableau 2.2.

8. Permet de séparer et quantifier les pigments afin d'identifier les différents groupes phytoplanctoniques présents. L'échantillon est injecté dans une colonne traversée par un solvant sous haute pression, où ses différents composés sont séparés puis détectés individuellement.

9. ubiquitaire, elle n'apporte pas d'information sur la composition de la communauté

L'abondance totale de phytoplancton est estimée par la concentration absolue en Chlorophylle-*a*, pigment ubiquitaire présent chez la majorité des organismes photosynthétiques.

Pigment	Abréviation	Groupe phytoplanctonique associé (PFD)	Classe de taille (PSC)
Divinyl chlorophylle <i>a</i>	dvChla	Procaryotes picoplanctoniques (<i>Prochlorococcus</i>)	Picophytoplancton
Chlorophylle <i>a</i>	Chla	Marqueur de biomasse totale (tous groupes)	–
Chlorophylle <i>b</i>	Chlb	Chlorophycées / Prasinophycées	Picophytoplancton
Zéaxanthine	Zea	Cyanobactéries (<i>Synechococcus</i>)	Picophytoplancton
Fucoxanthine	Fuco	Diatomées (dominantes)	Microphytoplancton
19'-hexanoyloxyfucoxanthine	Hex	Prymnésiophycées (haptophytes)	Nanophytoplancton
19'-butanoyloxyfucoxanthine	But	Prymnésiophycées / pélagophytes	Nanophytoplancton
Alloxanthine	Allo	Cryptophycées	Nanophytoplancton
Péridinine	Per	Dinoflagellés (péridiniens)	Microphytoplancton

Table 2.2 – Pigments photosynthétiques analysés et groupes phytoplanctoniques hypothétiquement associés (PFD et PSC) dans le secteur de Kerguelen en été austral, d'après [Lasbleiz2014], [sari2025influence]

2.4 Données modèles de température et salinité (CMEMS) et calcul des Domaines Océanographiques Fonctionnels (FOD)

2.4.1 Données modèles de température et salinité (CMEMS)

Les données de températures et salinité font partie du jeu de données "Global Ocean Physics Reanalysis" (la réanalyse GLORYS12V1, GLOBAL_MULTIYEAR_PHY_001_030) [cmems_glorys12], issues de la plateforme Copernicus¹⁰. Ce sont des données issues des observations temps-réelles CMEMS¹¹ et réanalysées par le modèle NEMO¹², et ERA5¹³. Elles ont une résolution spatiale de 0.083° et une résolution temporelle journalière. Afin d'alléger le traitement des données, seules les mesures de température et de salinité comprises entre 20 et 500 m de profondeur ont été conservées. La figure 2.5 présente un exemple de profile de température et salinité à 50°E de longitude, 60°S de latitude, le 2023-01-26.

10. Programme d'observation de la Terre de l'Union européenne, qui fournit notamment des données et services permettant de surveiller et comprendre l'état de l'environnement, dont l'océan [copernicus2026services]

11. Copernicus Marine Environment Monitoring Service, service marin de Copernicus

12. Nucleus for European Modelling of the Ocean, modèle numérique de l'océan qui simule l'évolution de paramètres comme la température, la salinité, les courants et le niveau de la mer

13. Modèle atmosphérique de l'ECMWF (European Centre for Medium-Range Weather Forecasts) qui fournit les conditions atmosphériques nécessaires pour forcer le modèle océanique NEMO à sa surface




Figure 2.5 – Profil de Température et de Salinité issue de GLORYS (CMEMS), tronqués en deçà de 20m et au delà de 500m aux coordonnées (50°E, 60°S).

2.4.2 Calcul des Domaines Océanographiques Fonctionnels (FOD)

Les Domaines Océanographiques Fonctionnels (FOD, Functional Oceanographic Domain) sont des masses d'eau ayant des caractéristiques thermohalines similaires. La méthode d'identification des FOD a été développée par Fonvieille N. et Nerini D. [fonvieille2024]. Les profils de température et salinité sont, dans un premier temps (1), estimées dans un espace fonctionnel par projection sur une base de B-spline. Dans un second temps (2), la dimension de la matrice des coefficients de pondération des B-splines est réduite par Analyse par Composante Principale (PCA, Principal Component Analysis). Dans un dernier temps (3), un clustering (GMM) est appliqué à K composantes principales déterminé par la PCA de l'étape précédente. Ces trois étapes sont développées en Annexe ??.

Dans notre étude, l'estimation par projection sur une base de B-splines a été effectué avec l'hyperparamètre de régularisation $\lambda = 0.25$, pour $K = 25$ B-splines. Sont conservées pour le clustering 6 composantes principales (> 0.99 % explained var., voir tableau ??). L'indice BIC nous permet de sélectionner $n_{clust} = 6$ clusters. En ajoutant les classes de transitions (les soft classes, c'est-à-dire toutes les données dont la probabilité d'appartenance au cluster le plus probable est inférieure à $thr = 0.75$), on obtient alors 13 clusters distincts (7 clusters de "transitions")¹⁴, ce sont les 13 Domaines Océanographiques Fonctionnels (FOD).

14. La classe "NA" correspond aux clusters manquants sur le plateau de Kerguelen. Les profils de température et salinité allant de 20 à 500m, sont retirés des calculs tout profils ayant des données manquantes entre ces deux valeurs. Les zones où la bathymétrie est inférieure à 500m sont donc exclues de ces calculs.





Figure 2.6 – Carte des Domaines Océanographiques Fonctionnels du 2023-01-26 générée par la méthode développée par Fonvieille N. et Nerini D. [fonvieille2024].



(a) Profil de température (°C) moyen par cluster

(b) Profil de salinité (PSU) moyen par cluster

Figure 2.7

La figure 2.6 illustre les 13 FOD capturés le 2023-01-26. Pour chacun des FOD, les profils de température et de salinité moyennés sur l'ensemble de la période d'étude sont présentés en figure ???. Chaque FOD correspond donc une masse d'eau ayant des propriétés thermohalines similaires.

La projection de ces FOD sur une carte permet également de visualiser l'hydrodynamisme de la région. Les fronts sont des zones de rencontres entre des masses d'eau ayant propriétés hydrologiques différentes. Les FOD de "transition" permettent de les identifier : T2-3 correspond à la transition entre le cluster 2 et le cluster 3. Sa latitude ($\approx 50^\circ\text{S}$) permet de l'identifier comme Front Polaire. En suivant la même méthode, on peut identifier le Front Subantarctique (T3-4) et le front sub-tropical (T4-5/T4-6). Les tourbillons sont des courants en vortex, ce qui empêche les masses d'eau de se mélanger entre elles. Ainsi, on peut également identifier les tourbillons sur les cartes de FOD : ce sont les régions où, localement, un FOD est présent, entouré par un autre FOD dominant. Sur la figure 2.6, on remarque par exemple un tourbillon aux coordonnées (53°E , 27°S) environ : le cluster 5 est pris dans un tourbillon.

2.5 Champs de courants modèles (CMEMS) et calcul du Finite Time Lyapunov Exponent (FTLE)

2.5.1 Données de Champs de courants modèles (CMEMS)

Les champs de courants sont des données modèles également issues du modèle de réanalyse océanique GLORYS12 du Copernicus Marine Service (CMEMS), détaillé en section 2.4.1. Les champs de courants de surface (composantes zonale (u) et méridienne (v)) en sont extraits avec une résolution journalière.

2.5.2 Calcul du Finite-Time Lyapunov Exponent

Le Finite Time Lyapunov Exponent est un indicateur qui permet de caractériser la séparation ou la convergence de trajectoires de particules d'eau sur une durée finie. On peut ainsi identifier les structures dynamiques susceptibles de contrôler le transport et la dispersion dans l'océan [shadden2005definition], [dovido2004mixing]. Son calcul, effectué dans cette étude par Molinet M.¹⁵ est le suivant :

On considère le champ de vitesse bidimensionnel dépendant de la position et du temps, issu des données de réanalyse GLORYS21 :

$$\mathbf{u}(x, y, t) = \begin{pmatrix} u(x, y, t) \\ v(x, y, t) \end{pmatrix} \quad (2.5)$$

avec u et v représentant respectivement les composantes zonale et méridienne de la vitesse, et où $\mathbf{x} = (x, y)$ désigne la position de la particule.

À partir d'une position initiale $\mathbf{x}_0$ au temps t_0 , la trajectoire d'une particule est obtenue en intégrant, dans notre cas avec la méthode Runge-kutta (RK4), l'équation d'advection :

$$\frac{d\mathbf{x}}{dt} = \mathbf{u}(\mathbf{x}, t), \quad \mathbf{x}(t_0) = \mathbf{x}_0. \quad (2.6)$$

Après une durée d'intégration T , la position finale de la particule peut être décrite à l'aide du flot lagrangien :

$$\mathbf{x}(t_0 + T) = \mathbf{F}_{t_0}^T(\mathbf{x}_0), \quad (2.7)$$

où $\mathbf{F}_{t_0}^T$ est l'application qui associe à chaque position initiale $\mathbf{x}_0$ sa position après une durée T .

On peut ensuite analyser la variation des trajectoires $\mathbf{F}_{t_0}^T(x_0)$ après un temps T si l'on change la position initiale x_0 des particules (tenseur de déformation) :

$$\nabla \mathbf{F}_{t_0}^T = \frac{\partial \mathbf{F}_{t_0}^T}{\partial \mathbf{x}_0} = \begin{pmatrix} \frac{\partial F_x}{\partial x_0} & \frac{\partial F_x}{\partial y_0} \\ \frac{\partial F_y}{\partial x_0} & \frac{\partial F_y}{\partial y_0} \end{pmatrix} \quad (2.8)$$

Le tenseur de Cauchy-Green permet de quantifier la déformation des distances entre des particules

15. Doctorant au MIO et CEBC, encadrant de ce stage

initialement proches. Il est défini par :

$$\mathbf{C}_{t_0}^T(\mathbf{x}_0) = \left(\nabla \mathbf{F}_{t_0}^T(\mathbf{x}_0) \right)^T \nabla \mathbf{F}_{t_0}^T(\mathbf{x}_0). \quad (2.9)$$

Le facteur maximal d'étirement entre les particules est donné par la plus grande valeur propre λ_{max} du tenseur de Cauchy-Green $\mathbf{C}_{t_0}^T(\mathbf{x}_0)$

Le FTLE ($\sigma_{t_0}^T$) est ensuite calculé, il correspond au taux de croissance logarithmique du facteur d'étirement maximal λ_{max} , normalisé par la durée d'intégration T :

$$\sigma_{t_0}^T(\mathbf{x}_0) = \frac{1}{|T|} \ln \left(\sqrt{\lambda_{max}(\mathbf{C}_{t_0}^T(\mathbf{x}_0))} \right) \quad (2.10)$$

avec :

- $\mathbf{C}_{t_0}^T$ le tenseur de Cauchy-Green, décrit comment les distances entre les particules évoluent. Il est calculé à partir des données de champs de courants

$$\mathbf{C}_{t_0}^T = \left(\nabla \mathbf{F}_{t_0}^T \right)^T \left(\nabla \mathbf{F}_{t_0}^T \right) \quad (2.11)$$

- λ_{max} la plus grande valeur propre du tenseur de Cauchy-Green
- $\mathbf{x}_0$ la position initiale de la particule
- T le temps d'intégration pendant lequel on suit la particule
- σ le FTLE qui mesure le taux moyen de séparation des trajectoires des particules, exprimé en unité inverse du temps




Figure 2.8 – Advection Lagrangienne FTLE backward (30j) du 2023-01-26. Les valeurs élevées de FTLE délimitent des crêtes correspondant à des frontières de transport de l'écoulement (de fronts ou de tourbillons) le long desquelles convergent les masses d'eau (structures cohérentes lagrangiennes attractives)

Dans notre étude, la durée d'advection est de trente jours en backward, c'est-à-dire que les trajectoires sont intégrées vers l'arrière dans le temps (de t à $t - T$). La résolution temporelle est journalière et la résolution spatiale est de 0.05° . La figure 2.8 présente une carte de FTLE issue de la journée 2023-01-26. Les crêtes (valeurs élevées) de FTLE marquent les zones où les particules voisines se séparent le plus fortement, ce qui permet d'identifier des structures physiques réelles de l'écoulement océanique.

3 Méthode

Cette section décrit la modélisation réalisée du NASC par Forêts Aléatoires en fonction du FOD, FTLE et des ratios de concentrations pigmentaires : $NASC \sim FOD + FTLE + R_1, \dots, R_9$.

3.1 Forêts Aléatoires

3.1.1 Algorithme

3.1.2 Forêts aléatoires et sur-apprentissage

3.2 Schéma de validation

3.3 Ajustement des hyperparamètres

3.4 Validation

3.4.1 validation des données

Le biais d'échantillonnage et le covariate shift portent sur les données : on peut les mesurer sans même avoir de modèle, en comparant les données d'entraînement à celles de la population cible ou de la production. C'est de la validation des données.

3.4.2 validation du protocole

La fuite de données porte sur le protocole : elle vient de la façon dont on a construit les variables, séparé les jeux d'entraînement et de test, ou choisi les informations disponibles au moment de prédire. La vérifier, c'est valider la conception de l'expérience.

3.4.3 validation du modèle

Valider un modèle, c'est établir qu'il est adapté à son usage prévu : que ses hypothèses tiennent, qu'il s'appuie sur des relations légitimes, qu'il reste fiable dans les conditions où il sera employé, et dans quel domaine il est applicable. Chercher à savoir à savoir si sa performance est fiable et si elle tiendra dans les conditions réelles.

Le shortcut learning porte sur le modèle lui-même : il faut regarder ce qu'il a réellement appris, avec des outils d'interprétabilité ou des tests où l'on neutralise la variable suspecte. C'est de la validation du modèle au sens strict.

Une fuite ou un biais d'échantillonnage dans les données est souvent ce qui rend possible un raccourci dans le modèle, et un décalage de distribution est ce qui fait apparaître ce raccourci en production.

vérifier que le modèle n'overfit pas : robustesse au bruit vérifier que le modèle ne fait pas shortcut learning vérifier que le modèle est capable d'extrapoler

3.5 Evaluation du modèle

vérifier que le modèle prédit de manière fiable et non biaisé

3.6 Interprétation post-hoc

3.6.1 Importance des variables

3.6.2 Source du biais

3.6.3 Suffisances des informations contenues par les covariables

4 Méthode

4.1 Forêts aléatoires

4.1.1 Algorithme

4.1.2 Complexité, sur-apprentissage et erreur OOB

4.2 Validation des données

4.2.1 Biais d'échantillonnage (dont densité jour/nuit)

4.2.2 Décalage de distribution entre jeux de données

4.3 Protocole et découpage des données

4.3.1 Prévention des fuites de données

4.3.2 Validation croisée par blocs (autocorrélation)

4.4 Ajustement des hyperparamètres

4.5 Évaluation des performances

4.5.1 Métriques et biais des prédictions

4.6 Validation du modèle

4.6.1 Sur-apprentissage et robustesse

4.6.2 Recherche de raccourcis (shortcut learning)

4.6.3 Domaine d'applicabilité

4.7 Interprétation post-hoc

4.7.1 Importance des variables (covariables corrélées)

4.7.2 Analyse des résidus et suffisance des covariables

5 Résultats

5.1 Structure et validation des données

5.2 Performances du modèle

5.3 Validité du modèle

5.4 Prédictions

5.5 Interprétation

6 Discussion

- 6.1 L'échantillonnage permet-il de répondre à la problématique ?
- 6.2 Les variables mesurées représentent-elles correctement les construits ?
- 6.3 Prédiction ou explicabilité ?
- 6.4 Contrainte des modèles prédictifs
- 6.5 Mise en relation des résultats associatifs avec la théorie de causalité et hypothèses

Table des figures

2.1	Carte des transects effectués par le Marion Dufresnes II lors des campagnes océanographiques OBSAUSTRAL/THEMISTO 2018, 2021, 2022 et 2023.	6
2.2	Exemple d'échogramme obtenu le 2023-01-28 entre 18h et 00h aux fréquences (a) 38 kHz et (b) 120 kHz	7
2.3	NASC en fonction du temps le 2023-01-28, données d'acoustique active (transect) issues de la campagne océanographique OBSAUSTRAL 2023 [flotteoceanographique_campagnes].	
2.4	Carte de prédiction de la concentration de Chlorophylle-a le 2023-01-26 sur le secteur indient du SO, prédictions issue de l'algorithme PIGMeANN développé par Sari el Dine [sari2026regional]. La présence de nuages gêne grandement la prédiction sur la zone totale.	9
2.5	Profil de Température et de Salinité issue de GLORYS (CMEMS), tronqués en deçà de 20m et au delà de 500m aux coordonnées (50°E, 60°S).	11
2.6	Carte des Domaines Océanographiques Fonctionnels du 2023-01-26 générée par la méthode développée par Fonvieille N. et Nerini D. [fonvieille2024].	12
2.7		12
2.8	Advection Lagrangienne FTLE backward (30j) du 2023-01-26. Les valeurs élevées de FTLE délimitent des crêtes correspondant à des frontières de transport de l'écoulement (de fronts ou de tourbillons) le long desquelles convergent les masses d'eau (structures cohérentes lagrangiennes attractives)	14

Liste des tableaux

2.1	Neuf pigments photosynthétiques dont les concentrations sont estimées par l'algorithme PIGMeANN [sari2026regional].	9
2.2	Pigments photosynthétiques analysés et groupes phytoplanctoniques hypothétiquement associés (PFD et PSC) dans le secteur de Kerguelen en été austral, d'après [Lasbleiz2014], [sari2025influence]	10