



UNIVERSITÉ PARIS CITÉ

Master 2 Mathématiques et Informatique Appliquées à la Science des Données

Modélisation de la relation entre structuration environnementale, communautés phytoplanctoniques et distribution des Niveaux Trophiques Intermédiaires

Une étude en saison estivale dans le secteur Indien de l'Océan Austral

Rapport de stage

Rapport réalisé par

Elise NICOLAS

Encadrants

Marius MOLINET, David NERINI, Christophe GUINET, Cédric COTTE

Professeure référente

Aurélie FISHER

Septembre 2026

Résumé

Contexte. Le réchauffement climatique modifie la structure des communautés phytoplanctoniques de l'océan Austral, avec une possible diminution de la contribution des diatomées au profit du nano- et picophytoplancton. Ce changement pourrait allonger le réseau trophique et affecter la biomasse des Niveaux Trophiques Intermédiaires (NTI, zooplancton et micronecton), avec des répercussions en cascade sur l'ensemble des écosystèmes.

Objectif et méthode. La relation entre la biomasse des NTI, estimée par acoustique active (Nautical Area Scattering Coefficient, NASC, à 38 et 120 kHz) a été modélisée avec des Forêts aléatoires par un ensemble de variables environnementales (température, salinité, hydrodynamisme via le Finite-Time Lyapunov Exponent) et pigmentaires (neuf pigments photosynthétiques). L'étude porte sur le secteur indien de l'océan Austral, en saison estivale (janvier-mars), à partir des campagnes OBSAUSTRAL 2018, 2021, 2022 et 2023. Une attention particulière a été portée à la fiabilité de l'évaluation et l'interprétation du modèle : une comparaison entre validation croisée Monte-Carlo et validation par blocage spatio-temporel a été effectuée.

Résultats. Des cartes de prédictions de NASC ont été générées sur l'ensemble de la région pour chaque modèle de validation croisée. Malgré des écarts de performance importants entre les schémas de validation, les cartes obtenues sont similaires. Elles révèlent une structuration latitudinale inversée entre 38 et 120 kHz. Les domaines océanographiques fonctionnels (température/salinité) et la biomasse phytoplanctonique totale ressortent comme les plus importantes variables pour la prédiction du NASC et le microphytoplancton (diatomées, dinoflagellés) apparaît plus déterminant que le nano- et le picophytoplancton. La comparaison entre validation croisée Monte-Carlo et validation par blocage spatio-temporel révèle une fuite d'information substantielle dans le premier schéma, confirmée par une forte sensibilité au bruit. Chaque schéma de validation témoigne d'un plafond structurel des courbes d'apprentissage dont l'origine, limite informationnelle des covariables, densité d'échantillonnage, ou non-stationnarité spatiale non prise en compte, n'a pu être totalement départagée.

Conclusion et perspectives. Ces résultats suggèrent que la structuration environnementale (physico-chimique et hydrodynamique) prédomine sur la seule composition pigmentaire dans l'explication de la distribution du NASC par le Random Forest, sur la période et l'échelle considérées. Ils soulignent également la nécessité d'une évaluation méthodologiquement rigoureuse dans les modèles écologiques spatio-temporels. Des travaux futurs pourraient intégrer une méthode de sélection de variable plus étoffée, la complétion de données manquantes, un décalage temporel entre efflorescence phytoplanctonique et réponse des NTI, l'intégration explicite de la non-stationnarité, l'exploitation de données de bio-logging pour élargir la couverture spatio-temporelle, et recourir à des modèles de machine learning causal pour identifier les relations biologiques entre les variables étudiées.

Mots-clés : océan Austral, niveaux trophiques intermédiaires, acoustique active, phytoplancton, arbres de régression, validation croisée spatio-temporelle

Table des matières

1	Introduction	3
2	Matériel et pré-traitement des données	5
2.1	Zone d'étude et plan d'échantillonnage	5
2.2	Données d'acoustique active (OBSAUSTRAL) et construction du Nautical Area Scattering Coefficient (NASC)	5
2.2.1	Données d'acoustique active	5
2.2.2	Construction du Nautical Area Scattering Coefficient (NASC)	7
2.3	Concentrations de pigments photosynthétiques (PIGMeANN)	8
2.4	Données modèles de température et salinité (CMEMS) et calcul des Domaines Océanographiques Fonctionnels (FOD)	10
2.4.1	Données modèles de température et salinité (CMEMS)	10
2.4.2	Calcul des Domaines Océanographiques Fonctionnels (FOD)	11
2.5	Champs de courants modèles (CMEMS) et calcul du Finite Time Lyapunov Exponent (FTLE)	13
2.5.1	Données de Champs de courants modèles (CMEMS)	13
2.5.2	Calcul du Finite-Time Lyapunov Exponent	13
3	Méthode	15
3.1	Validation des données	15
3.1.1	Biais d'échantillonnage	15
3.1.2	Autocorrélation spatio-temporelle	16
3.1.3	Décalage de distribution (<i>Distribution shift</i>)	17
3.2	Arbre de Régression et Forêt Aléatoire	19
3.2.1	Bagging	19
3.2.2	Arbres de classification et de régression (CART)	19
3.2.3	Forêt Aléatoire	20
3.3	Protocole de validation croisée	21
3.3.1	Prévention des fuites de données	21
3.3.2	Validation croisée	21
3.4	Ajustement des hyperparamètres	21
3.5	Évaluation des performances	21
3.5.1	Métriques et biais des prédictions	21
3.6	Validation du modèle	21
3.6.1	Sur-apprentissage et robustesse	21
3.6.2	Recherche de raccourcis (shortcut learning)	21
3.6.3	Domaine d'applicabilité	21
3.7	Interprétation post-hoc	21
3.7.1	Importance des variables (covariables corrélées)	21
3.7.2	Analyse des résidus et suffisance des covariables	21
3.8	Schéma de validation	21
3.9	Ajustement des hyperparamètres	21
3.10	Validation	21
3.10.1	validation des données	21
3.10.2	validation du protocole	22
3.10.3	validation du modèle	22
3.11	Evaluation du modèle	22
3.12	Interprétation post-hoc	22
3.12.1	Importance des variables	22
3.12.2	Source du biais	22
3.12.3	Suffisances des informations contenues par les covariables	22

4	Résultats	23
4.1	Structure et validation des données	23
4.2	Performances du modèle	23
4.3	Validité du modèle	23
4.4	Prédictions	23
4.5	Interprétation	23
5	Discussion	24
5.1	L'échantillonnage permet-il de répondre à la problématique?	24
5.2	Les variables mesurées représentent elles correctement les construits?	24
5.3	Prédiction ou explicabilité?	24
5.4	Contrainte des modèles prédictifs	24
5.5	Pertinence des forêts aléatoires	24
5.6	Mise en relation des résultats associatifs avec la théorie de causalité et hypothèses	24
5.7	Domaine d'applicabilité du modèles et précautions d'interprétations	24
5.8	perspectives	24

1 Introduction

Le phytoplancton désigne l'ensemble des organismes unicellulaires photosynthétiques (« phyto ») dépourvus de capacité de déplacement autonome contre le courant (« plancton »). Ces organismes soutiennent les écosystèmes marins en constituant le premier maillon de la chaîne alimentaire, aussi appelée réseau trophique. Ils jouent par ailleurs un rôle fondamental dans le cycle du carbone, en structurant, par leur taille, leur composition et leur abondance, les apports de carbone vers les fonds marins. On parle de communauté phytoplanctonique pour désigner un assemblage particulier d'organismes phytoplanctoniques dans un espace et à un temps donné [reynolds2006ecology].

Le réchauffement climatique induit des changements rapides dans l'océan Austral : l'eau se réchauffe et s'adoucit sous l'effet de la fonte des glaces, les champs de courants et de vents se modifient, la stratification de la colonne d'eau s'accroît, etc. [sallee2018] [abram2025Antarctic]. Ces changements ne sont pas sans conséquences pour les communautés phytoplanctoniques [deppeler2017southern]. Des études récentes montrent des changements de phénologie [thomalla2023Widespread][boyce2017environ] d'abondance [hayward2024Antarctic] et de structuration des communautés phytoplanctoniques [adrolis2026].

Dans l'océan Austral, ces communautés sont dominées par les diatomées, grandes cellules phytoplanctoniques (microphytoplancton, 20-200 μm) à forte valeur énergétique [treguer1992] [heidemann2024drivers]. Les modifications induites par le réchauffement climatique tendraient à augmenter la biomasse phytoplanctonique [delcastillo2019greener] [adrolis2026] tout en diminuant la contribution relative des diatomées au profit du nano- et picophytoplancton, organismes à plus faible valeur énergétique [krumhardt2022climate][sari2025influence]. Les diatomées soutiennent un réseau trophique court et hautement productif [treguer1992]. Elles sont consommées par le grand zooplancton (copépodes, krill) et le micronecton (petits poissons), regroupés sous l'appellation de Niveaux Trophiques Intermédiaires (NTI). Ces organismes sont eux-mêmes consommés par de plus gros poissons pélagiques, à leur tour proies de plus grands prédateurs. Un changement de structuration des communautés phytoplanctoniques vers une plus forte proportion de petit phytoplancton favoriserait ainsi le développement d'un zooplancton de plus petite taille, lui-même consommé par des organismes plus petits [krumhardt2022climate]. Ainsi, on observerait un allongement du réseau trophique et donc une modification du transfert d'énergie à chacun de ses maillons jusqu'aux prédateurs supérieurs [mestre2020decadal] : on parle de cascade trophique. Un changement d'assemblage des communautés phytoplanctoniques impacterait donc l'ensemble de l'écosystème.

Caractériser ces changements est par conséquent nécessaire, mais difficile dans les écosystèmes pélagiques¹ : ces milieux étant très vastes et peu accessibles, leur échantillonnage à grande échelle est logistiquement coûteux. L'acoustique active constitue un moyen d'étude des NTI dans ces zones difficiles d'accès. Elle consiste à émettre une onde, à la réceptionner, puis à analyser le signal reçu (principe du sonar) [benoitbird2016ecological]. L'écho reçu résulte de la réflexion du son émis sur un objet (le fond marin, par exemple), un organisme, ou encore une discontinuité physique dans la colonne d'eau (changement de densité). La connaissance de la vitesse locale de propagation du son dans l'eau permet, à partir du délai de réception du signal et de son intensité, de renseigner la profondeur, l'abondance et d'inférer sur la composition taxonomique des organismes présents [benoitbird2016ecological]. Le Nautical Area Scattering Coefficient (NASC), calculé à partir des échos acoustiques reçus, permet de résumer la rétrodiffusion acoustique sur un ensemble de profondeur considérées en un certain point de l'espace [maclennan2002]. Il sert donc de proxy de la biomasse de NTI à cette localisation. L'océan Austral étant particulièrement vaste et difficile d'accès, les campagnes d'échantillonnages restent limitées et, dans ce contexte, il est particulièrement pertinent de développer des modèles prédictifs permettant de généraliser les estimations faites à partir des données déjà acquises.

1. Ensemble des organismes et de leur environnement vivant dans la colonne d'eau du large, c'est-à-dire en pleine eau, loin du fond et des côtes, par opposition au domaine benthique lié au fond marin.

Cette étude a cherché à développer un modèle prédictif de la biomasse des NTI en fonction de l'assemblage des communautés phytoplanctoniques et de l'activité de mésoéchelle. Plus précisément, nous avons modélisé le NASC avec des Forêts Aléatoires en fonction de 9 variables de concentration pigmentaires ($P_1, P_2, \dots, P_9$), 2 variables physiques, la température et salinité (FOD), et 1 variable capturant l'hydrodynamisme (FTLE). Ainsi, nous avons cherché à documenter la relation $NASC \sim FTLE + FOD + P_1 + P_2 + \dots + P_9$. Ce modèle, développé sur le secteur indien de l'océan Austral à partir de données d'acoustique active collectées lors des campagnes OBSAUSTRAL 2018, 2021, 2022 et 2023, a permis de créer des cartes prédictives de NASC sur l'ensemble de la région et de mettre en évidence les variables environnementales clés pour la prédiction. L'objectif étant d'informer les conséquences de la restructuration des communautés phytoplanctoniques sur les NTI du secteur Indien de l'océan Austral.

La section **Matériel** détaillera la nature des données utilisées (acoustique active, température, salinité, champs de courants et concentrations pigmentaires). La section **Méthode** présentera le calcul des variables d'intérêt NASC, FTLE et FOD. Cette section décrira ensuite brièvement la méthode Random Forest, le calcul de l'importance des variables et le pipeline d'apprentissage mis en place. La section **Résultat** présentera (1) les cartes de NASC prédites (2) les variables environnementales identifiées comme importantes pour la prédiction du NASC (3) l'interprétation du modèle. La **Discussion** portera sur la fiabilité du modèle, la difficulté liée à la nature même des données et la mise en perspective avec la littérature de l'effet structurant des variables environnementales considérées et de la nature des communautés phytoplanctoniques.

2 Matériel et pré-traitement des données

La biomasse de zooplancton et micronecton, l'assemblage des communautés phytoplanctoniques, l'environnement physique des organismes ne sont pas directement mesurables, ce sont des construits (*constructs*), c'est à dire des abstractions qui décrivent le phénomène théorique d'intérêt [edwards2000nature]. Pour étudier ces phénomènes, nous avons besoin de trouver des variables mesurables pouvant les décrire, c'est l'opérationnalisation du construit. Les choix des variables utilisées sont justifiés par la connaissances théorique des phénomènes étudiés, appuyés par la littérature. Les variables mesurables sont alors dites variables *proxy* pour les construits associés. [shmueli2010explain].

Les variables proxy sélectionnées sont les suivantes : (1) le Nautical Area Scattering Coefficient (NASC) approxime la biomasse du zooplancton et micronecton sur l'ensemble de la profondeur considérée ; (2) les concentrations pigmentaires ($P_1, \dots, P_9$) approximent l'assemblage des communautés phytoplanctoniques leur abondance totale ; (3) le Finite-Time Lyapunov Exponent (FTLE) approxime l'hydrodynamisme et (4) la température et la salinité rendent compte des conditions physico-chimiques du milieu.

Toutes les données utilisées pour cette étude sont des données secondaires, c'est-à-dire que le plan d'échantillonnage n'a pas été construit spécifiquement pour répondre à cette problématique.

2.1 Zone d'étude et plan d'échantillonnage

L'étude a été réalisée sur les années 2018, 2021, 2022 et 2023, en saison estivale (janvier-mars) afin de limiter la variabilité saisonnière, et de jour (calculé selon l'angle solaire), afin de limiter l'effet de la migration verticale journalière (DVM) ¹. La fenêtre d'étude a été fixée à $[45, 90]^\circ\text{E}$ de longitude et $[30, 60]^\circ\text{S}$ de latitude afin de cibler précisément le secteur indien de l'Océan Austral.

2.2 Données d'acoustique active (OBSAUSTRAL) et construction du Nautical Area Scattering Coefficient (NASC)

2.2.1 Données d'acoustique active

Les données d'acoustiques actives ont été collectées par transects ² lors des campagnes océanographiques OBSAUSTRAL/THEMISTO 2018, 2021, 2022, 2023 en saison estivale. Ils sont détaillés sur la figure 2.1 [flotteoceanographique_campagnes].

1. Déplacement synchronisé dans la colonne d'eau au rythme du cycle jour/nuit : les organismes résident en profondeur durant le jour et remontent vers la surface la nuit, principalement pour se nourrir tout en réduisant le risque de prédation visuelle en eaux éclairées. Ce phénomène est considéré comme le plus grand mouvement synchronisé de biomasse à l'échelle de la planète. [Bandara2021]

2. Le bateau se déplace et collecte en même temps des données, par opposition aux données "stations" collectées lorsque le bateau est en arrêt. Cela a un coût en terme de résolution des spectrogramme et d'interprétabilité mais permet d'obtenir une plus grande couverture spatiale.




Figure 2.1 – Carte des transects effectués par le Marion Dufresnes II lors des campagnes océanographiques OBSAUSTRAL/THEMISTO 2018, 2021, 2022 et 2023.

Deux fréquences d'émissions ont été sélectionnées : 38 kHz, afin de comparer nos résultats avec la littérature³ et 120 kHz, fréquence à laquelle les zooplanctons d'intérêts, Euphausiacés (krill) et Copépodes, sont les plus détectables (voir Annexe ??, figure ??). Les échogrammes (figures 2.2a et 2.2b) donnent un aperçu de la nature des données collectées et de la manière dont l'information contenue par le signal reçu (résolution, organismes visibles) est déterminée par la fréquence de l'onde émise. Une forte intensité de l'écho reçu traduit la présence d'une importante biomasse d'organisme à ce temps, localisation géographique et profondeur.

3. La méthode d'acoustique active ayant été développée par les pêcheries, la fréquence d'échosondeur de référence est 38kHz (fréquence à laquelle les poissons sont facilement détectables).




Figure 2.2 – Exemple d'échogramme obtenu le 2023-01-28 entre 18h et 00h aux fréquences (a) 38 kHz et (b) 120 kHz

2.2.2 Construction du Nautical Area Scattering Coefficient (NASC)

L'**Intensité de l'écho (Echo Level EL)** correspond au signal reçu par le transducteur lorsqu'une onde est émise dans la colonne d'eau puis réfléchi par un objet.

$$EL = SL - 2TL + DI + TS \quad (2.1)$$

où

- SL (Source Level) : intensité du son émise (dB) $SL = 10 \times \log_{10}(I/I_{ref})$ et $I_{ref} = \rho_{ref}^2 = 1\mu\text{Pa}$ (ρ_{ref} la pression de référence)
- TL (Transmission Loss) : perte de transmission⁴ $TL = 20 \log_{10}(R) + \alpha R$
- DI (Directivity Index) : indice de directivité du transducteur (dB)
- TS (Target Strength) : réflectivité de la cible

La **section efficace de rétrodiffusion** $\sigma_{bs} = 10^{\frac{TS}{10}}$ (m^2) caractérise la capacité de la cible à rétrodiffuser l'énergie acoustique.

Le **volume backscattering coefficient** s_v (en $\text{m}^2.\text{m}^{-3}$ ou m^{-1}) est la somme toutes les surfaces réfléchissantes σ_{bs} de toutes les cibles acoustiques dans le volume d'échantillonnage V_0 , normalisées à 1m^3 .

$$s_v = \sum \sigma_{bs}/V \quad (2.2)$$

Il mesure la densité acoustique des organismes présents dans un volume d'eau. Un niveau de s_v élevé correspond à une quantité plus importante de rétrodiffusion acoustique dans le volume échantillonné. Ce qui est interprété comme un nombre important d'organismes présents dans la colonne d'eau ou un organisme de taille importante ou encore un organisme ayant des propriétés fortement

4. Le premier terme correspond à l'atténuation due à la dispersion de l'onde et le second terme correspondant à l'atténuation de la propagation du milieu (α le coefficient d'absorption en dB.m^{-1})

rétrodiffusantes⁵. Par convention, on exprime souvent cette grandeur en échelle logarithmique sous le nom de Volume Backscattering Strength, noté S_v (dB re 1 m^{-1}) tel que $s_v = 10^{\frac{S_v}{10}}$.

Le **Nautical Area Scattering Coefficient (NASC)**, noté s_A , correspond au coefficient de rétrodiffusion acoustique par unité de surface nautique (en $\text{m}^2 \cdot \text{nmi}^{-2}$). Il résume la rétrodiffusion acoustique sur une couche d'eau donnée en intégrant entre deux profondeurs le volume backscattering coefficient s_v multiplié par un certain facteur (convention) :

$$s_A = 4\pi(1852)^2 \int_{z_1}^{z_2} s_v(z) dz \quad (2.3)$$

Dans le cadre de cette étude, la profondeur d'intégration z_1 a été fixé à 25 m pour limiter le bruit d'échantillonnage de surface⁶. Le choix de z_2 dépend de la fréquence de l'échosondeur : pour des fréquences de 38 kHz et 120 kHz, la colonne d'eau est échantillonnée respectivement jusqu'à une profondeur moyenne de 700 m et 300 m. En effet, à partir de ces profondeurs, beaucoup de données s_v sont manquantes (voir Annexe ??, figure ??). Les profils avec plus de 50% de valeurs manquantes ont été exclus du jeu de données. Les valeurs manquantes résiduelles ont été comblées : (1) par interpolation linéaire lorsque situées entre deux valeurs connues et (2) par prolongation de la valeur la plus proche, lorsque situées aux extrémités.

Ainsi, pour chaque profil de S_v , on calcule le NASC et obtenons un scalaire, qui résume le volume de rétrodiffusion acoustique sur l'ensemble de la couche d'eau considérée ([25-700]m pour 38kHz et [25-300]m pour 120kHz). La figure 2.3 présente le NASC en fonction du temps pour le transect 2023 OBSAUSRAL.




Figure 2.3 – NASC en fonction du temps le 2023-01-28, données d'acoustique active (transect) issues de la campagne océanographique OBSAUSRAL 2023 [flotteoceanographique_campagnes].

2.3 Concentrations de pigments photosynthétiques (PIGMeANN)

La couleur des océans dépend de leur composition en pigments et ces pigments sont contenus dans les organismes phytoplanctoniques. L'analyse de la couleur des océans à partir d'images satellite permet donc d'étudier les communautés phytoplanctoniques sur une échelle spatiale et temporelle large. L'algorithme PIGMeANN [sari2026regional] associe, à l'aide de réseaux neuronaux profonds, une empreinte spectrale⁷ à des mesures de concentrations de pigments phytoplanctoniques *in-situ*

5. De nombreux poissons pélagiques présentent des vessies natatoires gazeuses ou lipidiques, organes leur permettant d'ajuster leur flottabilité. A 38 kHz, ces organes ont des propriétés retro-diffusantes particulières : ils amplifient le signal

6. effet de "bullage" du bateau bruitant les données à des faibles profondeurs

7. Forme caractéristique du spectre de la lumière réfléchiée par l'eau, c'est-à-dire de la façon dont la réflectance varie selon la longueur d'onde. Chaque pigment absorbe la lumière à des longueurs d'onde précises : des communautés de composition pigmentaire différente produisent donc des spectres de forme différente.

obtenues par High Performance Liquid Chromatography (HPLC)⁸. Ainsi, cette méthode permet de prédire les concentrations de neuf pigments phytoplanctoniques sur l'ensemble de la ROI. Ils sont détaillés dans le tableau 2.1.

Pigment	Divinyl chloro- phyll <i>a</i>	Chloro- phyll <i>a</i>	Chloro- phyll <i>b</i>	Zéaxan- thine	Fucoxan- thine	19'- hexanoyl- oxyfuco- xanthine	19'- butanoyl- oxyfuco- xanthine	Allo- xanthine	Péridinine
---------	--------------------------------------	---------------------------	---------------------------	------------------	-------------------	---	---	-------------------	------------

Table 2.1 – Neuf pigments photosynthétiques dont les concentrations sont estimées par l'algorithme PIGMeANN [sari2026regional].

La figure 2.4 illustre la prédiction par PIGMeANN de la Chlorophylle-a le 2023-01-26 sur le secteur étudié. Les zones non colorées correspondent sont des données manquantes. La forte couverture nuageuse de la région induit une absence de données satellitaires, et donc des concentrations prédites par PIGMeANN.




Figure 2.4 – Carte de prédiction de la concentration de Chlorophylle-a le 2023-01-26 sur le secteur indien du SO, prédictions issue de l'algorithme PIGMeANN développé par Sari el Dine [sari2026regional]. La présence de nuages gêne grandement la prédiction sur la zone totale.

Plutôt que les concentrations pigmentaires absolues, on s'intéresse aux concentrations relative, c'est-à-dire le ratio des concentrations de pigments sur la somme des concentrations pigmentaires totale (Chlorophylle-a exclue⁹) :

$$R_i = \frac{[\text{Pigment}_i]}{\sum_{j \neq \text{Chla}} [\text{Pigment}_j]} \quad (2.4)$$

La concentration relative R_i la plus importante à une certaine localisation et temps permet d'identifier hypothétiquement les classes taxonomique (Phytoplanctonique Functional Types, PFT) ou de taille (Phytoplanktonic Size Class, PSC) dominantes de la communauté, par association avec les connaissances théoriques développées dans la littérature [sari2025influence], [heidemann2024drivers] [Georges2014]. Ces correspondances sont détaillées dans le tableau 2.2.

8. Permet de séparer et quantifier les pigments afin d'identifier les différents groupes phytoplanctoniques présents. L'échantillon est injecté dans une colonne traversée par un solvant sous haute pression, où ses différents composés sont séparés puis détectés individuellement.

9. ubiquitaire, elle n'apporte pas d'information sur la composition de la communauté

L'abondance totale de phytoplancton est estimée par la concentration absolue en Chlorophylle-*a*, pigment ubiquitaire présent chez la majorité des organismes photosynthétiques.

Pigment	Abréviation	Groupe phytoplanctonique associé (PFD)	Classe de taille (PSC)
Divinyl chlorophylle <i>a</i>	dvChla	Procaryotes picoplanctoniques (<i>Prochlorococcus</i>)	Picophytoplancton
Chlorophylle <i>a</i>	Chla	Marqueur de biomasse totale (tous groupes)	–
Chlorophylle <i>b</i>	Chlb	Chlorophycées / Prasinophycées	Picophytoplancton
Zéaxanthine	Zea	Cyanobactéries (<i>Synechococcus</i>)	Picophytoplancton
Fucoxanthine	Fuco	Diatomées (dominantes)	Microphytoplancton
19'-hexanoyloxyfucoxanthine	Hex	Prymnésiophycées (haptophytes)	Nanophytoplancton
19'-butanoyloxyfucoxanthine	But	Prymnésiophycées / pélagophytes	Nanophytoplancton
Alloxanthine	Allo	Cryptophycées	Nanophytoplancton
Péridinine	Per	Dinoflagellés (péridiniens)	Microphytoplancton

Table 2.2 – Pigments photosynthétiques analysés et groupes phytoplanctoniques hypothétiquement associés (PFD et PSC) dans le secteur de Kerguelen en été austral, d'après [Lasbleiz2014], [sari2025influence]

2.4 Données modèles de température et salinité (CMEMS) et calcul des Domaines Océanographiques Fonctionnels (FOD)

2.4.1 Données modèles de température et salinité (CMEMS)

Les données de températures et salinité font partie du jeu de données "Global Ocean Physics Reanalysis" (la réanalyse GLORYS12V1, GLOBAL_MULTIYEAR_PHY_001_030) [cmems_glorys12], issues de la plateforme Copernicus¹⁰. Ce sont des données issues des observations temps-réelles CMEMS¹¹ et réanalysées par le modèle NEMO¹², et ERA5¹³. Elles ont une résolution spatiale de 0.083° et une résolution temporelle journalière. Afin d'alléger le traitement des données, seules les mesures de température et de salinité comprises entre 20 et 500 m de profondeur ont été conservées. La figure 2.5 présente un exemple de profile de température et salinité à 50°E de longitude, 60°S de latitude, le 2023-01-26.

10. Programme d'observation de la Terre de l'Union européenne, qui fournit notamment des données et services permettant de surveiller et comprendre l'état de l'environnement, dont l'océan [copernicus2026services]

11. Copernicus Marine Environment Monitoring Service, service marin de Copernicus

12. Nucleus for European Modelling of the Ocean, modèle numérique de l'océan qui simule l'évolution de paramètres comme la température, la salinité, les courants et le niveau de la mer

13. Modèle atmosphérique de l'ECMWF (European Centre for Medium-Range Weather Forecasts) qui fournit les conditions atmosphériques nécessaires pour forcer le modèle océanique NEMO à sa surface




Figure 2.5 – Profil de Température et de Salinité issue de GLORYS (CMEMS), tronqués en deçà de 20m et au delà de 500m aux coordonnées (50°E, 60°S).

2.4.2 Calcul des Domaines Océanographiques Fonctionnels (FOD)

Les Domaines Océanographiques Fonctionnels (FOD, Functional Oceanographic Domain) sont des masses d'eau ayant des caractéristiques thermohalines similaires. La méthode d'identification des FOD a été développée par Fonvieille N. et Nerini D. [fonvieille2024]. Les profils de température et salinité sont, dans un premier temps (1), estimées dans un espace fonctionnel par projection sur une base de B-spline. Dans un second temps (2), la dimension de la matrice des coefficients de pondération des B-splines est réduite par Analyse par Composante Principale (PCA, Principal Component Analysis). Dans un dernier temps (3), un clustering (GMM) est appliqué à K composantes principales déterminé par la PCA de l'étape précédente. Ces trois étapes sont développées en Annexe ??.

Dans notre étude, l'estimation par projection sur une base de B-splines a été effectué avec l'hyperparamètre de régularisation $\lambda = 0.25$, pour $K = 25$ B-splines. Sont conservées pour le clustering 6 composantes principales (> 0.99 % explained var., voir tableau ??). L'indice BIC nous permet de sélectionner $n_{clust} = 6$ clusters. En ajoutant les classes de transitions (les soft classes, c'est-à-dire toutes les données dont la probabilité d'appartenance au cluster le plus probable est inférieure à $thr = 0.75$), on obtient alors 13 clusters distincts (7 clusters de "transitions")¹⁴, ce sont les 13 Domaines Océanographiques Fonctionnels (FOD).

14. La classe "NA" correspond aux clusters manquants sur le plateau de Kerguelen. Les profils de température et salinité allant de 20 à 500m, sont retirés des calculs tout profils ayant des données manquantes entre ces deux valeurs. Les zones où la bathymétrie est inférieure à 500m sont donc exclues de ces calculs.





Figure 2.6 – Carte des Domaines Océanographiques Fonctionnels du 2023-01-26 générée par la méthode développée par Fonvieille N. et Nerini D. [fonvieille2024].



(a) Profil de température (°C) moyenné par cluster

(b) Profil de salinité (PSU) moyenné par cluster

Figure 2.7

La figure 2.6 illustre les 13 FOD capturés le 2023-01-26. Pour chacun des FOD, les profils de température et de salinité moyennés sur l'ensemble de la période d'étude sont présentés en figure ???. Chaque FOD correspond donc une masse d'eau ayant des propriétés thermohalines similaires.

La projection de ces FOD sur une carte permet également de visualiser l'hydrodynamisme de la région. Les fronts sont des zones de rencontres entre des masses d'eau ayant propriétés hydrologiques différentes. Les FOD de "transition" permettent de les identifier : T2-3 correspond à la transition entre le cluster 2 et le cluster 3. Sa latitude ($\approx 50^\circ\text{S}$) permet de l'identifier comme Front Polaire. En suivant la même méthode, on peut identifier le Front Subantarctique (T3-4) et le front sub-tropical (T4-5/T4-6). Les tourbillons sont des courants en vortex, ce qui empêche les masses d'eau de se mélanger entre elles. Ainsi, on peut également identifier les tourbillons sur les cartes de FOD : ce sont les régions où, localement, un FOD est présent, entouré par un autre FOD dominant. Sur la figure 2.6, on remarque par exemple un tourbillon aux coordonnées (53°E , 27°S) environ : le cluster 5 est pris dans un tourbillon.

2.5 Champs de courants modèles (CMEMS) et calcul du Finite Time Lyapunov Exponent (FTLE)

2.5.1 Données de Champs de courants modèles (CMEMS)

Les champs de courants sont des données modèles également issues du modèle de réanalyse océanique GLORYS12 du Copernicus Marine Service (CMEMS), détaillé en section 2.4.1. Les champs de courants de surface (composantes zonale (u) et méridienne (v)) en sont extraits avec une résolution journalière.

2.5.2 Calcul du Finite-Time Lyapunov Exponent

Le Finite Time Lyapunov Exponent est un indicateur qui permet de caractériser la séparation ou la convergence de trajectoires de particules d'eau sur une durée finie. On peut ainsi identifier les structures dynamiques susceptibles de contrôler le transport et la dispersion dans l'océan [shadden2005definition], [dovido2004mixing]. Son calcul, effectué dans cette étude par Molinet M.¹⁵ est le suivant :

On considère le champ de vitesse bidimensionnel dépendant de la position et du temps, issu des données de réanalyse GLORYS21 :

$$\mathbf{u}(x, y, t) = \begin{pmatrix} u(x, y, t) \\ v(x, y, t) \end{pmatrix} \quad (2.5)$$

avec u et v représentant respectivement les composantes zonale et méridienne de la vitesse, et où $\mathbf{x} = (x, y)$ désigne la position de la particule.

À partir d'une position initiale $\mathbf{x}_0$ au temps t_0 , la trajectoire d'une particule est obtenue en intégrant, dans notre cas avec la méthode Runge-kutta (RK4), l'équation d'advection :

$$\frac{d\mathbf{x}}{dt} = \mathbf{u}(\mathbf{x}, t), \quad \mathbf{x}(t_0) = \mathbf{x}_0. \quad (2.6)$$

Après une durée d'intégration T , la position finale de la particule peut être décrite à l'aide du flot lagrangien :

$$\mathbf{x}(t_0 + T) = \mathbf{F}_{t_0}^T(\mathbf{x}_0), \quad (2.7)$$

où $\mathbf{F}_{t_0}^T$ est l'application qui associe à chaque position initiale $\mathbf{x}_0$ sa position après une durée T .

On peut ensuite analyser la variation des trajectoires $\mathbf{F}_{t_0}^T(x_0)$ après un temps T si l'on change la position initiale x_0 des particules (tenseur de déformation) :

$$\nabla \mathbf{F}_{t_0}^T = \frac{\partial \mathbf{F}_{t_0}^T}{\partial \mathbf{x}_0} = \begin{pmatrix} \frac{\partial F_x}{\partial x_0} & \frac{\partial F_x}{\partial y_0} \\ \frac{\partial F_y}{\partial x_0} & \frac{\partial F_y}{\partial y_0} \end{pmatrix} \quad (2.8)$$

Le tenseur de Cauchy-Green permet de quantifier la déformation des distances entre des particules

15. Doctorant au MIO et CEBC, encadrant de ce stage

initialement proches. Il est défini par :

$$\mathbf{C}_{t_0}^T(\mathbf{x}_0) = \left(\nabla \mathbf{F}_{t_0}^T(\mathbf{x}_0) \right)^T \nabla \mathbf{F}_{t_0}^T(\mathbf{x}_0). \quad (2.9)$$

Le facteur maximal d'étirement entre les particules est donné par la plus grande valeur propre λ_{max} du tenseur de Cauchy-Green $\mathbf{C}_{t_0}^T(\mathbf{x}_0)$

Le FTLE ($\sigma_{t_0}^T$) est ensuite calculé, il correspond au taux de croissance logarithmique du facteur d'étirement maximal λ_{max} , normalisé par la durée d'intégration T :

$$\sigma_{t_0}^T(\mathbf{x}_0) = \frac{1}{|T|} \ln \left(\sqrt{\lambda_{max}(\mathbf{C}_{t_0}^T(\mathbf{x}_0))} \right) \quad (2.10)$$

avec :

- $\mathbf{C}_{t_0}^T$ le tenseur de Cauchy-Green, décrit comment les distances entre les particules évoluent. Il est calculé à partir des données de champs de courants

$$\mathbf{C}_{t_0}^T = \left(\nabla \mathbf{F}_{t_0}^T \right)^T \left(\nabla \mathbf{F}_{t_0}^T \right) \quad (2.11)$$

- λ_{max} la plus grande valeur propre du tenseur de Cauchy-Green
- $\mathbf{x}_0$ la position initiale de la particule
- T le temps d'intégration pendant lequel on suit la particule
- σ le FTLE qui mesure le taux moyen de séparation des trajectoires des particules, exprimé en unité inverse du temps




Figure 2.8 – Advection Lagrangienne FTLE backward (30j) du 2023-01-26. Les valeurs élevées de FTLE délimitent des crêtes correspondant à des frontières de transport de l'écoulement (de fronts ou de tourbillons) le long desquelles convergent les masses d'eau (structures cohérentes lagrangiennes attractives)

Dans notre étude, la durée d'advection est de trente jours en backward, c'est-à-dire que les trajectoires sont intégrées vers l'arrière dans le temps (de t à $t - T$). La résolution temporelle est journalière et la résolution spatiale est de 0.05° . La figure 2.8 présente une carte de FTLE issue de la journée 2023-01-26. Les crêtes (valeurs élevées) de FTLE marquent les zones où les particules voisines se séparent le plus fortement, ce qui permet d'identifier des structures physiques réelles de l'écoulement océanique.

3 Méthode

Ce chapitre décrit le protocole de validation des données et de modélisation du NASC par Forêts Aléatoires en fonction du FOD, FTLE et des ratios de concentrations pigmentaires : $NASC \sim FOD + FTLE + R_1, \dots, R_9$. On décrira dans un premier temps le protocole de validation des données, puis, dans un second temps, le protocole d'apprentissage par Forêt Aléatoire (méthode, validation croisée, ajustement des hyperparamètres) suivi par l'évaluation du modèle, sa validation et enfin son interprétation.

3.1 Validation des données

Les variables $NASC$, $FTLE$, FOD et $R_1, \dots, R_9$ sont des séries spatio-temporelles, acquises le long des trajets des campagnes océanographiques. Plusieurs de leurs propriétés peuvent compromettre l'apprentissage ou fausser l'évaluation du modèle : un échantillonnage déséquilibré ou informatif, des différences de distribution entre sous-ensembles de données, et une dépendance entre observations voisines. Cette section vise à caractériser ces propriétés indépendamment de tout modèle, afin (1) de justifier les choix de prétraitement, (2) de construire un schéma de validation croisée adapté et (3) de délimiter le domaine dans lequel les estimations du modèle pourront être interprétées.

Notations

Les données sont constituées de n unités élémentaires d'échantillonnage (*Elementary Sampling Units*, ESU). Pour chaque ESU $i \in \{1, \dots, n\}$, on note :

- $Y_i \in \mathbb{R}_+$ la valeur du $NASC$ (variable cible) ;
- $X_i = (X_i^{(1)}, \dots, X_i^{(d)}) \in \mathbb{R}^d$ le vecteur des covariables (FOD , $FTLE$ et $R_1, \dots, R_9$, soit $d = 11$) ;
- $s_i \in \mathbb{R}^2$ la position de l'ESU, exprimée en degré de latitude et longitude ;
- $\tau_i \in \mathbb{R}$ l'instant d'acquisition ;
- $c_i \in \mathcal{C}$ la campagne océanographique d'acquisition.

Une partition naturelle des données est une partition $\{G_1, \dots, G_K\}$ de l'ensemble des indices $\{1, \dots, n\}$, dont chaque élément G_k est appelé modalité. On considérera deux types de partitions : spatiale, où $G_k = \{i : s_i \in C_k\}$ pour une cellule C_k d'une grille régulière couvrant la zone d'étude, et temporelle, où $G_k = \{i : c_i = c\}$ pour une campagne $c \in \mathcal{C}$. On note $n_k = |G_k|$ l'effectif de la modalité k .

3.1.1 Biais d'échantillonnage

Un biais d'échantillonnage peut affecter l'apprentissage de plusieurs manières. Par exemple : (1) une densité d'échantillonnage déséquilibrée conduit à un sous-apprentissage des conditions peu échantillonnées, et donc à une dégradation des performances prédictives dans ces conditions ; (2) lorsque la présence d'une observation dépend d'autres variables, voire de la valeur de la cible elle-même, les données disponibles ne sont plus représentatives de la population totale, ce qui induit un biais de sélection. Il est donc nécessaire d'identifier ces biais afin d'interpréter correctement les estimations du modèle et d'en encadrer la portée.

Formellement, soit $S \in \{0, 1\}$ l'indicatrice d'échantillonnage d'un point (s, τ) du domaine d'étude. Les données observées sont issues de la loi conditionnelle $P(X, Y \mid S = 1)$, et non de la loi $P(X, Y)$ de la population. L'échantillonnage est dit *ignorable* pour l'estimation de $f(x) = \mathbb{E}[Y \mid X = x]$ si S est indépendant de Y conditionnellement à X :

$$P(S = 1 \mid X, Y) = P(S = 1 \mid X). \quad (3.1)$$

Dans ce cas, $\mathbb{E}[Y \mid X, S = 1] = \mathbb{E}[Y \mid X]$ et la relation apprise reste valable dans la population, même si la loi des covariables $P(X \mid S = 1)$ diffère de $P(X)$. Si au contraire la probabilité d'échantillonnage dépend de Y (échantillonnage *informatif*), l'estimateur appris est biaisé.

Les données de *NASC* sont des données *in situ*, acquises lors des campagnes océanographiques OBSAUSTRAL/THEMISTO. On s'intéressera au déséquilibre de l'échantillonnage selon les deux partitions naturelles définies plus haut : spatiale et temporelle. Pour chacune, on étudiera (1) la densité d'échantillonnage et (2) la distribution et la nature des valeurs manquantes.

Densité d'échantillonnage

Le déséquilibre spatial sera décrit par les effectifs n_k des cellules de deux grilles de résolutions différentes (20×20 km et 1500×1000 km), représentés sous forme de cartes de densité d'échantillonnage. Le déséquilibre temporel sera décrit par les effectifs $n_c = |\{i : c_i = c\}|$ des campagnes $c \in \mathcal{C}$.

Les deux partitions seront ensuite croisées. Pour une cellule C_k et une campagne c , on note $n_{k,c} = |\{i : s_i \in C_k, c_i = c\}|$ et $\pi_{c|k} = n_{k,c}/n_k$ la proportion des ESU de la cellule k issues de la campagne c . Une cellule telle que $\pi_{c|k} = 1$ n'a été échantillonnée que lors de la campagne c : les effets de la zone et de la campagne y sont alors confondus et indiscernables pour le modèle.

On évaluera ensuite le caractère informatif de l'échantillonnage. Pour chaque ESU, on définit la densité locale d'échantillonnage

$$\delta_i = |\{i' \neq i : \|s_{i'} - s_i\| \leq h, |\tau_{i'} - \tau_i| \leq \Delta\}|, \quad (3.2)$$

c'est-à-dire le nombre d'ESU acquises dans un voisinage spatial de rayon h et temporel de demi-largeur Δ . L'association entre Y et δ sera quantifiée par le coefficient de corrélation de rang de Spearman r_S entre $(Y_1, \dots, Y_n)$ et $(\delta_1, \dots, \delta_n)$, ainsi que par la comparaison des distributions du *NASC* entre ESU de forte et de faible densité (au-dessus et en dessous de la médiane de δ). Une association marquée signalerait une violation possible de (3.1) : l'échantillonnage porte alors de l'information sur la cible, et le modèle risque d'effectuer un *shortcut learning*.

Distribution et nature des valeurs manquantes

Pour chaque ESU i et chaque variable j , on note $M_i^{(j)} = \mathbb{1}_{\{X_i^{(j)} \text{ manquante}\}}$ l'indicatrice de valeur manquante, et $M_i = (M_i^{(1)}, \dots, M_i^{(d)}) \in \{0, 1\}^d$ le motif de valeurs manquantes de l'ESU. On quantifiera d'abord le taux de valeurs manquantes par variable et par modalité :

$$\overline{M}_k^{(j)} = \frac{1}{n_k} \sum_{i \in G_k} M_i^{(j)}. \quad (3.3)$$

On cherchera ensuite à déterminer si certaines variables manquent conjointement, en dénombrant les ESU partageant chaque motif $m \in \{0, 1\}^d$; cette structure sera représentée par un graphique UpSet.

Enfin, on caractérisera le mécanisme de non-réponse selon la typologie de Rubin [rubin1976]. Les données sont dites manquantes complètement au hasard (MCAR) si $P(M | X, Y) = P(M)$, manquantes au hasard (MAR) si M ne dépend que des valeurs observées, et manquantes non au hasard (MNAR) si M dépend des valeurs non observées elles-mêmes. L'hypothèse MCAR sera examinée en comparant, pour chaque variable j , les distributions de Y et des autres covariables entre les ESU telles que $M_i^{(j)} = 1$ et celles telles que $M_i^{(j)} = 0$: une différence marquée exclut le mécanisme MCAR, et la suppression des ESU incomplètes introduirait alors un biais de sélection.

3.1.2 Autocorrélation spatio-temporelle

Les observations acquises le long d'un trajet sont d'autant plus semblables qu'elles sont proches dans l'espace et dans le temps. Cette dépendance a trois conséquences : (1) elle réduit le nombre effectif d'observations indépendantes, ce qui rend optimistes les tests statistiques classiques ; (2) elle compromet l'évaluation du modèle : lors du tirage bootstrap des Forêts Aléatoires, comme lors d'une validation croisée aléatoire, une observation de test a presque toujours des voisines dans le jeu d'entraînement, ce qui conduit à surestimer les performances (erreur *out-of-bag* optimiste) ; (3) elle favorise la mémorisation de la localisation : lorsque les covariables varient lentement dans l'espace, leur combinaison identifie une zone, et le modèle peut restituer le *NASC* observé dans cette zone

plutôt qu'apprendre une relation entre variables (*shortcut learning*).

Pour illustrer la première conséquence, si les observations d'une série suivent un processus autorégressif d'ordre 1 de coefficient $\rho \in [0, 1[$, la variance de la moyenne empirique de n observations est celle de la moyenne de n_{eff} observations indépendantes, avec

$$n_{\text{eff}} \approx n \frac{1 - \rho}{1 + \rho}, \quad (3.4)$$

de sorte que, par exemple, $\rho = 0,9$ divise le nombre effectif d'observations par environ 19.

Dans la suite, Z_i désigne indifféremment Y_i ou l'une des covariables $X_i^{(j)}$: les analyses seront conduites pour le *NASC* et pour chacune des covariables, dont les échelles de structuration peuvent différer.

Autocorrélation spatiale

L'autocorrélation spatiale sera caractérisée par le semi-variogramme empirique

$$\hat{\gamma}(h) = \frac{1}{2|N(h)|} \sum_{(i,i') \in N(h)} (Z_i - Z_{i'})^2, \quad (3.5)$$

où $N(h) = \{(i, i') : h - \frac{\varepsilon}{2} \leq \|s_i - s_{i'}\| < h + \frac{\varepsilon}{2}\}$ est l'ensemble des paires d'ESU séparées d'une distance proche de h , à la tolérance ε près. Pour séparer les effets spatial et temporel, le semi-variogramme sera calculé à l'intérieur de chaque campagne. Un modèle paramétrique (sphérique ou exponentiel) sera ajusté à $\hat{\gamma}$; sa portée a est la distance au-delà de laquelle $\hat{\gamma}$ atteint son palier, c'est-à-dire au-delà de laquelle deux observations ne sont plus corrélées.

L'indice de Moran fournira un résumé global de l'autocorrélation spatiale :

$$I = \frac{n}{W} \frac{\sum_{i=1}^n \sum_{i'=1}^n w_{ii'} (Z_i - \bar{Z})(Z_{i'} - \bar{Z})}{\sum_{i=1}^n (Z_i - \bar{Z})^2}, \quad W = \sum_{i=1}^n \sum_{i'=1}^n w_{ii'}, \quad (3.6)$$

où $w_{ii'} = \mathbb{1}_{\{0 < \|s_i - s_{i'}\| \leq h\}}$ pondère les paires d'ESU voisines. En l'absence d'autocorrélation, $\mathbb{E}[I] = -1/(n-1) \approx 0$; une valeur positive indique que des ESU voisines ont des valeurs semblables.

Autocorrélation temporelle

Le long d'un trajet, les ESU sont ordonnées et régulièrement espacées. Pour une série $Z_1, \dots, Z_T$ ainsi ordonnée, la fonction d'autocorrélation empirique au décalage ℓ est

$$\hat{\rho}(\ell) = \frac{\sum_{t=1}^{T-\ell} (Z_t - \bar{Z})(Z_{t+\ell} - \bar{Z})}{\sum_{t=1}^T (Z_t - \bar{Z})^2}, \quad \ell = 0, 1, \dots \quad (3.7)$$

La portée temporelle sera estimée par le plus petit décalage ℓ tel que $|\hat{\rho}(\ell)|$ passe sous le seuil de significativité $1,96/\sqrt{T}$. Le navire se déplaçant au cours de l'acquisition, un décalage le long du trajet correspond à la fois à une durée et à une distance : l'autocorrélation temporelle ainsi mesurée mêle donc les deux composantes.

Conséquence pour la validation croisée

Les portées spatiale et temporelle serviront à dimensionner les blocs de la validation croisée, dont la taille devra leur être au moins égale, éventuellement complétée par une zone tampon de largeur a entre blocs d'entraînement et de test.

3.1.3 Décalage de distribution (*Distribution shift*)

Un modèle entraîné sur une partie des données puis appliqué à une autre (extrapolation) suppose que les deux sont issues d'une même distribution. Lorsque ce n'est pas le cas (*distribution shift*), les performances mesurées sur les données d'entraînement ne sont pas représentatives des performances en conditions d'application. On étudiera ce décalage entre les modalités des partitions naturelles correspondant à l'usage visé du modèle, à savoir les campagnes et les zones géographiques.

Pour deux modalités k et k' , on note P_k et $P_{k'}$ les lois jointes de (X, Y) dans chacune d'elles. Les décompositions $P(X, Y) = P(X)P(Y | X) = P(Y)P(X | Y)$ conduisent à distinguer trois types de décalage [morenotorres2012] :

- le décalage des covariables (*covariate shift*) : $P_k(X) \neq P_{k'}(X)$, mais $P_k(Y | X) = P_{k'}(Y | X)$;
- le décalage de la cible (*label shift*) : $P_k(Y) \neq P_{k'}(Y)$, mais $P_k(X | Y) = P_{k'}(X | Y)$;
- le décalage de concept (*concept shift*) : $P_k(Y | X) \neq P_{k'}(Y | X)$, c'est-à-dire que la relation entre covariables et cible elle-même change.

Les deux premiers peuvent être étudiés sur les données seules ; le troisième, qui ne peut être évalué sans modèle, sera étudié lors de la validation du modèle.

Décalage des covariables

Pour chaque variable j , les distributions seront comparées entre modalités par des densités superposées et par la statistique de Kolmogorov-Smirnov

$$D_{k,k'}^{(j)} = \sup_{x \in \mathbb{R}} |\hat{F}_k^{(j)}(x) - \hat{F}_{k'}^{(j)}(x)|, \quad (3.8)$$

où $\hat{F}_k^{(j)}$ est la fonction de répartition empirique de $X^{(j)}$ dans la modalité k .

Une attention particulière sera portée aux plages de valeurs couvertes : les Forêts Aléatoires n'extrapolant pas au-delà de la plage observée à l'entraînement, une modalité dont les covariables sortent de cette plage se situe hors du domaine d'applicabilité du modèle. Pour un ensemble d'entraînement G_{train} et une modalité d'application G_k , on mesurera la proportion d'ESU hors plage

$$\pi_k^{\text{out}} = \frac{1}{n_k} \sum_{i \in G_k} \mathbb{1}_{\{\exists j: X_i^{(j)} \notin [x_{\min}^{(j)}, x_{\max}^{(j)}]\}}, \quad (3.9)$$

où $x_{\min}^{(j)} = \min_{i' \in G_{\text{train}}} X_{i'}^{(j)}$ et $x_{\max}^{(j)} = \max_{i' \in G_{\text{train}}} X_{i'}^{(j)}$ délimitent la plage de la variable j observée à l'entraînement.

Le décalage multivarié sera ensuite évalué par validation adversariale. Pour deux modalités k et k' , on attribue à chaque ESU $i \in G_k \cup G_{k'}$ l'étiquette $A_i = \mathbb{1}_{\{i \in G_k\}}$, et on entraîne un classifieur $\hat{g} : \mathbb{R}^d \rightarrow [0, 1]$ estimant $P(A = 1 | X)$ à partir des seules covariables. Sa capacité à séparer les deux modalités est mesurée par l'aire sous la courbe ROC, estimée par

$$\widehat{\text{AUC}} = \frac{1}{n_k n_{k'}} \sum_{i \in G_k} \sum_{i' \in G_{k'}} \left(\mathbb{1}_{\{\hat{g}(X_i) > \hat{g}(X_{i'})\}} + \frac{1}{2} \mathbb{1}_{\{\hat{g}(X_i) = \hat{g}(X_{i'})\}} \right), \quad (3.10)$$

c'est-à-dire la probabilité qu'une ESU de G_k tirée au hasard reçoive un score plus élevé qu'une ESU de $G_{k'}$. Une valeur proche de 0,5 indique des distributions indiscernables, une valeur proche de 1 des distributions disjointes. Les scores $\hat{g}(X_i)$ seront calculés hors échantillon, par une validation croisée par blocs spatiaux : avec une validation croisée aléatoire, l'autocorrélation permettrait au classifieur de reconnaître des ESU voisines de celles vues à l'entraînement, et gonflerait l'AUC. L'importance des variables de ce classifieur identifie celles qui portent le décalage.

Décalage de la cible

Le décalage sera également examiné sur la variable cible, en comparant les distributions du $NASC$ entre modalités par la statistique (3.8) appliquée à Y , ainsi que par la proportion de valeurs nulles $\frac{1}{n_k} \sum_{i \in G_k} \mathbb{1}_{\{Y_i=0\}}$ dans chaque modalité.

Taille des effets

Compte tenu du nombre d'observations et de leur autocorrélation (3.4), les tests statistiques seront presque systématiquement significatifs ; l'interprétation reposera donc sur la taille des effets plutôt que sur les p -valeurs : la statistique $D_{k,k'}^{(j)}$, l'AUC adversariale et le coefficient de recouvrement des densités

$$\text{OVL}_{k,k'}^{(j)} = \int_{\mathbb{R}} \min(\hat{p}_k^{(j)}(x), \hat{p}_{k'}^{(j)}(x)) dx \in [0, 1], \quad (3.11)$$

où $\hat{p}_k^{(j)}$ est une estimation à noyau de la densité de $X^{(j)}$ dans la modalité k . Les décalages identifiés serviront à définir les blocs de la validation croisée, de sorte que l'évaluation reproduise les conditions de transfert réalistes, ainsi qu'à délimiter le domaine d'applicabilité du modèle.

3.2 Arbre de Régression et Forêt Aléatoire

3.2.1 Bagging

Le *bagging*, ou *bootstrap aggregating* est un ensemble de méthodes d'apprentissage qui combinent différents estimateurs entraînés sur des échantillons *bootstrap*¹. Une *forêt aléatoire* est une méthode de bagging consistant à entraîner un ensemble de B arbres de classification ou de régression (Classification And Regression Trees, CART) et à prédire la moyenne des prédictions des B arbres.

3.2.2 Arbres de classification et de régression (CART)

Un Arbre de Classification ou de Régression (Classification And Regression Trees, CART) [breiman1984classification] est construit par partitionnement binaire récursif de l'espace des variables explicatives (voir figure 3.1). À chaque nœud, l'algorithme sélectionne la variable et le seuil de coupure qui minimisent le plus la variance intra-groupe des sous-ensembles résultants. Ce processus est répété récursivement jusqu'à ce qu'un critère d'arrêt soit atteint. La prédiction d'une nouvelle observation correspond, dans le cas d'une régression, à la moyenne des valeurs observées dans la feuille terminale où elle est routée.




Figure 3.1 – Schéma du partitionnement de l'espace des covariable par CART [fischer2026].

De manière plus formelle, on dispose d'un échantillon $\mathcal{D}_n = \{(X_1, Y_1), \dots, (X_n, Y_n)\}$ de couples indépendants et de même loi que (X, Y) , où $X = (X^{(1)}, \dots, X^{(d)}) \in \mathbb{R}^d$ et $Y \in \mathbb{R}$. L'objectif est d'estimer la fonction de régression $f(x) = \mathbb{E}[Y | X = x]$.

Partitionnement et critère de coupure

Un arbre partitionne récursivement l'espace des variables $\mathbb{R}^d$ en rectangles, chaque rectangle correspondant à un nœud de l'arbre. Soit $\mathcal{D}$ l'échantillon utilisé pour construire l'arbre, $R \subseteq \mathbb{R}^d$ un nœud et $n_R = \sum_i^n \mathbb{1}_{\{X_i \in R\}}$ le nombre d'observations de $\mathcal{D}$ qui tombent dans R .

Une coupure est un couple $(j, t) \in \{1, \dots, d\} \times \mathbb{R}$, avec $j \in d$ la variable et $t \in \mathbb{R}$ le seuil de coupure. Elle partitionne le nœud R en deux nœuds fils $R_1(j, t)$ et $R_2(j, t)$:

$$R_1(j, t) = \{x \in R : x_j < t\} \quad \text{et} \quad R_2(j, t) = \{x \in R : x_j \geq t\},$$

d'effectifs respectifs $n_1(j, t) = n_{R_1(j, t)}$ et $n_2(j, t) = n_{R_2(j, t)}$, avec $n_1(j, t) + n_2(j, t) = n_R$.

1. Tirage aléatoire avec remise

On souhaite trouver une manière de partitionner les variables telle que les deux nouvelles régions $R_1(j, t)$ et $R_2(j, t)$ issues de cette partition soient les plus homogènes possibles. Cela revient à, dans le cas de la régression, minimiser la variance de chaque noeud R (critère d'impureté) :

$$V(R) = \frac{1}{n_R} \sum_{i: X_i \in R} (Y_i - \bar{Y}_R)^2 \quad \text{où} \quad \bar{Y}_R = \frac{1}{n_R} \sum_{i: X_i \in R} Y_i. \quad (3.12)$$

La qualité d'une coupure (j, t) admissible est mesurée par la diminution d'impureté qu'elle produit, ou gain d'information (Information Gain, IG) :

$$\text{IG}_R(j, t) = V(R) - \frac{n_1(j, t)}{n_R} V(R_1(j, t)) - \frac{n_2(j, t)}{n_R} V(R_2(j, t)). \quad (3.13)$$

Les variances des fils sont pondérées par la proportion d'observations qu'ils contiennent, de sorte que $\text{IG}_R(j, t) \geq 0$ (décomposition de la variance totale en variances intra- et inter-groupes). La meilleure coupure parmi un ensemble de variables candidates $\mathcal{M} \subseteq \{1, \dots, d\}$ est

$$(j^*, t^*) \in \operatorname{argmax}_{j \in \mathcal{M}, t \in \mathcal{T}_j(R)} \text{IG}_R(j, t). \quad (3.14)$$

Prédiction d'un arbre

Pour $x \in \mathbb{R}^d$, on note $R(x)$ la feuille de l'arbre $\hat{f}$ contenant x et $n_{R(x)}$ le nombre de points de $\mathcal{D}_m$ qui y tombent. La prédiction de l'arbre est la moyenne des réponses de cette feuille :

$$\hat{f}(x) = \bar{Y}_{R(x)} = \frac{1}{n_{R(x)}} \sum_{(X_i, Y_i) \in \mathcal{D}_m} Y_i \mathbb{1}_{\{X_i \in R(x)\}} \quad (3.15)$$

3.2.3 Forêt Aléatoire

Une forêt aléatoire [breiman2001] est une méthode de bagging consistant à tirer B échantillons bootstrap à partir de $\mathcal{D}_n$, puis construire un arbre CART sur chacun d'eux et enfin agréger les prédictions des B arbres. Les CART construits sont cependant légèrement différents : à chaque noeud, la meilleure coupure n'est pas cherchée parmi les d variables, mais parmi un sous-ensemble de $p \leq d$ variables tirées au hasard.

Construction de la forêt

Pour $b = 1, \dots, B$, on tire avec remise un échantillon bootstrap $\mathcal{D}_m^{(b)}$ de taille m dans $\mathcal{D}_n$, puis on construit un arbre $\hat{f}^{(b)}$ sur $\mathcal{D}_m^{(b)}$ par partitionnement récursif. À chaque noeud R , on tire uniformément et sans remise un ensemble $\mathcal{M} \subseteq \{1, \dots, d\}$ de p variables, et on coupe R selon la coupure (j^*, t^*) définie par (3.14). Le tirage de $\mathcal{M}$ est effectué indépendamment à chaque noeud.

Prédiction de la forêt

Pour chaque arbre $b \in [1, \dots, B]$, la prédiction $\hat{f}^{(b)}(x)$ est donnée par (3.15) (en remplaçant $\mathcal{D}_m$ par $\mathcal{D}_m^{(b)}$). La forêt prédit la moyenne des B arbres :

$$\hat{f}_B(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{(b)}(x). \quad (3.16)$$

Hyperparamètres

La construction de forêts aléatoires dépend donc de quatre hyperparamètres :

- B le nombre d'arbres (`num.trees`),
- m la taille des échantillons bootstrap (`sample.fraction`),
- p le nombre de variables candidates pour chaque split (`mtry`),
- $n_{\min}$ l'effectif minimal des feuilles (`min.node.size`)

3.3 Protocole de validation croisée

3.3.1 Prévention des fuites de données

Les données environnementales et biologiques présentent une structuration dépendante de la latitude : leurs propriétés statistiques varient donc selon la position dans l'espace. Les hypothèses de stationnarité d'ordre 1 (moyenne constante dans l'espace) et d'ordre 2 (structure de covariance invariante par translation, ne dépendant que de la distance entre points) ne sont donc pas respectées.

De plus, lors des campagnes océanographiques, une onde acoustique est émise toutes les 3 à 4 secondes. La conséquence de cette proximité spatio-temporelle est la présence de pseudo-duplicatas dans le jeu de données.

Ces deux éléments, non-stationnarité spatiale et auto-corrélation, doivent être pris en compte lors de la construction du schéma de validation croisée, afin d'éviter toute fuite d'information entre les jeux d'entraînement et de validation (data leakage).

3.3.2 Validation croisée

La validation croisée est une méthode permettant consistant à diviser l'ensemble des données en K sous-ensemble de taille à peu près identiques, appelés *plis* (ou *folds*). Un pli sert d'*ensemble de validation* (ou *ensemble test*) et les $K - 1$ plis restants servent d'*ensemble d'entraînement*. On obtient donc K prédictions pour un même modèle.

Il existe différentes manières de sous-échantillonner les données pour construire les plis. Dans notre étude, nous avons testés différentes méthodes : validation croisée Monte-Carlo (Monte-Carlo Cross Validation, MC-CV) et la validation croisée par blocage spatio-temporel.

Validation croisée Monte-Carlo (MC-CV)

Les analyses d'auto-correlation effectuée en section ??

Validation croisée par blocage spatio-temporel

3.4 Ajustement des hyperparamètres

3.5 Évaluation des performances

3.5.1 Métriques et biais des prédictions

3.6 Validation du modèle

3.6.1 Sur-apprentissage et robustesse

3.6.2 Recherche de raccourcis (shortcut learning)

3.6.3 Domaine d'applicabilité

3.7 Interprétation post-hoc

3.7.1 Importance des variables (covariables corrélées)

3.7.2 Analyse des résidus et suffisance des covariables

3.8 Schéma de validation

3.9 Ajustement des hyperparamètres

3.10 Validation

3.10.1 validation des données

Le biais d'échantillonnage et le covariate shift portent sur les données : on peut les mesurer sans même avoir de modèle, en comparant les données d'entraînement à celles de la population cible ou de la production. C'est de la validation des données.

3.10.2 validation du protocole

La fuite de données porte sur le protocole : elle vient de la façon dont on a construit les variables, séparé les jeux d'entraînement et de test, ou choisi les informations disponibles au moment de prédire. La vérifier, c'est valider la conception de l'expérience.

3.10.3 validation du modèle

Valider un modèle, c'est établir qu'il est adapté à son usage prévu : que ses hypothèses tiennent, qu'il s'appuie sur des relations légitimes, qu'il reste fiable dans les conditions où il sera employé, et dans quel domaine il est applicable. Chercher à savoir si sa performance est fiable et si elle tiendra dans les conditions réelles.

Le shortcut learning porte sur le modèle lui-même : il faut regarder ce qu'il a réellement appris, avec des outils d'interprétabilité ou des tests où l'on neutralise la variable suspecte. C'est de la validation du modèle au sens strict.

Une fuite ou un biais d'échantillonnage dans les données est souvent ce qui rend possible un raccourci dans le modèle, et un décalage de distribution est ce qui fait apparaître ce raccourci en production.

vérifier que le modèle n'overfit pas : robustesse au bruit vérifier que le modèle ne fais pas shortcut learning vérifier que le modèle est capable d'extrapoler

3.11 Evaluation du modèle

vérifier que le modèle prédit de manière fiable et non biaisé

3.12 Interprétation post-hoc

3.12.1 Importance des variables

3.12.2 Source du biais

3.12.3 Suffisances des informations contenues par les covariables

4 Résultats

4.1 Structure et validation des données

4.2 Performances du modèle

4.3 Validité du modèle

4.4 Prédictions

4.5 Interprétation

5 Discussion

5.1 L'échantillonnage permet-il de répondre à la problématique ?

- biais d'échantillonnage et régions/années moins représentées => perf du modèle diminuées dans certaines régions - distribution shift => un modèle n'est pas suffisant pour prédire toute la ROI (sauf peut-être s'il apprend la causalité). - valeurs manquantes MNAR et biais de sélection (couverture nuageuse)

5.2 Les variables mesurées représentent-elles correctement les construits ?

incertitudes liées aux données : - NASC et acoustique active - classes de phyto à partir des pigments

5.3 Prédiction ou explicabilité ?

5.4 Contrainte des modèles prédictifs

- nécessité d'avoir une métrique rigoureuse d'évaluation des performances du modèle (CV blocage)
- nécessité de robustesse face à l'extrapolation - en découle la nécessité de limiter le shortcut learning
- apprendre la causalité permet la robustesse face à l'extrapolation

5.5 Pertinence des forêts aléatoires

- surapprentissage et RF : surapprentissage possible par profondeur des arbres - diminution de la variance utile pour le trade-off biais-variance de la prédiction - extrapolation difficile étant donné que RF est fonction continue par morceaux - importance des variables sur échantillon OOB mais OOB est leaked/fortement corrélé/biais d'échantillonnage

5.6 Mise en relation des résultats associatifs avec la théorie de causalité et hypothèses

- liens entre mésoéchelle et distrib phyto - liens trophiques entre phyto et NTI mais délai - liens avec importance des variables - liens entre connaissances des distrib de euphausiacés et prédictions - liens entre connaissance inversion 18/38 et observations + distributions des poissons 38 et prédictions

5.7 Domaine d'applicabilité des modèles et précautions d'interprétations

5.8 perspectives

Table des figures

2.1	Carte des transects effectués par le Marion Dufresnes II lors des campagnes océanographiques OBSAUSTRAL/THEMISTO 2018, 2021, 2022 et 2023.	6
2.2	Exemple d'échogramme obtenu le 2023-01-28 entre 18h et 00h aux fréquences (a) 38 kHz et (b) 120 kHz	7
2.3	NASC en fonction du temps le 2023-01-28, données d'acoustique active (transect) issues de la campagne océanographique OBSAUSTRAL 2023 [flotteoceanographique_campagnes].	
2.4	Carte de prédiction de la concentration de Chlorophylle-a le 2023-01-26 sur le secteur indien du SO, prédictions issue de l'algorithme PIGMeANN développé par Sari el Dine [sari2026regional]. La présence de nuages gêne grandement la prédiction sur la zone totale.	9
2.5	Profil de Température et de Salinité issue de GLORYS (CMEMS), tronqués en deçà de 20m et au delà de 500m aux coordonnées (50°E, 60°S).	11
2.6	Carte des Domaines Océanographiques Fonctionnels du 2023-01-26 générée par la méthode développée par Fonvieille N. et Nerini D. [fonvieille2024].	12
2.7		12
2.8	Advection Lagrangienne FTLE backward (30j) du 2023-01-26. Les valeurs élevées de FTLE délimitent des crêtes correspondant à des frontières de transport de l'écoulement (de fronts ou de tourbillons) le long desquelles convergent les masses d'eau (structures cohérentes lagrangiennes attractives)	14
3.1	Schéma du partitionnement de l'espace des covariable par CART [fischer2026]. . .	19

Liste des tableaux

2.1	Neuf pigments photosynthétiques dont les concentrations sont estimées par l'algorithme PIGMeANN [sari2026regional].	9
2.2	Pigments photosynthétiques analysés et groupes phytoplanctoniques hypothétiquement associés (PFD et PSC) dans le secteur de Kerguelen en été austral, d'après [Lasbleiz2014], [sari2025influence]	10