

UNIVERSITÉ PARIS CITÉ

Département de mathématiques et d'informatique

**Comment la structure des communautés
phytoplanctoniques influence t-elle la distribution du
zooplancton et du micronecton ?**

Une étude dans le secteur Indien de l'Océan Austral

Rapport de stage

Abstract

Rapport réalisé par

Elise NICOLAS

Encadrants

Marius MOLINET, David NERINI, Christophe GUINET, Cédric COTTE

Professeure référente

FISHER Aurélie

Contents

1	Introduction	2
1.1	Généralités	2
1.2	Secteur Indien de l’Océan Austral	3
1.2.1	Contexte physico-chimique de la région	4
1.2.2	Contexte biologique	4
1.2.3	Et dans un contexte de changement climatique ?	5
1.3	Question scientifique	5
1.4	il manque	5
2	Matériel	6
2.1	Données Pigmentaires (PIGMeANN)	6
2.2	Données hydrologiques (Copernicus)	6
2.3	Données hydrodynamiques : FTLE	6
2.4	Données d’acoustique active (OBSAUSTRAL)	6
3	Méthode	7
3.1	Pré-traitement des données	7
3.1.1	Calcul du NASC	7
3.1.2	Calcul des Functional Oceanographic Domain (FOD)	7
3.1.3	Filtrage des pigments	13
3.1.4	Colocalisation NASC/PIG/FTLE/FOD	13
3.2	Arbres de Régression	13
3.2.1	CART	14
3.2.2	Random Forest	14
3.2.3	Extreme Gradient Boosting	14
3.2.4	Tuning, entraînement, validation et prédiction	14
4	Résultats	15
4.1	distrib interanuelles générales	15
4.2	FOD	15
4.3	Cluster de pigments	15
4.4	Résultats des régressions	15
5	Discussion	16
5.1	Influence des fréquences	16
5.2	Complétion des NAs et influence sur le NASC	16
5.3	FOD : nombre de composante principale, données modèles, non prise en compte des données chimique (fer) et sea ice	16
5.4	définition de communauté phyto à partir des bio-optical water types	16
5.5	test statistiques : effet du nombre de données et dispersion sur la significativité, tendance vs climate change trend	16
5.6	Influence sur la prédiction : gradient latitudinal, overfit, déséquilibre de l’échantillonnage	16
5.7	Choix des variables prédictives, manque de variables	16
5.8	Interprétation de l’importance des variables	16
5.9	Evaluation des performances prédictives du modèle	16
6	Conclusion	17
7	Annexes	18
7.1	Stratification verticale et horizontale des océans	18
7.2	Distribution verticale des valeurs manquantes des ESU	18
7.3	Influence du nombre de composantes principales sur la reconstruction des profils de température et salinité	18

1 Introduction

1.1 Généralités

L'**océan** couvre 70% de la surface terrestre. La répartition des terres émergées n'est pas équivalente selon les deux hémisphères: l'hémisphère Sud est composé à 80.9% de mer, contre 60.7% pour l'hémisphère Nord. Dans l'hémisphère Sud, dans le bassin Antarctique, les océans Atlantique, Pacifique et Indien se connectent. Une seule masse d'eau liquide se déplace alors dans les différents bassins. L'océan est un **milieu continu**.




Figure 1: Illustration de l'Océan Austral et de la connexion entre tous les océans (Fieux 2019)

Un **biotope** correspond à l'espace physique et les conditions abiotiques associées dans lesquelles vit une biocénose. Une **biocénose** est l'ensemble des populations d'organismes qui occupent une zone donnée et interagissent entre elles. L'océan étant un milieu continu, seuls la distance géographique et les paramètres physiques de l'eau (abiotiques) conditionnent la régionalisation en biotopes. La connaissance des paramètres physiques de l'eau est donc particulièrement importante pour l'étude de la distribution des organismes et **niches écologiques**¹ marines.

Les principaux **paramètres abiotiques** structurant les écosystèmes sont : les propriétés hydrologiques et hydrodynamiques de l'eau, la pression et la lumière (Dipper 2022). Les **propriétés hydrologiques** (température, salinité, composition chimique) de l'eau dépendent du climat : la chaleur et le vent induisent une évaporation rendant l'eau de mer plus salée, les précipitations induisent un adoucissement de la salinité. La composition chimique de l'eau de mer est fortement dépendante des apports du littoral (fer, nitrates, etc). **L'hydrodynamisme** inclue les marées et les divers courants induits par des gradients de température, de pressions. Ces derniers dépendent majoritairement du vent et de l'ensoleillement. **L'éclairement** (intensité et spectre) est structuré verticalement selon la profondeur à cause des propriétés d'absorption de l'eau (Annexe 7.1, figure 8). On parle de milieu eutrophe (épipélagique) entre 0 et 200m, de milieu dysphotique (mésopélagique) entre 200 et 1000m, de milieu aphotique (bathypélagique) entre 1000 et 4000m et de milieu abyssal au delà de cette dernière. La pression croît avec la profondeur et une stratification arbitraire est également appliquée selon cette variable (Annexe 7.1, figure 8). La proximité au littoral participant grandement à la modification de ces paramètres abiotiques, on sépare arbitrairement l'océan horizontalement selon sa distance au plateau continental. On parle de **zone pélagique** au delà du plateau continental. Le contexte actuel de changement global induit des modifications importantes de l'expression de ces paramètres et induit en conséquence des changements de structuration des écosystèmes océaniques (Doney et al. 2012, Sallée 2018).

¹**Niche écologique** : ensemble des conditions environnementales permettant à une espèce de survivre et de se reproduire (Hutchinson 1957).

L'**écologie** est une discipline qui s'intéresse aux interactions entre les différentes espèces d'un même biotope. Parmi elles, les **relations trophiques** (alimentaires) jouent un rôle fondamentale dans la structuration des écosystèmes (figure 2).




Figure 2: Schéma du réseau trophique océanique (Dipper 2022).

Les **producteurs primaires** supportent tout le réseau trophique. Leur capacité à transformer la matière inorganique en matière organique (organismes autotrophes) les positionnent à la base du réseau. En effet, de nombreux organismes (hétérotrophes) n'ont pas cette capacité et dépendent uniquement des apports organiques de leur alimentation pour survivre. Le producteur primaire du milieu pélagique est le **phytoplancton**. Ce terme désigne tous les organismes végétaux ("*phyto*") n'ayant pas la capacité de se déplacer contre le courant ("*plancton*"). Ce sont des organismes **photo-autotrophes**, c'est-à-dire, qu'ils peuvent soutenir leur métabolisme uniquement grâce à l'énergie lumineuse. Le processus bio-chimique permettant la transformation de l'énergie lumineuse en énergie chimique utilisable par le métabolisme est la **photosynthèse**. Ce processus nécessite la présence de **pigments photosynthétiques** chez les organismes l'effectuant. Les **consommateurs primaires** sont les organismes s'alimentant des producteurs primaires. Dans le contexte du milieu pélagique, c'est le **zooplancton**² et le **micronecton**³. Les **niveaux trophiques intermédiaires** sont tous les étages de la chaîne alimentaire, correspondent à tous les organismes situés entre les producteurs primaires et les prédateurs supérieurs (dernier niveau du réseau trophique).

1.2 Secteur Indien de l'Océan Austral

L'Océan Austral (ou Antarctique) forme un anneau autour de l'Antarctide. Il représente 22% de la surface totale des océans. Contrairement aux autres océans, il n'est pas délimité par des frontières continentales. En regardant une carte (voir figure 1), on pourrait penser qu'il est simplement la prolongation du bassin Atlantique, Pacifique et Indien. En réalité, il est délimité par une frontière océanographique : le Front Subtropical (approximativement à 40°S), caractérisé par de très forts gradients de températures (figure 3). L'Océan Austral se distingue également des autres océans par l'uniformité de son climat, de son hydrodynamisme et de ses propriétés hydrologiques.

²"Zoo" : animal, "Plancton" : n'ayant pas la possibilité de se déplacer à contre-courant.

³Petits poissons pélagiques.




Figure 3: Positions moyennes du Front subtropical (STF), du Front subantarctique (SAF), du Front sud du Courant circumpolaire antarctique (SACCF), de la Divergence antarctique (AD), ainsi que des trois gyres cycloniques du bassin de Weddell-Endeavour, du bassin Antarctique-Australien et de la mer de Ross (D'après Fieux 2019).

parler du sous échantillonnage de la région, de sa vasteté et de son importance dans le carbon uptake etc

1.2.1 Contexte physico-chimique de la région

Le secteur indien de l'Océan Austral est situé entre 20° et 80°E de longitude et s'étend de 30° à 70°S de latitude (figure 3, 4). Dans notre étude, la région d'intérêt (ROI) correspond au secteur Indien restreint en longitude (45-90°E, 30-60°S). Cette zone est caractérisée par plusieurs éléments : un fort gradient latitudinal de température, des changements bathymétriques importants (plateau de Crozet) et un fort hydrodynamisme (Courant des Agulhas, front subtropical, front subantarctique, front polaire) (voir figure 4).

parler du faible éclaircissement, des concentrations en fer nitrates etc limitante, de la couverture de glace et de l'apport en fer de kerguelen




Figure 4: Carte du secteur Indien de l'Océan Austral et des courants (Shetye, Mohan, and Nair 2013)

1.2.2 Contexte biologique

D'un point de vue écologique, le réseau trophique de la région contient peu de niveaux. Le producteur primaire du milieu pélagique est le phytoplancton. Les communautés phytoplanctoniques ⁴ sont structurées selon un axe latitudinal. **recherches sur les structures phytoplanctoniques de base** Les consommateurs primaires sont le zooplancton et le micronecton. Plus particulièrement, la région est marquée par une forte abondance de Krill et d'euphosiés. **parler des communautés phyto observées (pcq plus tard on présentera les chgms) la forte productivité primaire de la région et de la forte saisonnalité**

Les prédateurs supérieurs sont les éléphants de mer, manchots,...

1.2.3 Et dans un contexte de changement climatique ?

Dans un contexte de changement global, les caractéristiques physico-chimiques de l'eau et de l'atmosphère changent également. Des études récentes ont annoncé par exemple des changements de régime de vent, une diminution de la profondeur de la couche de mélange ⁵, une altération des courants de circulation, une migration au sud du front polaire, un réchauffement de la température de surface, un changement du flux du fer et des changements dans la proportion de couverture de la glace induisant une diminution de la salinité de l'eau (adoucissement). Sallée 2018,

Ces changements affectent les organismes habitant ces milieux, comme le phytoplancton. Des études récentes font l'hypothèse d'une augmentation de la production primaire totale et d'une restructuration des communautés phytoplanctoniques (Adroli et al. 2026) : la contribution relative des diatomées dans la production primaire diminuerait. Au contraire, la contribution relative des haptophytes et des cryptophytes (nano/picophytoplankton ?) Hayward et al. 2024

+ des changements de temporalité des blooms et de leur durée et amplitude (être + précise dans quel sens) Thomalla et al. 2023

⁶

développer les observations de ces changements et les hypothèses + long terme

développer les hypothèses sur les effets sur les NTI (trophic cascade) changements de temporalité/durée/amplitude des blooms = dictate the amount of biomass being generated within a season that can be exported to the ocean's interior or transferred to higher trophic levels Thomalla et al. 2023

1.3 Question scientifique

Ce projet de recherche s'intéresse à l'influence du type phytoplanctonique sur les niveaux trophiques intermédiaires du secteur Indien de l'Océan Austral

1.4 il manque

RESTREINDRE LES HYPOTHESES A L'ETE et a la ROI si possible la présence de l'importance de l'atmosphère dans les params physicochimique (vent mixing water, increase in CO₂, more clouds = less light, etc) l'importance du so dans le contexte de changement global (carbon uptake, ..) réseau trophique + détaillé du so Le changement climatique dans l'océan austral phytoplancton du so : énorme vers kerguelen, limité par lumière et iron Les changements de commu phyto observés Les hypothèses de changements /les changements observés dans les niveaux trophiques supérieurs (étude avec le carbone, article de ziad) : ramifications trophodynamique (southern ocean in a changing climate, climate drivers of so phytoplankton community) hypothèses claires des changements physiques de la zone (changement de flux d'iron (avec sea ice zone différentes), chgmt de régime de vent, stratification, chgmt de mld (decreased), stratification alteration des pattern de circulation, southward migration of ocean fronts, increase in sst, changes in sea ice cover) hypothèses claires des changements de commu phyto induits (augmentation chl a totale diminution contribution des diatoms, augmentation de contribution des petits phyto) hypothèses claires des changements de nti induits (ramification)

⁴Composition taxonomique en phytoplancton du milieu

⁵text

⁶"In marine climate systems, a regime shift refers to a persistent reorganisation of physical and ecological system structure, variability and feedback processes that results in a transition toward a new dominant state rather than a short term interannual fluctuation Abram et al. 2025

2 Matériel

2.1 Données Pigmentaires (PIGMeANN)

article ziad Influence of the phytoplankton community structure on the southern elephant seals nature

2.2 Données hydrologiques (Copernicus)

2.3 Données hydrodynamiques : FTLE

2.4 Données d'acoustique active (OBSAUSTRAL)

3 Méthode

3.1 Pré-traitement des données

3.1.1 Calcul du NASC

3.1.2 Calcul des Functional Oceanographic Domain (FOD)

3.1.2.a Présentation des Domaines Océanographiques Fonctionnels

Les Domaines Océanographiques Fonctionnels (ou Functional Oceanographic Domain) sont des masses d'eau ayant des caractéristiques thermohalines similaires. La méthode d'identification des FOD a été développée par Fonvieille N. et Nerini D. (Fonvieille 2024). Les données thermohalines (des modèles de Copernicus dans notre cas) sont, dans un premier temps (1), estimées dans un espace fonctionnel par une estimation semi-paramétrique sur une base de B-spline. Dans un second temps (2), la dimension de la matrice des coefficients de pondération des B-splines est réduite par une Analyse par Composante Principale (ACP ou PCA en anglais). Dans un dernier temps (3), un clustering (GMM) est appliqué à cette nouvelle matrice de coefficients de pondération des B-splines. Ces trois étapes seront développées dans les paragraphes suivants.

3.1.2.b Estimation fonctionnelle sur des bases de B-splines Estimation semi-paramétrique des profils de température et salinité

Motivation Les profils de température/salinité $T, S \in \mathbb{R}^{\text{time} \times \text{lon} \times \text{lat} \times \text{depth}}$, $Swl_i \in \mathbb{R}^{n_{depths}}$ pour pourquoi on fait une estimation fonctionnelle des profils de T/S ?

B-splines d'ordre k (Boor 2001) Les B-splines sont des fonctions pouvant servir de base pour l'estimation fonctionnelle (B pour "Basis"). Ce sont des polynômes par morceaux pourvus de certaines conditions de régularités aux noeuds (ou points de rupture). La Figure 5 montre un exemple simple de B-splines (Eilers and Marx 1996) : en (a) est montrée une B-spline de degré 1 et en (b) une B-spline de degré 2.




Figure 5: Illustration d'une B-spline isolée de B-splines chevauchantes, de degré 1 (a) et de degré 2 (b) (Eilers and Marx 1996)

Soit $\tau_i, \dots, \tau_{i+m+1}$ noeuds (équi-espacés ou non) avec m le degré de la B-spline (on a donc un ordre valant $m+1$)

Soit $\phi_{i,m}(x)$ la B-spline de degré m dont le support est $\text{supp}(\phi_{i,m}(x)) = [\tau_i, \tau_{i+m+1}]$. On peut définir la B-spline $\phi_{i,m}(x)$ par la formule de récurrence de Cox-de-Boor (Boor 2001) :

1. Initialisation d'une fonction porte par noeud (degré 0, ordre 1)

$$\phi_{i,0}(x) = \begin{cases} 1 & \text{si } \tau_i \leq x < \tau_{i+1} \\ 0 & \text{sinon} \end{cases} \quad (1)$$

2. Récurrence : combinaison convexe de B-splines de degré inférieur à deux noeuds consécutifs

$$\phi_{i,m}(x) = \omega_{i,m}(x) \phi_{i,m-1}(x) + (1 - \omega_{i+1,m}(x)) \phi_{i+1,m-1}(x) \quad (2)$$

avec, pour tout indice j ,

$$\omega_{j,m}(x) := \frac{x - \tau_j}{\tau_{j+m} - \tau_j} \quad (3)$$

(le poids de chaque terme est normalisé par le support de la B-spline de degré $m - 1$ qu'il pondère : $\text{supp}(\phi_{i,m-1}) = [\tau_i, \tau_{i+m}]$ et $\text{supp}(\phi_{i+1,m-1}) = [\tau_{i+1}, \tau_{i+1+m}]$).

Propriétés des B-Splines de degré m : Support, positivité et régularité La B-spline $\phi_{i,m}(x)$ est un polynôme par morceau de degré m (et d'ordre $m + 1$) avec des points de rupture (noeuds) $\tau_i, \dots, \tau_{i+m+1}$ et les propriétés suivantes :

- Continuité : $\phi_{i,m}(x) \in C^{m-1}$ aux noeuds (les dérivées jusqu'à l'ordre $m - 1$ sont continues sur les noeuds). Pour une B-spline cubique ($m = 3$), $\phi_{i,3} \in \mathcal{C}^2$,
- Support compact : $\text{supp}(\phi_{i,m}) = [\tau_i, \tau_{i+m+1}]$, donc $\langle \phi_{i,m}, \phi_{j,m} \rangle = 0$ si $|i - j| \geq m + 1$.
- Positivité : $\phi_{i,m}(x) > 0$ sur (τ_i, τ_{i+m+1}) et $\phi_{i,m}(x) = 0$ sinon.

Espace des splines $\mathbb{S}_{m,\tau}$ Une fonction spline $f : [a, b] \rightarrow \mathbb{R}$, $f \in \mathbb{S}_{m,\tau}$ de degré m avec suite de noeuds τ est toute combinaison linéaire de B-splines de degré m pour la suite de noeuds τ . La suite de noeuds τ est la suivante :

$$\underbrace{a = \tau_1 = \tau_2 = \dots = \tau_{m+1}}_{m+1 \text{ noeuds répétés en } a} < \underbrace{\tau_{m+2} < \dots < \tau_{m+L+1}}_{L \text{ noeuds intérieurs}} < \underbrace{\tau_{m+L+2} = \dots = \tau_{2m+L+2}}_{m+1 \text{ noeuds répétés en } b} = b \quad (4)$$

La collection de toutes ces fonctions est notée $\mathbb{S}_{m,\tau}$. Les B-splines $\{\phi_{i,m}\}_{i=1}^{L+m+1}$ forment alors une base de cet espace de dimension $\dim(\mathbb{S}_{m,\tau}) = L + m + 1$, avec L le nombre de noeuds intérieurs.

$$\mathbb{S}_{m,\tau} := \left\{ \sum_{i=1}^{L+m+1} \alpha_i \phi_{i,m} : \alpha_i \in \mathbb{R} \right\} \quad (5)$$

Estimation fonctionnelle par minimisation des moindres carrés pénalisée (O-Splines) (Wand and Ormerod 2008, Eilers and Marx 1996) Appliquons ce cadre à l'estimation fonctionnelle des profils de température et de salinité. Soit l un indice spatio-temporel (combinaison d'un instant, d'une longitude et d'une latitude) et $v \in \{T, S\}$ la variable considérée (température ou salinité). Le profil brut $v_l \in \mathbb{R}^{n_{depths}}$ correspond aux valeurs de v issues du modèle Copernicus aux profondeurs discrètes $z_1, \dots, z_{n_{depths}}$. On modélise ce profil comme une fonction sous-jacente f_l de la profondeur z , observée avec bruit :

$$v_l(z_k) = f_l(z_k) + \varepsilon_k, \quad \forall k \in \{1, \dots, n_{depths}\} \quad (6)$$

où ε_k représente le bruit de mesure et d'échantillonnage du modèle à la profondeur z_k , et n_{depths} le nombre de profondeurs échantillonnées pour le profil l .

On souhaite effectuer une estimation de f_l sur $[a, b]$, l'intervalle de profondeurs couvert par le profil (dans notre cas, $a = 20\text{m}$ et $b = 500\text{m}$). Soit $\hat{f}_l \in \mathbb{S}_{m,\tau}$, $\hat{f}_l : [a, b] \rightarrow \mathbb{R}$, une spline (combinaison linéaire de B-splines de degré m) estimée de f_l , permettant de représenter le profil de température ou de salinité de façon continue et régulière selon la profondeur :

$$\hat{v}_l(z_k) = \sum_{i=1}^{m+L+1} \alpha_{l,i} \phi_{i,m}(z_k), \quad (7)$$

où $\phi_1, \dots, \phi_{m+L+1}$ sont les B-splines de degré m définies sur l'intervalle de profondeurs $[a, b]$, L le nombre de noeuds intérieurs, avec $\text{supp}(\phi_{i,m}) = [\tau_i, \tau_{i+m+1}]$, et $\alpha_{l,i}$ le coefficient de la i -ème B-spline propre au profil l . Ce sont précisément ces coefficients $\boldsymbol{\alpha}_l = (\alpha_{l,1}, \dots, \alpha_{l,K})^\top$, une fois empilés pour l'ensemble des profils l , qui formeront la matrice des coefficients de pondération des B-splines réduite ensuite par ACP (cf. étape suivante de la méthode FOD).

La fonction objective des moindres carrés (MSE pour "Mean Square Error") à minimiser, pour un profil l donné, est :

$$S_l = \sum_{k=1}^{n_{depths}} \left(v_l(z_k) - \hat{f}_l(z_k) \right)^2 \quad (8)$$

$$= \sum_{k=1}^{n_{depths}} \left(v_l(z_k) - \sum_{i=1}^{L+m+1} \alpha_{l,i} \phi_{i,m}(z_k) \right)^2 \quad (9)$$

Choisir le nombre de nœuds $K = m + L$ des B-splines peut s'avérer difficile et peut induire de l'overfitting : un grand nombre de nœuds permet de capturer toutes les variations fines du profil de température/salinité observé mais donne de mauvaises performances de généralisation sur d'autres profils. Plusieurs techniques de pénalisation (Paul H. C. Eilers, Brian D. Marx, O'Sullivan) ont été mises en place pour choisir les hyper-paramètres des B-splines de manière optimale. On présentera ici la régression pénalisée de O'Sullivan (1986). Se référer aux travaux de (Wand and Ormerod 2008, Eilers and Marx 1996) pour d'avantages de détails sur les autres méthodes.

La régression de O'Sullivan pénalise la rugosité de la fonction estimée, c'est-à-dire à quel point le profil reconstruit oscille ou est irrégulier selon la profondeur — un critère particulièrement pertinent ici, les profils physiques de température et de salinité étant naturellement lisses en dehors de phénomènes spécifiques (thermocline, mélange de couches).

Le terme de pénalisation de O'Sullivan (matrice de rugosité) ajouté à la MSE est défini par :

$$\Omega_{i,j} = \int_a^b \phi''_{i,m}(z) \phi''_{j,m}(z) dz, \quad 1 \leq i, j \leq K \quad (10)$$

La MSE pénalisée (O-Sullivan, Ridge fonctionnel) pour le profil l est alors :

$$S_{l,\lambda} = \underbrace{\sum_{k=1}^{n_{depths}} \left(v_l(z_k) - \sum_{i=1}^K \alpha_{l,i} \phi_{i,m}(z_k) \right)^2}_{\text{MSE}} + \lambda \underbrace{\alpha_l^\top \Omega \alpha_l}_{\text{rugosité}} \quad (11)$$

où $\lambda \geq 0$ est le paramètre de lissage contrôlant le compromis entre fidélité au profil observé (MSE) et régularité de $\hat{f}_l$ selon la profondeur.

Forme matricielle. En posant $\mathbf{v}_l = (v_l(z_1), \dots, v_l(z_{n_{depths}}))^\top$, $\alpha_l = (\alpha_{l,1}, \dots, \alpha_{l,K})^\top$ et la matrice de design $\phi \in \mathbb{R}^{n_{depths} \times K}$, commune à tous les profils partageant la même grille de profondeurs, telle que $\phi_{k,i} = \phi_{i,m}(z_k)$, on réécrit :

$$S_{l,\lambda} = (\mathbf{v}_l - \phi \alpha_l)^\top (\mathbf{v}_l - \phi \alpha_l) + \lambda \alpha_l^\top \Omega \alpha_l \quad (12)$$

Solution analytique. Puisque $S_{l,\lambda}$ est convexe en α_l , on peut trouver les coefficients minimaux en annulant la dérivée de $S_{l,\lambda}$ par rapport à α_l :

$$\frac{\partial S_{l,\lambda}}{\partial \alpha_l} = -2\phi^\top (\mathbf{v}_l - \phi \alpha_l) + 2\lambda \Omega \alpha_l = \mathbf{0} \quad (13)$$

On obtient l'estimateur des coefficients de pondération des B-splines pour le profil l :

$$\hat{\alpha}_l = (\phi^\top \phi + \lambda \Omega)^{-1} \phi^\top \mathbf{v}_l \quad (14)$$

et le profil ajusté (reconstruction lissée de température ou de salinité selon la profondeur) :

$$\hat{\mathbf{v}}_l = \phi \hat{\alpha}_l = \underbrace{\phi (\phi^\top \phi + \lambda \Omega)^{-1} \phi^\top}_{\mathbf{H}(\lambda)} \mathbf{v}_l \quad (15)$$

où $\mathbf{H}(\lambda)$ est la *matrice d'influence*, identique pour tous les profils l dès lors qu'ils partagent la même grille de profondeurs $z_1, \dots, z_{n_{depths}}$ et le même paramètre λ — ce qui permet de calculer $\hat{\alpha}_l$ efficacement pour l'ensemble des profils du jeu de données.

Choix du paramètre de lissage λ par validation croisée leave-one-out (CV-LOO). Le paramètre λ contrôle la régularité du profil estimé selon la profondeur : un λ trop petit conduit à de l'overfitting (le profil lissé colle au bruit de mesure), un λ trop grand à de l'underfitting (des structures physiques réelles, comme une thermocline marquée, sont lissées à l'excès). La validation croisée leave-one-out consiste à estimer l'erreur de prédiction en retirant tour à tour chaque profondeur d'observation k :

$$\text{CV}(\lambda) = \frac{1}{n_{depths}} \sum_{k=1}^{n_{depths}} \left(v_l(z_k) - \hat{f}_l^{(-k)}(z_k) \right)^2 \quad (16)$$

où $\hat{f}_l^{(-k)}$ est l'estimateur calculé sans l'observation à la profondeur z_k . Grâce à la hat matrix $\mathbf{H}(\lambda)$, on dispose d'une formule analytique évitant de refaire n_{depths} régressions :

$$CV(\lambda) = \frac{1}{n_{depths}} \sum_{k=1}^{n_{depths}} \left(\frac{v_l(z_k) - \hat{v}_l(z_k)}{1 - H_{kk}(\lambda)} \right)^2 \quad (17)$$

où $H_{kk}(\lambda)$ est le k -ème élément diagonal de $\mathbf{H}(\lambda)$. Le paramètre optimal est alors :

$$\hat{\lambda} = \arg \min_{\lambda > 0} CV(\lambda) \quad (18)$$

Dans notre cas, le nombre de profils (et donc d'observations) étant très important, on se limite à une validation croisée sur un sous-ensemble de profils. On trouve $\lambda = 0.25$ pour $K = 25$ splines.




Figure 6: Estimation fonctionnelle des profils de Température/Salinité ($\lambda = 0.25$, $K = 25$) issu de Copernicus (E.U. Copernicus Marine Service Information (CMEMS). Global Ocean Physics Reanalysis. Marine Data Store (MDS). DOI: 10.48670/moi-00021) le 2023-01-26 aux coordonnées 450E,-60°N.

3.1.2.c Réduction de dimension par Functional Principal Component Analysis

Suite à l'estimation fonctionnelle réalisée à l'étape précédente, chaque profil l est désormais représenté par un couple de fonctions de la profondeur, la température et la salinité, estimées sur la même base de B-splines $(\Phi_k)_{1 \leq k \leq K}$ définie sur $[d_{min}, d_{max}]$:

$$T_l(z) = \sum_{k=1}^K \alpha_{l,k}^T \Phi_k(z), \quad S_l(z) = \sum_{k=1}^K \alpha_{l,k}^S \Phi_k(z), \quad z \in [d_{min}, d_{max}]$$

On considère alors chaque profil comme une observation **bivariée** $X_l = (T_l, S_l) \in (L^2([d_{min}, d_{max}]))^2$, muni du produit scalaire

$$\langle (f_1, g_1), (f_2, g_2) \rangle = \langle f_1, f_2 \rangle_{L^2} + \langle g_1, g_2 \rangle_{L^2}$$

L'objectif de cette étape est de réduire conjointement la dimension des profils de température et de salinité, afin de capturer les modes de variabilité communs aux deux variables.

Motivation Réduire la dimension des données permet d'effectuer des analyses avec une plus grande facilité en diminuant par exemple les temps de calculs.

Une approche pour réduire la dimension des données est l'analyse par composante principale (ACP ou PCA pour Principal Component Analysis). Puisque les données sont fonctionnelles, on parle alors d'Analyse par Composante Principale fonctionnelle (ACPf ou FPCA). La logique est identique à celle d'une PCA classique mais les outils sont adaptés pour manipuler les fonctions. Ici, la FPCA est réalisée conjointement sur les deux variables, on parle de FPCA **bivariée**.

Étape 0 : Construction du vecteur de coefficients bivarié Pour chaque profil l , on concatène les coefficients de B-spline de température et de salinité en un unique vecteur $\alpha_l \in \mathbb{R}^{2K}$:

$$\alpha_l = \begin{pmatrix} \alpha_l^T \\ \alpha_l^S \end{pmatrix}, \quad \alpha_l^T = (\alpha_{l,1}^T, \dots, \alpha_{l,K}^T)^\top, \quad \alpha_l^S = (\alpha_{l,1}^S, \dots, \alpha_{l,K}^S)^\top$$

En empilant les N profils, on obtient la matrice $\alpha \in \mathbb{R}^{N \times 2K}$.

Étape 1 : Centrage des données Soit $\bar{\alpha} \in \mathbb{R}^{2K}$ la moyenne empirique, sur l'ensemble des N profils, des coefficients de chaque B-spline pour la partie température et pour la partie salinité :

$$\bar{\alpha} = \frac{1}{N} \sum_{l=1}^N \alpha_l$$

On obtient ainsi les coefficients bivariés centrés $\tilde{\alpha} \in \mathbb{R}^{N \times 2K}$, où pour un profil l donné :

$$\tilde{\alpha}_l = \alpha_l - \bar{\alpha}$$

Étape 2 : Calcul de la covariance empirique On définit la matrice bivariée de fonctions de base $\Phi(z) \in \mathbb{R}^{2K}$ comme la concaténation de la base Φ utilisée pour chacune des deux composantes :

$$\Phi(z) = \begin{pmatrix} \Phi(z) \\ \Phi(z) \end{pmatrix}, \quad \Phi(z) = (\Phi_1(z), \dots, \Phi_K(z))^\top$$

de sorte que le profil bivarié centré s'écrive $\tilde{X}_l(z) = \tilde{\alpha}_l^\top \Phi(z) \in \mathbb{R}$ (une combinaison scalaire mêlant la partie température et la partie salinité). La fonction de covariance empirique associée est :

$$\hat{V}(s, t) = \frac{1}{N} \sum_{l=1}^N \tilde{X}_l(s) \tilde{X}_l(t) = \frac{1}{N} (\tilde{\alpha} \Phi(s))^\top (\tilde{\alpha} \Phi(t)) \in \mathbb{R} = \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^T \tilde{\alpha} \Phi(t)$$

où $\tilde{\alpha}^\top \tilde{\alpha} \in \mathbb{R}^{2K \times 2K}$ est la matrice de covariance empirique des coefficients bivariés.

Étape 3 : Décomposition en valeurs propres et vecteurs propres de la matrice de covariance On effectue la décomposition spectrale de l'opérateur de covariance $\hat{V}$:

$$\int \hat{V}(s, t) \xi(t) dt = \rho \xi(s)$$

avec la contrainte d'orthonormalité des fonctions propres bivariées : $\|\xi\|_{L^2} = 1$ et $\langle \xi_i, \xi_j \rangle = 0$ si $i \neq j$.

On fait l'hypothèse que la fonction propre bivariée $\xi(t)$ se décompose dans la même base bivariée que nos profils :

$$\xi(t) = \Phi^\top(t) b, \quad b \in \mathbb{R}^{2K}$$

On a alors :

$$\begin{aligned} \int \hat{V}(s, t) \xi(t) dt &= \int \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} \Phi(t) \Phi^\top(t) b dt \\ &= \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} \underbrace{\int \Phi(t) \Phi^\top(t) dt}_W b \\ &= \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} W b \end{aligned}$$

où $W = \int \Phi(t) \Phi^\top(t) dt \in \mathbb{R}^{2K \times 2K}$ est la matrice de Gram de la base bivariée. Comme $\Phi(t)$ répète deux fois la même base $\Phi(t)$, W prend la forme bloc-diagonale

$$W = \begin{pmatrix} W_0 & 0 \\ 0 & W_0 \end{pmatrix}, \quad W_0 = \int \Phi(t) \Phi^\top(t) dt \in \mathbb{R}^{K \times K}$$

les blocs hors-diagonale étant nuls car la partie température et la partie salinité de ξ n'interagissent qu'au travers de la covariance des coefficients $\tilde{\alpha}^\top \tilde{\alpha}$, pas au travers de la base elle-même.

On peut donc réécrire la décomposition spectrale comme suit :

$$\begin{aligned} \int \hat{V}(s, t) \xi(t) dt &= \rho \xi(s) \\ \iff \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho \Phi^\top(s) b \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho b \end{aligned}$$

La matrice $\tilde{\alpha}^\top \tilde{\alpha}$ est symétrique (c'est un produit de la forme $A^\top A$), mais le produit $\tilde{\alpha}^\top \tilde{\alpha} W$ ne l'est pas en général : le problème aux valeurs propres n'est donc pas directement résoluble par une décomposition spectrale standard. Pour contourner ce problème, on utilise le changement de variable $b = W^{-\frac{1}{2}} u$:

$$\begin{aligned} \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho b \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W W^{-\frac{1}{2}} u &= \rho W^{-\frac{1}{2}} u \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W^{\frac{1}{2}} u &= \rho W^{-\frac{1}{2}} u \\ \iff \frac{1}{N} \underbrace{W^{\frac{1}{2}} \tilde{\alpha}^\top \tilde{\alpha} W^{\frac{1}{2}}}_{\text{symétrique}} u &= \rho u \end{aligned}$$

La matrice $W^{1/2} \tilde{\alpha}^\top \tilde{\alpha} W^{1/2}$ est bien symétrique (elle est de la forme $M^\top M$ avec $M = \tilde{\alpha} W^{1/2}$), ce qui garantit des valeurs propres réelles ρ et des vecteurs propres u orthogonaux. Une fois u obtenu, on retrouve $b = W^{-1/2} u$, puis la fonction propre bivariée $\xi(t) = \Phi^\top(t) b$, dont les deux moitiés de b (les K premiers et les K derniers coefficients) donnent respectivement la composante "température" ξ^T et la composante "salinité" ξ^S de la fonction propre.

Étape 4 : Calcul des scores (projections), reconstruction dans l'espace propre et variance expliquée Une fois les fonctions propres bivariées $\xi_j = (\xi_j^T, \xi_j^S)$ et valeurs propres ρ_j calculées, on peut calculer les projections $c_{l,j}$ des profils bivariés centrés $\tilde{X}_l = (\tilde{T}_l, \tilde{S}_l)$ sur l'espace propre. On note $c_{l,j}$ le score du profil l sur la j -ème composante principale (commun à la température et à la salinité, puisque la composante principale est bivariée) :

$$\begin{aligned} c_{l,j} &= \langle \tilde{X}_l, \xi_j \rangle \\ &= \int \tilde{\alpha}_l^\top \Phi(t) \Phi^\top(t) b_j dt \\ &= \tilde{\alpha}_l^\top W b_j \in \mathbb{R} \end{aligned}$$

On choisit ensuite $J \ll 2K$ composantes à partir de la variance expliquée cumulée. La variance expliquée cumulée des J premières composantes principales est calculée comme suit :

$$VE = \frac{\sum_{j=1}^J \rho_j}{\sum_{k=1}^{2K} \rho_k}$$

avec ρ_k la valeur propre associée à la k -ième composante principale, les composantes étant triées par ordre **décroissant** de valeur propre ($\rho_1 \geq \rho_2 \geq \dots$), de sorte que les J premières composantes soient celles qui expliquent le plus de variance conjointe des profils de température et de salinité. On peut ainsi sélectionner par exemple les J premières composantes principales qui expliquent 90% de la variance.

Finalement, on peut reconstruire conjointement les profils de température et de salinité du profil l comme la combinaison linéaire des J premières fonctions propres bivariées et des scores

associés (les mêmes scores $c_{l,j}$ pilotant simultanément la reconstruction des deux variables) :

$$T_l(t) = \bar{T}(t) + \sum_{j=1}^J c_{l,j} \xi_j^T(t), \quad S_l(t) = \bar{S}(t) + \sum_{j=1}^J c_{l,j} \xi_j^S(t)$$

où $\bar{T}$ et $\bar{S}$ sont les profils moyens de température et de salinité, obtenus à partir des composantes correspondantes de $\bar{\alpha}$.




Figure 7: Réduction de la matrice de coefficients de pondération des B-splines par PCA et reconstruction des profils de Température/Salinité issu de Copernicus (E.U. Copernicus Marine Service Information (CMEMS). Global Ocean Physics Reanalysis. Marine Data Store (MDS). DOI: 10.48670/moi-00021) le 2023-01-26 aux coordonnées 450E,-60°N. k=6 composantes principales sont conservées (>99% de variance expliquée (voir Table 1, Annexe 7.3))

3.1.3 Filtrage des pigments

3.1.4 Colocalisation NASC/PIG/FTLE/FOD

3.2 Arbres de Régression

”Depending on the problem, the basic purpose of a classification/regression study can be either to produce an accurate classifier or to uncover the predictive structure of the problem.” (classif. and regression trees p.6) Notre objectif ici est chercher à connaître la prédictibilité du NASC en fonction de la structure des communautés phytoplanctoniques, en lien avec l’activité de mésoéchelle. The

goal is to understand the structural relationship between the response and the measured variables.
(p.221)

3.2.1 CART

3.2.1.a Description du modèle

3.2.1.b Importance des variables

3.2.1.c Compromis biais-variance

3.2.2 Random Forest

3.2.2.a Description du modèle

3.2.2.b Importance des variables

3.2.2.c Compromis biais-variance

3.2.3 Extreme Gradient Boosting

3.2.3.a Description du modèle

3.2.3.b Importance des variables

3.2.3.c Compromis biais-variance

3.2.4 Tuning, entraînement, validation et prédiction

4 Résultats

4.1 distrib interanuelles générales

description des distribs de ftle nasc et pigs au global

4.2 FOD

Description des caractéristiques des masses d'eau (profil T/S moyen) et mise en relation avec leur propriétés physico-chimique potentielles, la provenance de l'eau etc mise en lien des FOD avec la structuration couremment utilisée du SO (Tréguer et Jacques 1992 et Sullivan et al 1998 : SAZ, SSIZ, MIZ, CZ (climate drivers of SO, Krumhardt2022))

Description des conentrations de pigments par fod, est ce qu'il y a des tendances ? déplacement des communauté phyto ? NASC par fod ftle par fod

4.3 Cluster de pigments

Description des classes de pigments identification des communautés phyto selon la ref de Ziad (Influence of the phyto community nature 2025) Description des tendances interanuelle en terme de concentration Description de la régionalisation des cluster de pigs et des fod (intersection entre les 2 ?) déplacement des communauté phyto ? (distrib des fod par an par cluster) Description du NASC par cluster de pigment

4.4 Résultats des régressions

5 Discussion

5.1 Influence des fréquences

Les NTI sont des poissons pourvu ou non de vessies natatoire ⁷. (mettre dans la partie)

5.2 Complétion des NAs et influence sur le NASC

5.3 FOD : nombre de composante principale, données modèles, non prise en compte des données chimique (fer) et sea ice

5.4 définition de communauté phyto à partir des bio-optical water types

however an increase in chl-a is not necessarily associated with an increase in biomass, particularly in the iron light co-limited SO where phytoplankton can adjust their cellular chl-a to carbon ratios in response to environmental stresses Thomalla et al. 2023 (pas la ref n°1)

5.5 test statistiques : effet du nombre de données et dispersion sur la significativité, tendance vs climate change trend

30-40 years of PP data are necessary to distinguish a climate trend change (pas la ref n°1) Thomalla et al. 2023

5.6 Influence sur la prédiction : gradient latitudinal, overfit, déséquilibre de l'échantillonnage

gradient latitudinal = hypothèse de stationnarité de 1er et second ordre pas respecté, plots pour analyser cet effet overfit du RS et capacité de transfer learning (spatial nested cv) : plots effet du déséquilibre de l'échantillonnage sur les cartes de prédictions

5.7 Choix des variables prédictives, manque de variables

variance, distance geo par fold et capacité prédictive -> hypothèse de manque de variable prédictive

5.8 Interprétation de l'importance des variables

comment XGB et RF et CART n'ont pas les mêmes algos et comment ça veut en fait dire des choses différentes, méfiance sur l'interprétation, bien se renseigner (lire les articles)

5.9 Evaluation des performances prédictives du modèle

résistance aux valeurs manquantes résistance au bruit d'échantillonnage

⁷organe permettant à l'organisme de contrôler sa flottaison

6 Conclusion

7 Annexes

7.1 Stratification verticale et horizontale des océans




Figure 8: Stratification verticale de l'eau selon la pénétration de la lumière et de la pression, stratification horizontale selon la distance au plateau continental (Dipper 2022).

7.2 Distribution verticale des valeurs manquantes des ESU

7.3 Influence du nombre de composantes principales sur la reconstruction des profils de température et salinité

PC	Eigenvalue	Prop. variance	Cumulative variance
1	981.66665873	0.9810935	0.9810935
2	12.52661452	0.0125193	0.9936128
3	4.16020812	0.0041578	0.9977705
4	0.92707153	0.0009265	0.9986971
5	0.56820781	0.0005679	0.9992649
6	0.41429271	0.0004141	0.9996790
7	0.13458956	0.0001345	0.9998135
8	0.05806269	0.0000580	0.9998715
9	0.05427009	0.0000542	0.9999258
10	0.02370249	0.0000237	0.9999495

Table 1: Valeurs propres et variance expliquée par les composantes principales.




Figure 9: Effet du nombre de composantes principales k sur la qualité de reconstruction des profils de température et salinité. Un nombre de PC permettant d'obtenir une variance expliquée > 0.99 ne permet pas nécessairement une reconstruction correcte des profils.

References

- Abram, Nerilie J. et al. (2025). “Emerging evidence of abrupt changes in the Antarctic environment”. In: *Nature* 644.8077, pp. 621–633. DOI: [10.1038/s41586-025-09349-5](https://doi.org/10.1038/s41586-025-09349-5).
- Adroli, Nurmalia et al. (July 2026). “Southern Ocean regime shift: divergent trends in surface phytoplankton community composition using a diagnostic pigment framework”. In: *Nature Communications* 17.1, p. 8607. DOI: [10.1038/s41467-026-75303-2](https://doi.org/10.1038/s41467-026-75303-2).
- Boor, Carl de (2001). “A Practical Guide to Splines”. In: Revised Edition. New York: Springer. Chap. B-splines, p. 87.
- Dipper, Frances (2022). “The seawater environment and ecological adaptations”. In: *Elements of Marine Ecology*. 5th ed. Oxford: Butterworth-Heinemann, pp. 37–151. DOI: [10.1016/B978-0-08-102826-1.00002-8](https://doi.org/10.1016/B978-0-08-102826-1.00002-8).
- Doney, Scott C. et al. (2012). “Climate Change Impacts on Marine Ecosystems”. In: *Annual Review of Marine Science* 4, pp. 11–37. DOI: [10.1146/annurev-marine-041911-111611](https://doi.org/10.1146/annurev-marine-041911-111611).
- Eilers, Paul H. C. and Brian D. Marx (May 1996). “Flexible Smoothing with B-splines and Penalties”. In: *Statistical Science* 11.2, pp. 89–102. DOI: [10.1214/ss/1038425655](https://doi.org/10.1214/ss/1038425655).
- Fieux, Michèle (2019). *L’Océan planétaire*. 2nd ed. Les Presses de l’ENSTA. ISBN: 978-2-7225-0960-3.
- Fonvieille, Nadège (Sept. 2024). “Structure des paysages océaniques tridimensionnels par l’analyse de données issues d’éléphants de mer du Sud”. Thèse de doctorat. Marseille, France: Aix-Marseille Université.
- Hayward, Alexander et al. (2024). “Climate driven shifts in Antarctic phytoplankton groups: Implications of widespread diatom decline”. In: *Research Square*. DOI: [10.21203/rs.3.rs-5188031/v1](https://doi.org/10.21203/rs.3.rs-5188031/v1).
- Hutchinson, G. Evelyn (1957). “Concluding Remarks”. In: *Cold Spring Harbor Symposia on Quantitative Biology* 22, pp. 415–427. DOI: [10.1101/SQB.1957.022.01.039](https://doi.org/10.1101/SQB.1957.022.01.039).
- Sallée, Jean-Baptiste (June 2018). “Southern Ocean Warming”. In: *Oceanography* 31.2, pp. 52–62. DOI: [10.5670/oceanog.2018.215](https://doi.org/10.5670/oceanog.2018.215).
- Shetye, Suhas, Rahul Mohan, and Abhilash Nair (Dec. 2013). “Latitudinal shifts in the Polar Front in Indian sector of the Southern Ocean: evidences from silicoflagellate assemblage”. In: *Geosciences Journal* 18.2, pp. 241–246. DOI: [10.1007/s12303-013-0061-8](https://doi.org/10.1007/s12303-013-0061-8).
- Thomalla, Sandy J. et al. (2023). “Widespread changes in Southern Ocean phytoplankton blooms linked to climate drivers”. In: *Nature Climate Change* 13.9, pp. 975–984. DOI: [10.1038/s41558-023-01768-4](https://doi.org/10.1038/s41558-023-01768-4).
- Wand, Matthew P. and John T. Ormerod (2008). “On Semiparametric Regression with O’Sullivan Penalized Splines”. In: *Australian & New Zealand Journal of Statistics* 50.2, pp. 179–198. DOI: [10.1111/j.1467-842X.2008.00507.x](https://doi.org/10.1111/j.1467-842X.2008.00507.x).