

UNIVERSITÉ PARIS CITÉ

Département de mathématiques et d'informatique

**Comment la structure des communautés
phytoplanctoniques influence t-elle la distribution du
zooplancton et du micronecton ?**

Une étude en été dans le secteur Indien de l'Océan Austral

Rapport de stage

Résumé

Rapport réalisé par

Elise NICOLAS

Encadrants

Marius MOLINET, David NERINI, Christophe GUINET, Cédric
COTTE

Professeure référente

FISHER Aurélie

Table des matières

1	Introduction	3
1.1	Généralités	3
1.2	Secteur Indien de l’Océan Austral	6
1.2.1	Contexte physico-chimique de la région	6
1.2.2	Contexte biologique	7
1.2.3	Et dans un contexte de changement climatique?	7
1.3	Question scientifique	8
1.4	il manque	8
2	Matériel	10
2.1	Concentrations de pigments photosynthétiques (PIGMeANN)	10
2.2	Données hydrologiques de température et salinité (CMEMS)	12
2.3	Données hydrodynamiques : Finite Time Lyapunov Exponent	12
2.4	Données d’acoustique active (OBSAUSTRAL)	14
3	Méthode	16
3.1	Pré-traitement des données	16
3.1.1	Calcul du Nautical Area Scattering Coefficient (NASC) [20]	16
3.1.2	Calcul des Functional Oceanographic Domain (FOD)	18
3.1.3	Colocalisation NASC/PIG/FTLE/FOD	27
3.2	Arbres de Régression	29
3.2.1	CART	29
3.2.2	Random Forest	29
3.2.3	Extreme Gradient Boosting	29
3.2.4	Tuning, entraînement, validation et prédiction	29
4	Résultats	30
4.1	distrib interanuelles générales	30
4.2	FOD	30
4.3	Cluster de pigments	30
4.4	Résultats des régressions	30
5	Discussion	31
5.1	Influence des fréquences	31
5.2	Complétion des NAs et influence sur le NASC	31

5.3	FOD : nombre de composante principale, données modèles, non prise en compte des données chimique (fer) et sea ice	31
5.4	définition de communauté phyto à partir des bio-optical water types . .	31
5.5	effet du temps sur les corrélations mésoéchelle/phyto/zoo/nti	31
5.6	test statistiques : effet du nombre de données et dispersion sur la significativité, tendance vs climate change trend	32
5.7	Influence sur la prédiction : gradient latitudinal, overfit, déséquilibre de l'échantillonnage	32
5.8	Choix des variables prédictives, manque de variables	32
5.9	Interprétation de l'importance des variables	32
5.10	Evaluation des performances prédictives du modèle	32
6	Conclusion	33
7	Annexes	34
7.1	Stratification verticale et horizontale des océans	34
7.2	Réponse fréquentielle des organismes pélagiques	35
7.3	Valeurs manquantes sur le volume de rétropropagation acoustique S_v en fonction de la profondeur et de la fréquence de l'échosondeur	36
7.4	Propriétés des B-Splines de degré m : Support, positivité et régularité .	36
7.5	Influence du nombre de composantes principales sur la reconstruction des profils de température et salinité	37

1 Introduction

1.1 Généralités

L'**océan** couvre 70% de la surface terrestre. La répartition des terres émergées n'est pas équivalente selon les deux hémisphères : l'hémisphère Sud est composé à 80.9% de mer, contre 60.7% pour l'hémisphère Nord. Dans l'hémisphère Sud, dans le bassin Antarctique, les océans Atlantique, Pacifique et Indien se connectent. Une seule masse d'eau liquide se déplace alors dans les différents bassins. L'océan est un **milieu continu**.




Figure 1.1 – Illustration de l'Océan Austral et de la connexion entre tous les océans ([1])

Un **biotope** correspond à l'espace physique et les conditions abiotiques associées dans lesquelles vit une biocénose. Une **biocénose** est l'ensemble des populations d'organismes qui occupent une zone donnée et interagissent entre elles. L'océan étant un milieu continu, seuls la distance géographique et les paramètres physiques de l'eau (abiotiques) conditionnent la régionalisation en biotopes. La connaissance des paramètres physiques de l'eau est donc particulièrement importante pour l'étude des distributions des organismes et **niches écologiques**¹ marines.

1. **Niche écologique** : ensemble des conditions environnementales permettant à une espèce de survivre et de se reproduire [2].

Les principaux **paramètres abiotiques** structurant les écosystèmes sont : les propriétés hydrologiques et hydrodynamiques de l'eau, la pression et la lumière [3]. Les **propriétés hydrologiques** (température, salinité, composition chimique) de l'eau dépendent du climat : la chaleur et le vent induisent une évaporation rendant l'eau de mer plus salée, les précipitations induisent un adoucissement de la salinité. La composition chimique de l'eau de mer est fortement dépendante des apports du littoral (fer, nitrates, etc). **L'hydrodynamisme** inclue les marées et les divers courants induits par des gradients de température, de pressions. Ces derniers dépendent majoritairement du vent et de l'ensoleillement. **L'éclairement** (intensité et spectre) est structuré verticalement selon la profondeur à cause des propriétés d'absorption de l'eau (Annexe 7.1, figure 7.1). On parle de milieu eutrophe (épipélagique) entre 0 et 200m, de milieu dysphotique (mésopélagique) entre 200 et 1000m, de milieu aphotique (bathypélagique) entre 1000 et 4000m et de milieu abyssal au delà de cette dernière. La pression croît avec la profondeur et une stratification arbitraire est également appliquée selon cette variable (Annexe 7.1, figure 7.1). La proximité au littoral participant grandement à la modification de ces paramètres abiotiques, on sépare arbitrairement l'océan horizontalement selon sa distance au plateau continental. On parle de **zone pélagique** au delà du plateau continental. Le contexte actuel de changement global induit des modifications importantes de l'expression de ces paramètres et induit en conséquence des changements de structuration des écosystèmes océaniques [4], [5].

L'écologie est une discipline qui s'intéresse aux interactions entre les différentes espèces d'un même biotope. Parmi elles, les **relations trophiques** (alimentaires) jouent un rôle fondamentale dans la structuration des écosystèmes (figure 1.2).




Figure 1.2 – Schéma du réseau trophique océanique [3].

Les **producteurs primaires** supportent tout le réseau trophique. Leur capacité à transformer la matière inorganique en matière organique (organismes autotrophes) les positionnent à la base du réseau. En effet, de nombreux organismes (hétérotrophes) n'ont pas cette capacité et dépendent uniquement des apports organiques de leur alimentation pour survivre. Le producteur primaire du milieu pélagique est le **phytoplancton**. Ce terme désigne tous les organismes végétaux ("*phyto*") n'ayant pas la capacité de se déplacer contre le courant ("*plancton*"). Ce sont des organismes **photo-autotrophes**, c'est-à-dire, qu'ils peuvent soutenir leur métabolisme uniquement grâce à l'énergie lumineuse. Le processus bio-chimique permettant la transformation de l'énergie lumineuse en énergie chimique utilisable par le métabolisme est la **photosynthèse**. Ce processus nécessite la présence de **pigments photosynthétiques** chez les organismes l'effectuant. Les **consommateurs primaires** sont les organismes s'alimentant des producteurs primaires. Dans le contexte du milieu pélagique, c'est le **zooplancton**² et le **micronecton**³. Les **niveaux trophiques intermédiaires** sont tous les étages de la chaîne alimentaire, correspondent à tous les organismes situés entre les producteurs primaires et les prédateurs supérieurs (dernier niveau du réseau trophique).

2. "*Zoo*" : animal, "*Plancton*" : n'ayant pas la possibilité de se déplacer à contre-courant.

3. Petits poissons pélagiques.




Figure 1.3 – Positions moyennes du Front subtropical (STF), du Front subantarctique (SAF), du Front sud du Courant circumpolaire antarctique (SACCF), de la Divergence antarctique (AD), ainsi que des trois gyres cycloniques du bassin de Weddell-Endeavour, du bassin Antarctique-Australien et de la mer de Ross [1].

1.2 Secteur Indien de l’Océan Austral

L’océan Austral (ou Antarctique) forme un anneau autour de l’Antarctide. Il représente 22% de la surface totale des océans. Contrairement aux autres océans, il n’est pas délimité par des frontières continentales. En regardant une carte (voir figure 1.1), on pourrait penser qu’il est simplement la prolongation du bassin Atlantique, Pacifique et Indien. En réalité, il est délimité par une frontière océanographique : le Front Subtropical (approximativement à 40°S), caractérisé par de très forts gradients de températures (figure 1.3). L’océan Austral se distingue également des autres océans par l’uniformité de son climat, de son hydrodynamisme et de ses propriétés hydrologiques.

parler du sous échantillonnage de la région, de sa vasteté et de son importance dans le carbon uptake etc

1.2.1 Contexte physico-chimique de la région

Le secteur indien de l’Océan Austral est situé entre 20° et 80°E de longitude et s’étend de 30° à 70°S de latitude (figure 1.3, 1.4). Dans notre étude, la région d’intérêt (ROI) correspond au secteur Indien restreint en longitude (45-90°E, 30-60°S). Cette zone est caractérisée par plusieurs éléments : un fort gradient latitudinal de température, des changements bathymétriques importants (plateau de Crozet et Kerguelen) et un fort hydrodynamisme (Courant des Agulhas, front subtropical, front subantarctique, front polaire) (voir figure 1.4).

parler du faible éclaircissement, des concentrations en fer nitrates etc limitante, de la couverture de glace et de l'apport en fer de kerguelen




Figure 1.4 – Carte du secteur Indien de l’Océan Austral et des courants [6]

1.2.2 Contexte biologique

D’un point de vue écologique, le réseau trophique de la région contient peu de niveaux. Le producteur primaire du milieu pélagique est le phytoplancton. Les communautés phytoplanctoniques⁴ sont structurées selon un axe latitudinal. **recherches sur les structures phytoplanctoniques de base** Les consommateurs primaires sont le zooplancton et le micronecton. Plus particulièrement, la région est marquée par une forte abondance de Krill et d’euphosiacés. **parler des communautés phyto observées (pcq plus tard on présentera les chgms) la forte productivité primaire de la région et de la forte saisonnalité**

Les prédateurs supérieurs sont les éléphants de mer, manchots,..

1.2.3 Et dans un contexte de changement climatique ?

Dans un contexte de changement global, les caractéristiques physico-chimiques de l’eau et de l’atmosphère changent également. Des études récentes ont annoncé par exemple des changements de régime de vent, une diminution de la profondeur de la couche de mélange⁵, une altération des courants de circulation, une migration au sud du front polaire, un réchauffement de la température de surface, un changement du flux du fer et des changements dans la proportion de couverture de la glace induisant une diminution de la salinité de l’eau (adoucissement). [5],

4. Composition taxonomique en phytoplancton du milieu

5. text

Ces changements affectent les organismes habitant ces milieux, comme le phytoplancton. Des études récentes font l'hypothèse d'une augmentation de la production primaire totale et d'une restructuration des communautés phytoplanctonique ([7] : la contribution relative des diatomées dans la production primaire diminuerait. Au contraire, la contribution relative des haptophytes et des cryptophytes (nano/picophytoplankton ?) [8]

+ des changements de temporalité des blooms et de leur durée et amplitude (être + précise dans quel sens) [9]

6

développer les observations de ces changements et les hypothèses + long terme

développer les hypothèses sur les effets sur les NTI (trophic cascade) changements de temporalité/durée/amplitude des blooms => dictate the amount of biomass being generated within a season that can be exported to the ocean's interior or transferred to higher trophic levels [9]

1.3 Question scientifique

Ce projet de recherche s'intéresse à l'influence du type phytoplanctonique sur les niveaux trophiques intermédiaires du secteur Indien de l'Océan Austral

1.4 il manque

RESTREINDRE LES HYPOTHESES A L'ETE et a la ROI si possible
la présence de l'importance de l'atmosphère dans les params physicochimique (vent mixing water, increase in CO₂, more clouds = less light, etc) l'importance du SO dans le contexte de changement global (carbon uptake, ..) réseau trophique + détaillé du SO
Le changement climatique dans l'océan austral phytoplancton du SO : énorme vers Kerguelen, limité par lumière et iron Les changements de commu phyto observés Les hypothèses de changements /les changements observés dans les niveaux trophiques supérieurs (étude avec le carbone, article de Ziad) : ramifications trophodynamique (southern ocean in a changing climate, climate drivers of SO phytoplankton community)
hypothèses claires des changements physiques de la zone (changement de flux d'iron (avec sea ice zone différentes) , chgmt de régime de vent, stratification, chgmt de mld (decreased), stratification alteration des pattern de circulation, southward migration of ocean fronts, increase in SST, changes in sea ice cover) hypothèses claires des changements

6. "In marine climate systems, a regime shift refers to a persistent reorganisation of physical and ecological system structure, variability and feedback processes that results in a transition toward a new dominant state rather than a short term interannual fluctuation [10]

de commu phyto induits (augmentation chla totale diminution contribution des diatoms, auglntation de contribution des petits phyto) hypothèses claires des changements de nti induits (ramification)

2 Matériel

Les données sélectionnées pour notre étude servent de proxy aux paramètres abiotiques clés dans la régionalisation des écosystèmes (développés dans la section 1.1) et de proxy pour l'étude des organismes d'intérêt (phytoplancton, niveaux trophiques intermédiaires). L'hydrodynamisme est approximé par le modèle de Finite-Time Lyapunov Exponent et les données hydrologiques sont approximées par les données de modèles du Copernicus Marine Service. La production primaire est déduite des concentrations de pigments issues du modèle PIGMeANN. Enfin, la distribution des niveaux trophiques intermédiaires est approchée par acoustique active à 38 et 120kHz.

Ces quatre ensembles de données sont au moins tri-dimensionnels (temps, longitude, latitude). Une quatrième dimension (profondeur) est également présente pour les données d'acoustique active et de température/salinité.

L'étude a été réalisée sur les années 2018, 2021, 2022 et 2023, en été afin de limiter la variabilité saisonnière, et de jour (calculé selon l'angle solaire), afin de limiter l'effet de la migration verticale journalière (DVM).

2.1 Concentrations de pigments photosynthétiques (PIGMeANN)

L'analyse de la couleur des océans à partir d'images satellite permet de d'étudier le phytoplancton sur une échelle spatiale et temporelle large. Historiquement les études se sont concentrées sur l'analyse de la chlorophylle-a de surface [9]. Plus récemment, des méthodes de deep learning ont permis la caractérisation de "Phytoplankton Functional Types" et de "Phytoplankton Size Classes" depuis des images satellites (par exemple Physat). La radiance renvoyée par les océans a une couleur dépendant des pigments photosynthétiques qu'ils contiennent. L'idée est d'identifier une empreinte spectrale et de l'associer (deep learning) avec des mesures *in-situ* High Performance Liquid Chromatography¹ et de cytométrie en flux² qui caractérisent la présence et la structure des communautés phytoplanctoniques.

1. L'échantillon est injecté dans une colonne traversée par un solvant sous haute pression, où ses différents composés sont séparés puis détectés individuellement. Permet de séparer et quantifier les pigments afin d'identifier les différents groupes présents.

2. Les cellules sont entraînées individuellement devant un laser qui mesure leur diffusion (taille/forme des cellules) et leur fluorescence. On peut ensuite identifier les taxons.




Figure 2.1 – Carte de prédiction de la concentration de Chlorophylle-a le 2023-01-26 sur le secteur indien du SO, prédictions issue de l’alorithme PIGMeANN développé par Sari el Dine [11].

Pigment	Abréviation
Divinyl chlorophylle <i>a</i>	dvChla
Chlorophylle <i>a</i>	Chla
Chlorophylle <i>b</i>	Chlb
Zéaxanthine	Zea
Fucoxanthine	Fuco
19'-hexanoyloxyfucoxanthine	Hex
19'-butanoyloxyfucoxanthine	But
Alloxanthine	Allo
Péridinine	Per

Table 2.1 – Pigments photosynthétiques analysés.

Sari El Dine a récemment mis en place la méthode de deep-learning PIGMeANN [11] permettant de distinguer des les concentrations de surfce de neuf pigments photosynthétiques(tableau 2.1) sur l’ensemble de la couverture spatiale de l’image satellite donnée en entrée (exemple de prédiction avec la Chorophylle-a figure 2.1).

A partir de la connaissance des différentes communautés phytoplanctoniques présente dans la région d’étude, et en s’appuyant notamment sur des études récentes [12], [13], on peut relier certains pigments à des groupes phytoplanctoniques (PFD) ou Phytoplankton Size Classes (PSC). Ainsi on peut identifier la composition des communautés phytoplanctoniques à partir des différents assemblage de concentration de pigments prédites. A noter que plusieurs taxons phytoplanctoniques peuvent partager

les mêmes pigments photosynthétiques, ce pourquoi on identifie des PFD/PSC et non des taxons.

2.2 Données hydrologiques de température et salinité (CMEMS)

Les données de températures et salinité sont issues de la plateforme Copernicus³. Ce sont des données issues des observations temps-réelles CMEMS⁴ et réanalysées par le modèle NEMO⁵, et ERA5⁶. Sont téléchargées tous les profils de température ("thetao") et de salinité ("so") entre 45-90°E de longitude et 30 et 60°S de latitude, avec une résolution spatiale de 0,083° et une résolution temporelle journalière, sur les quatres années étudiées : 2018, 2021, 2022, 2023, entre janvier et mars.

2.3 Données hydrodynamiques : Finite Time Lyapunov Exponent

Le Finite Time Lyapunov Exponent est un indicateur qui, à partir des données de champs de courants, permet de caractériser la séparation ou la convergence de trajectoires de particules d'eau sur une durée finie. On peut ainsi identifier les structures dynamiques susceptibles de contrôler le transport et la dispersion dans l'océan [15], [16].

On considère un champ de vitesse bidimensionnel dépendant de la position et du temps, issu des données de réanalyse GLORYS21 de Copernicus Marine Service :

$$\mathbf{u}(x, y, t) = \begin{pmatrix} u(x, y, t) \\ v(x, y, t) \end{pmatrix} \quad (2.1)$$

avec u et v représentant respectivement les composantes zonale et méridienne de la vitesse, et où $\mathbf{x} = (x, y)$ désigne la position de la particule.

À partir d'une position initiale $\mathbf{x}_0$ au temps t_0 , la trajectoire d'une particule est obtenue en intégrant l'équation d'advection :

$$\frac{d\mathbf{x}}{dt} = \mathbf{u}(\mathbf{x}, t), \quad \mathbf{x}(t_0) = \mathbf{x}_0. \quad (2.2)$$

3. Programme d'observation de la Terre de l'Union européenne, qui fournit notamment des données et services permettant de surveiller et comprendre l'état de l'environnement, dont l'océan [14]

4. Copernicus Marine Environment Monitoring Service, service marin de Copernicus

5. Nucleus for European Modelling of the Ocean, modèle numérique de l'océan qui simule l'évolution de paramètres comme la température, la salinité, les courants et le niveau de la mer

6. Modèle atmosphérique de l'ECMWF (European Centre for Medium-Range Weather Forecasts) qui fournit les conditions atmosphériques nécessaires pour forcer le modèle océanique NEMO à sa surface

Après une durée d'intégration T , la position finale de la particule peut être décrite à l'aide du flot lagrangien :

$$\mathbf{x}(t_0 + T) = \mathbf{F}_{t_0}^T(\mathbf{x}_0), \quad (2.3)$$

où $\mathbf{F}_{t_0}^T$ est l'application qui associe à chaque position initiale $\mathbf{x}_0$ sa position après une durée T .

On peut ensuite analyser la variation des trajectoires $\mathbf{F}_{t_0}^T(x_0)$ après un temps T si l'on change la position initiale x_0 des particules (tenseur de déformation) :

$$\nabla \mathbf{F}_{t_0}^T = \frac{\partial \mathbf{F}_{t_0}^T}{\partial \mathbf{x}_0} = \begin{pmatrix} \frac{\partial F_x}{\partial x_0} & \frac{\partial F_x}{\partial y_0} \\ \frac{\partial F_y}{\partial x_0} & \frac{\partial F_y}{\partial y_0} \end{pmatrix} \quad (2.4)$$

Le tenseur de Cauchy-Green permet de quantifier la déformation des distances entre des particules initialement proches. Il est défini par :

$$\mathbf{C}_{t_0}^T(\mathbf{x}_0) = \left(\nabla \mathbf{F}_{t_0}^T(\mathbf{x}_0) \right)^T \nabla \mathbf{F}_{t_0}^T(\mathbf{x}_0). \quad (2.5)$$

Le facteur maximal d'étirement entre les particules est donné par la plus grande valeur propre λ_{max} du tenseur de Cauchy-Green $\mathbf{C}_{t_0}^T(\mathbf{x}_0)$

Le FTLE ($\sigma_{t_0}^T$) est ensuite calculé, il correspond au taux de croissance logarithmique du facteur d'étirement maximal λ_{max} , normalisé par la durée d'intégration T :

$$\sigma_{t_0}^T(\mathbf{x}_0) = \frac{1}{|T|} \ln \left(\sqrt{\lambda_{max}(\mathbf{C}_{t_0}^T(\mathbf{x}_0))} \right) \quad (2.6)$$

avec :

- $\mathbf{C}_{t_0}^T$ le tenseur de Cauchy-Green, décrit comment les distances entre les particules évoluent. Il est calculé à partir des données de champs de courants

$$\mathbf{C}_{t_0}^T = \left(\nabla \mathbf{F}_{t_0}^T \right)^T \left(\nabla \mathbf{F}_{t_0}^T \right) \quad (2.7)$$

- λ_{max} la plus grande valeur propre du tenseur de Cauchy-Green
- $\mathbf{x}_0$ la position initiale de la particule
- T le temps d'intégration pendant lequel on suit la particule
- σ le FTLE qui mesure le taux moyen de séparation des trajectoires des particules, exprimé en unité inverse du temps




Figure 2.2 – Advection Lagrangienne FTLE backward (90j) du 2023-01-26

Dans notre étude, la durée d’advection est de quatre-vingt dix jours en backward. On obtient des cartes de $FTLE \in \mathbb{R}^{time \times lon \times lat}$ pour les années 2018, 2021, 2022, 2023 entre janvier et mars. La résolution temporelle est journalière et la résolution spatiale est de 0.05° .

Une valeur élevée du FTLE indique une forte séparation des trajectoires voisines sur la période considérée. Les structures organisées apparaissant comme des crêtes de FTLE (voir figure 2.2) peuvent ainsi être utilisées pour identifier des frontières de transport ou des structures cohérentes lagrangiennes (Lagrangian Coherent Structures, LCS) dans l’écoulement [15].

2.4 Données d’acoustique active (OBSAUSTRAL)

Les écosystèmes pélagiques sont difficilement observable. L’acoustique active est une méthode consistant à émettre une onde, la réceptionner et analyser le signal reçu (principe du sonar) [17]. L’écho reçu résulte de la réflexion du son émis par un objet (par exemple le fond marin (bathymétrie)), un organisme où encore des discontinuité physiques dans la colonne d’eau (i.e. changements de densité). Avec la connaissance de la vitesse locale de propagation du son dans l’eau, le délai avec lequel le signal est reçu et son intensité peuvent informer : la distance des backscaterrers (leur position dans la colonne d’eau), leur abondance, la composition taxonomique des organismes présents, voir également leur taille. Cette méthode à l’avantage de permettre un échantillonnage de la colonne d’eau avec une résolution et couverture spatiale et temporelle importante. Elle est également non-invasive et non-extractive.




Figure 2.3 – Schéma explicatif illustrant l'acquisition de données d'acoustique active par des navires, permettant de caractériser la distribution des organismes dans la colonne d'eau à partir des signaux acoustiques enregistrés et représentés sous forme d'échogramme [18].

La réflectance des ondes acoustiques sur un objet dépend également de la fréquence émise. D'autre part, différents organismes ont des réponses fréquentielles différentes (voir Annexe 7.2, figure 7.2). La méthode d'acoustique active ayant été développée par les pêcheries, la fréquence d'échosondeur de référence est 38kHz (fréquence à laquelle sont les poissons résonnent).

Pour notre étude, nous avons utilisé des données d'acoustiques actives collectées en transect⁷ lors des campagnes océanographiques OBSAUSTRAL/THEMISTO [19] lors des étés 2018, 2021, 2022, 2023. Deux fréquences d'émissions ont été choisies pour notre étude : 38kHz (afin de comparer nos résultats avec la littérature) et 120kHz qui correspond à la fréquence à laquelle les Euphausiacés (krill) et Copépodes sont le plus détectable (voir Annexe 7.2, figure 7.2). En effet, ces organismes sont en forte abondance et constituent des éléments importants du réseau trophiques de la région d'étude.

7. Le bateau se déplace et collecte en même temps des données, (par opposition aux données "stations" collectées lorsque le bateau est en arrêt). Cela a un coût en terme de résolution des spectrogramme et d'interprétabilité mais permet d'obtenir une plus grande couverture spatiale.

3 Méthode

3.1 Pré-traitement des données

3.1.1 Calcul du Nautical Area Scattering Coefficient (NASC) [20]

L'**Intensité de l'écho (IE)** correspond au signal reçu par le transducteur lorsqu'une onde est émise dans la colonne d'eau puis réfléchi par un objet.

$$IE = IS - 2TL + DI + TS \quad (3.1)$$

où

- IS est l'intensité du son émise (dB) $IS = 10 \times \log_{10}(I/I_{ref})$ et $I_{ref} = \rho_{ref}^2 = 1\mu\text{Pa}$ (ρ_{ref} la pression de référence)
- TL la perte de transmission ¹ $TL = 20 \log_{10}(R) + \alpha R$
- DI : l'indice de directivité du transducteur (dB)
- TS la réflectivité de la source (Target Strength) ²

Sur une échelle linéaire, le TS correspond à la **section efficace de rétrodiffusion** $\sigma_{bs} = 10^{\frac{TS}{10}}$ (m²). Elle caractérise la capacité de la cible à rétrodiffuser l'énergie acoustique et est déterminée par référence à la section efficace de rétrodiffusion théorique de la sphère de calibration utilisée lors de la calibration du sondeur.

Le **volume backscattering coefficient** s_v (en m².m⁻³ ou m⁻¹) est la somme toutes les surfaces réfléchives σ_{bs} de toutes les cibles acoustiques dans le

1. Le premier terme correspond à l'atténuation due à la dispersion de l'onde et le second terme correspondant à l'atténuation de la propagation du milieu (α le coefficient d'absorption en dB.m⁻¹)

2. $TS = 10 \log_{10}(P - r) + 4010 \log_{10}(R) + 2\alpha R - 10 \log_{10}(\frac{P_t \lambda^2}{16\pi^2} - 2G_0)$ avec

- P_r : puissance du signal reçu, mesurée aux bornes du transducteur (W).
- P_t : puissance du signal transmis, référencée aux bornes du transducteur (W).
- R : distance entre le transducteur et la cible détectée (m).
- c : célérité du son dans le milieu (m/s).
- α : coefficient d'absorption du milieu (dB/m).
- λ : longueur d'onde (m).
- G_0 : gain du transducteur sur l'axe acoustique, mesuré lors de la calibration du sondeur (dB).

volume d'échantillonnage V , normalisées à $1m^3$. Il mesure de la densité acoustique des organismes présents dans un volume d'eau. Un niveau de S_v élevé correspond à une quantité plus importante de rétrodiffusion acoustique dans le volume échantillonné. Ce qui est interprété comme un nombre important d'organismes présents dans la colonne d'eau ou un organisme de taille importante ou encore un organisme ayant des propriétés réfléchives diffusantes³.

$$s_v = \sum \sigma_{bs}/V \quad (3.2)$$

Le **Nautical Area Scattering Coefficient (NASC)**, noté s_A , correspond au coefficient de rétrodiffusion acoustique par unité de surface nautique (en $m^2.nmi^{-2}$) correspond à l'intégration sur l'ensemble de la colonne d'eau du volume backscattering coefficient en échelle linéaire $s_v = 10^{\frac{S_v}{10}}$ multiplié par un certain facteur (convention). Le NASC résume la rétrodiffusion acoustique sur une couche d'eau donnée.

$$s_A = 4\pi(1852)^2 \int_{z_1}^{z_2} s_v \quad (3.3)$$

Pour notre étude, nous avons utilisé le NASC comme mesure approximant la biomasse de zooplancton et micronecton (NTI) présents dans la colonne d'eau. Les calculs de volume backscattering coefficient s_v à partir de l'intensité de l'écho (IE) Isabelle Durand, ingénieure au MNHN. Pour les calculs du NASC, la profondeur d'intégration z_1 a été fixé à 25m pour limiter le biais d'échantillonnage⁴. Le choix de z_2 dépend de la fréquence de l'échosondeur : pour des fréquences de 38kHz et 120m, la colonne d'eau est échantillonné respectivement jusqu'à une profondeur moyenne de 700m et 300m (voir Annexe 7.3, figure 7.3). A partir de ces profondeurs, beaucoup de profils de volume de rétropropagation acoustiques ont des valeurs manquantes. Afin d'éviter d'intégrer les coefficients de rétrodiffusion acoustique sur des profondeurs variables, les profils avec plus de 50% de valeurs manquantes ont été exclues du jeu de données. Les valeurs manquantes résiduelles situées entre deux profondeurs connues ont été comblées par interpolation linéaire. Les valeurs manquantes résiduelles situées aux extrémité du profil sont comblées en prolongant le profil par la valeur la plus proche.

Ainsi, pour chaque profil de volume de retropropagation acoustique (ESU), on calcule le NASC qui nous donne un scalaire, le résumé de la rétrodiffusion acoustique sur l'ensemble de la couche d'eau considérée ([25-700]m pour 38kHz et [25-300]m pour 120kHz) (figure 3.1).

3. Beaucoup de poissons pélagiques ont des vessies natatoires, ce sont des organes leur permettant d'ajuster leur flottabilité. Cette vessie natatoire est connue pour particulièrement diffuser à 38kHz et donc augmenter artificiellement le volume de rétrodiffusion mesuré

4. effet de "bullage" du bateau bruyant les données à des faibles profondeurs




Figure 3.1 – $\log_{10}(NASC)$ en fonction du temps, données d’acoustique active (transect) issues de la campagne océanographique OBSAUSTRAL 2023 [19].

3.1.2 Calcul des Functional Oceanographic Domain (FOD)

3.1.2.1 Présentation des Domaines Océanographiques Fonctionnels

Les Domaines Océanographiques Fonctionnels (ou Functional Oceanographic Domain) sont des masses d’eau ayant des caractéristiques thermohalines similaires. La méthode d’identification des FOD a été développée par Fonvieille N. et Nerini D. [21]. Les données thermohalines (des modèles de Copernicus dans notre cas) sont, dans un premier temps (1), estimées dans un espace fonctionnel par projection sur une base de B-spline. Dans un second temps (2), la dimension de la matrice des coefficients de pondération des B-splines est réduite par une Analyse par Composante Principale (ACP ou PCA en anglais). Dans un dernier temps (3), un clustering (GMM) est appliqué à cette nouvelle matrice de coefficients de pondération des B-splines. Ces trois étapes seront développées dans les paragraphes suivants.

3.1.2.2 Estimation fonctionnelle sur des bases de B-splines Estimation semi-paramétrique des profils de température et salinité

Basis-splines de degré m [22]

Les Basis-splines (B-splines) peuvent servir de base pour l’estimation par projection (estimation semi-paramétrique ou fonctionnelle). Ce sont des fonctions à support local pouvant être définies par la récurrence de Cox-de-Boor [22] :




Figure 3.2 – Illustration d’une B-spline isolée et de B-splines chevauchantes, de degré 1 (a) et de degré 2 (b) [23]

Soit $\phi_{i,m}(x)$ la B-spline de degré m dont le support est $\text{supp}(\phi_{i,m}(x)) = [\tau_i, \tau_{i+m+1}]$. Avec $\tau_i, \dots, \tau_{i+m+1}$ les noeuds (équi-espacés ou non). On peut définir la B-spline $\phi_{i,m}(x)$ comme suis [22] :

1. Initialisation d’une fonction porte par noeud (degré 0, ordre 1)

$$\phi_{i,0}(x) = \begin{cases} 1 & \text{si } \tau_i \leq x < \tau_{i+1} \\ 0 & \text{sinon} \end{cases} \quad (3.4)$$

2. Réccurence : combinaison convexe de B-splines de degré inférieur à deux noeuds consécutifs

$$\phi_{i,m}(x) = \omega_{i,m}(x) \phi_{i,m-1}(x) + (1 - \omega_{i+1,m}(x)) \phi_{i+1,m-1}(x) \quad (3.5)$$

avec

$$\omega_{j,m}(x) := \frac{x - \tau_j}{\tau_{j+m} - \tau_j}, \forall j \quad (3.6)$$

(le poids de chaque terme est normalisé par le support de la B-spline de degré $m-1$ qu’il pondère : $\text{supp}(\phi_{i,m-1}) = [\tau_i, \tau_{i+m}]$ et $\text{supp}(\phi_{i+1,m-1}) = [\tau_{i+1}, \tau_{i+1+m}]$).

Espace des splines et base de B-splines

Soit $\tau = (\tau_1, \dots, \tau_{2m+L+2})$ une suite de noeuds définie par

$$\underbrace{a = \tau_1 = \tau_2 = \dots = \tau_{m+1}}_{m+1 \text{ noeuds répétés en } a} < \underbrace{\tau_{m+2} < \dots < \tau_{m+L+1}}_{L \text{ noeuds intérieurs}} < \underbrace{\tau_{m+L+2} = \dots = \tau_{2m+L+2} = b}_{m+1 \text{ noeuds répétés en } b} \quad (3.7)$$

On note $\mathbb{S}_{m,\tau}$ l’espace des fonctions splines de degré m associées à cette suite de noeuds. Une spline $f \in \mathbb{S}_{m,\tau}$ est une fonction polynomiale par morceaux de degré au plus m , définie sur les intervalles délimités par les noeuds τ , et satisfaisant les conditions de continuité imposées par les multiplicités des noeuds (Voir Annexe 7.4)..

Les B-splines de degré m associées à la suite de noeuds τ , notées $\{\phi_{i,m}\}_{i=1}^{L+m+1}$ constituent une base de l'espace $\mathbb{S}_{m,\tau}$ ($\dim(\mathbb{S}_{m,\tau}) = L + m + 1$).

Par conséquent, toute fonction spline $f \in \mathbb{S}_{m,\tau}$ peut s'écrire de manière unique comme une combinaison linéaire des B-splines :

$$f(x) = \sum_{i=1}^{L+m+1} \alpha_i \phi_{i,m}(x), \quad \alpha_i \in \mathbb{R}. \quad (3.8)$$

Estimation fonctionnelle par minimisation des moindres carrés pénalisée (O-Splines) [24], [23]

Appliquons maintenant ce cadre à l'estimation fonctionnelle des profils de température et de salinité. Soit l un indice spatio-temporel (combinaison d'un instant, d'une longitude et d'une latitude) et $v \in T, S$ la variable considérée. Le profil brut $\mathbf{v}_l \in \mathbb{R}^{n_{depths}}$ correspond aux valeurs de v issues du modèle Copernicus aux profondeurs discrètes $z_1, \dots, z_{n_{depths}}$. On suppose que ces observations proviennent de l'évaluation d'une fonction sous-jacente f_l aux profondeurs considérées :

$$v_l(z_k) = f_l(z_k) + \varepsilon_k, \quad k = 1, \dots, n_{depths}, \quad (3.9)$$

où ε_k représente le terme d'erreur associé à l'observation du profil à la profondeur z_k .

L'objectif est d'estimer f_l sur l'intervalle de profondeur $[a, b]$, qui correspond ici à $[20, 500]$ m. On cherche pour cela une approximation $\hat{f}_l \in \mathbb{S}_{m,\tau}$ sous la forme d'une combinaison linéaire des B-splines définies précédemment :

$$\hat{f}_l(z) = \sum_{i=1}^K \alpha_{l,i} \phi_{i,m}(z), \quad K = L + m + 1. \quad (3.10)$$

où L désigne le nombre de noeuds intérieurs et K le nombre total de B-splines. Les coefficients $\boldsymbol{\alpha}_l = (\alpha_{l,1}, \dots, \alpha_{l,K})^\top$ déterminent ainsi entièrement la spline estimée pour le profil l . Pour un profil donné, les coefficients $\boldsymbol{\alpha}_l$ sont déterminés en minimisant l'erreur d'ajustement entre les observations et la spline. La fonction objectif des moindres carrés est

$$S_l = \sum_{k=1}^{n_{depths}} \left(v_l(z_k) - \hat{f}_l(z_k) \right)^2 \quad (3.11)$$

$$= \sum_{k=1}^{n_{depths}} \left(v_l(z_k) - \sum_{i=1}^K \alpha_{l,i} \phi_{i,m}(z_k) \right)^2. \quad (3.12)$$

Cependant, lorsque le nombre de noeuds est élevé, l'ajustement peut devenir excessivement flexible et conduire à un sur-ajustement (*overfitting*). Afin de contrôler la

complexité de la fonction estimée, on introduit une pénalisation de sa rugosité⁵. La matrice de pénalisation Ω est définie par

$$\Omega_{i,j} = \int_a^b \phi_{i,m}''(z) \phi_{j,m}''(z) dz, \quad 1 \leq i, j \leq K. \quad (3.13)$$

Le critère pénalisé à minimiser pour le profil l est alors

$$S_{l,\lambda} = \underbrace{\sum_{k=1}^{n_{depths}} \left(v_l(z_k) - \sum_{i=1}^K \alpha_{l,i} \phi_{i,m}(z_k) \right)^2}_{\text{erreur d'ajustement}} + \lambda \underbrace{\alpha_l^\top \Omega \alpha_l}_{\text{pénalisation de la rugosité}}. \quad (3.14)$$

où $\lambda \geq 0$ est le paramètre de lissage contrôlant le compromis entre fidélité aux observations et régularité de la fonction estimée. Dans notre cas, le nombre de splines K et le paramètre de lissage λ ont été choisis par validation croisée leave-one-out (CV-LOO). On trouve $\lambda = 0.25$ pour $K = 25$ splines




Figure 3.3 – Estimation fonctionnelle des profils de Température/Salinité ($\lambda = 0.25$, $K = 25$) issu de Copernicus (E.U. Copernicus Marine Service Information (CMEMS). Global Ocean Physics Reanalysis. Marine Data Store (MDS). DOI : 10.48670/moi-00021) le 2023-01-26 aux coordonnées 450E,-60°N.

5. mesure le degré d'irrégularité d'une fonction, est quantifié par l'intégrale du carré de sa dérivée seconde

3.1.2.3 Réduction de dimension par Analyse en Composante Principale

Suite à l'estimation fonctionnelle réalisée à l'étape précédente, chaque profil l est désormais représenté par un couple de fonctions de la profondeur, la température et la salinité, estimées sur la même base de B-splines $(\Phi_k)_{1 \leq k \leq K}$ définie sur $[d_{min}, d_{max}]$:

$$T_l(z) = \sum_{k=1}^K \alpha_{l,k}^T \Phi_k(z), \quad S_l(z) = \sum_{k=1}^K \alpha_{l,k}^S \Phi_k(z), \quad z \in [d_{min}, d_{max}]$$

On considère alors chaque profil comme une observation **bivariée** $X_l = (T_l, S_l) \in \left(L^2([d_{min}, d_{max}])\right)^2$, muni du produit scalaire

$$\langle (f_1, g_1), (f_2, g_2) \rangle = \langle f_1, f_2 \rangle_{L^2} + \langle g_1, g_2 \rangle_{L^2}$$

L'objectif de cette étape est de réduire conjointement la dimension des profils de température et de salinité, afin de capturer les modes de variabilité communs aux deux variables.

Une approche pour réduire la dimension des données est l'analyse par composante principale (ACP ou PCA pour Principal Component Analysis). Puisque les données sont dans un espace fonctionnel $\mathbb{S}_{m,\tau}$, on parle alors d'Analyse par Composante Principale *fonctionnelle* (ACPf ou FPCA). La logique est identique à celle d'une PCA classique mais les outils sont adaptés pour manipuler les fonctions. Ici, la fPCA est réalisée conjointement sur les deux variables, on parle de fPCA bivariée.

Construction du vecteur de coefficients bivarié

Pour chaque profil l , on concatène les coefficients de B-spline de température et de salinité en un unique vecteur $\alpha_l \in \mathbb{R}^{2K}$:

$$\alpha_l = \begin{pmatrix} \alpha_l^T \\ \alpha_l^S \end{pmatrix}, \quad \alpha_l^T = (\alpha_{l,1}^T, \dots, \alpha_{l,K}^T)^\top, \quad \alpha_l^S = (\alpha_{l,1}^S, \dots, \alpha_{l,K}^S)^\top$$

En empilant les N profils, on obtient la matrice $\alpha \in \mathbb{R}^{N \times 2K}$.

Centrage des données

Soit $\bar{\alpha} \in \mathbb{R}^{2K}$ la moyenne empirique, sur l'ensemble des N profils, des coefficients de chaque B-spline pour la partie température et pour la partie salinité :

$$\bar{\alpha} = \frac{1}{N} \sum_{l=1}^N \alpha_l$$

On obtient ainsi les coefficients bivariés centrés $\tilde{\alpha} = \alpha_l - \bar{\alpha}$, avec $\tilde{\alpha} \in \mathbb{R}^{N \times 2K}$. Pour

$l \in N$:

$$\tilde{\alpha}_l = \begin{pmatrix} \tilde{\alpha}_l^T \\ \tilde{\alpha}_l^S \end{pmatrix} \in \mathbb{R}^{2K}$$

Calcul de la covariance empirique

On définit la matrice bivariée de fonctions de base $\Phi(z) \in \mathbb{R}^{2 \times 2K}$ comme la concaténation de la base Φ utilisée pour chacune des deux composantes :

$$\Phi(z) = \begin{pmatrix} \Phi(z)^\top & 0 \\ 0 & \Phi(z)^\top \end{pmatrix} \in \mathbb{R}^{2 \times 2K},$$

de sorte que le profil bivarié centré s'écrive $\tilde{X}_l(z) = \Phi(z)\tilde{\alpha}_l = \begin{pmatrix} \tilde{T}_l(z) \\ \tilde{S}_l(z) \end{pmatrix}$.

La covariance empirique entre deux profondeurs s et t est alors une matrice 2×2 donnée par

$$\hat{V}(s, t) = \frac{1}{N} \sum_{l=1}^N \tilde{X}_l(s) \tilde{X}_l(t)^\top.$$

En introduisant la matrice de covariance empirique des coefficients

$$C = \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} \in \mathbb{R}^{2K \times 2K},$$

on obtient

$$\boxed{\hat{V}(s, t) = \Phi(s) C \Phi(t)^\top.}$$

Cette matrice contient à la fois les covariances intra-variables, correspondant aux blocs température-température et salinité-salinité, et les covariances croisées température-salinité.

Décomposition en valeurs propres et vecteurs propres de la matrice de covariance

On effectue la décomposition spectrale de l'opérateur de covariance $\hat{V}$:

$$\int \hat{V}(s, t) \xi(t) dt = \rho \xi(s)$$

avec la contrainte d'orthonormalité des fonctions propres bivariées : $\|\xi\|_{L^2} = 1$ et $\langle \xi_i, \xi_j \rangle = 0$ si $i \neq j$.

On fait l'hypothèse que la fonction propre bivariée $\xi(t)$ se décompose dans la même

base bivariée que nos profils :

$$\xi(t) = \Phi^\top(t) b, \quad b \in \mathbb{R}^{2K}$$

On a alors :

$$\begin{aligned} \int \hat{V}(s, t) \xi(t) dt &= \int \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} \Phi(t) \Phi^\top(t) b dt \\ &= \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} \underbrace{\int \Phi(t) \Phi^\top(t) dt}_=W b \\ &= \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} W b \end{aligned}$$

où $W = \int \Phi(t) \Phi^\top(t) dt \in \mathbb{R}^{2K \times 2K}$ est la matrice de Gram de la base bivariée. Comme $\Phi(t)$ répète deux fois la même base $\Phi(t)$, W prend la forme bloc-diagonale

$$W = \begin{pmatrix} W_0 & 0 \\ 0 & W_0 \end{pmatrix}, \quad W_0 = \int \Phi(t) \Phi^\top(t) dt \in \mathbb{R}^{K \times K}$$

les blocs hors-diagonale étant nuls car la partie température et la partie salinité de ξ n'interagissent qu'au travers de la covariance des coefficients $\tilde{\alpha}^\top \tilde{\alpha}$, pas au travers de la base elle-même.

On peut donc réécrire la décomposition spectrale comme suit :

$$\begin{aligned} \int \hat{V}(s, t) \xi(t) dt &= \rho \xi(s) \\ \iff \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho \Phi^\top(s) b \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho b \end{aligned}$$

La matrice $\tilde{\alpha}^\top \tilde{\alpha}$ est symétrique (c'est un produit de la forme $A^\top A$), mais le produit $\tilde{\alpha}^\top \tilde{\alpha} W$ ne l'est pas en général : le problème aux valeurs propres n'est donc pas directement résoluble par une décomposition spectrale standard. Pour contourner ce problème, on utilise le changement de variable $b = W^{-\frac{1}{2}} u$:

$$\begin{aligned} \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho b \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W W^{-\frac{1}{2}} u &= \rho W^{-\frac{1}{2}} u \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W^{\frac{1}{2}} u &= \rho W^{-\frac{1}{2}} u \\ \iff \frac{1}{N} \underbrace{W^{\frac{1}{2}} \tilde{\alpha}^\top \tilde{\alpha} W^{\frac{1}{2}}}_{\text{symétrique}} u &= \rho u \end{aligned}$$

La matrice $W^{1/2}\tilde{\alpha}^\top\tilde{\alpha}W^{1/2}$ est bien symétrique (elle est de la forme $M^\top M$ avec $M = \tilde{\alpha}W^{1/2}$), ce qui garantit des valeurs propres réelles ρ et des vecteurs propres u orthogonaux. Une fois u obtenu, on retrouve $b = W^{-1/2}u$, puis la fonction propre bivariée $\xi(t) = \Phi^\top(t)b$, dont les deux moitiés de b (les K premiers et les K derniers coefficients) donnent respectivement la composante "température" ξ^T et la composante "salinité" ξ^S de la fonction propre.

Calcul des scores (projections), reconstruction dans l'espace propre et variance expliquée

Une fois les fonctions propres bivariées $\xi_j = (\xi_j^T, \xi_j^S)$ et valeurs propres ρ_j calculées, on peut calculer les projections $c_{l,j}$ des profils bivariés centrés $\tilde{X}_l = (\tilde{T}_l, \tilde{S}_l)$ sur l'espace propre. On note $c_{l,j}$ le score du profil l sur la j -ème composante principale (commun à la température et à la salinité, puisque la composante principale est bivariée) :

$$\begin{aligned} c_{l,j} &= \langle \tilde{X}_l, \xi_j \rangle \\ &= \int \tilde{\alpha}_l^\top \Phi(t) \Phi^\top(t) b_j dt \\ &= \tilde{\alpha}_l^\top W b_j \in \mathbb{R} \end{aligned}$$

On choisit ensuite $J \ll 2K$ composantes à partir de la variance expliquée cumulée. La variance expliquée cumulée des J premières composantes principales est calculée comme suit :

$$VE = \frac{\sum_{j=1}^J \rho_j}{\sum_{k=1}^{2K} \rho_k}$$

avec ρ_k la valeur propre associée à la k -ième composante principale, les composantes étant triées par ordre **décroissant** de valeur propre ($\rho_1 \geq \rho_2 \geq \dots$), de sorte que les J premières composantes soient celles qui expliquent le plus de variance conjointe des profils de température et de salinité. On peut ainsi sélectionner par exemple les J premières composantes principales qui expliquent 90% de la variance.

Finalement, on peut reconstruire conjointement les profils de température et de salinité du profil l comme la combinaison linéaire des J premières fonctions propres bivariées et des scores associés (les mêmes scores $c_{l,j}$ pilotant simultanément la reconstruction des deux variables) :

$$T_l(t) = \bar{T}(t) + \sum_{j=1}^J c_{l,j} \xi_j^T(t), \quad S_l(t) = \bar{S}(t) + \sum_{j=1}^J c_{l,j} \xi_j^S(t)$$

où $\bar{T}$ et $\bar{S}$ sont les profils moyens de température et de salinité, obtenus à partir des composantes correspondantes de $\bar{\alpha}$.




Figure 3.4 – Réduction de la matrice de coefficients de pondération des B-splines par PCA et reconstruction des profils de Température/Salinité issu de Copernicus (E.U. Copernicus Marine Service Information (CMEMS). Global Ocean Physics Reanalysis. Marine Data Store (MDS). DOI : 10.48670/moi-00021) le 2023-01-26 aux coordonnées 450E,-60°N. $k=6$ composantes principales sont conservées (>99% de variance expliquée (voir Table 7.1, Annexe 7.5))

3.1.2.4 Gaussian Model Mixture Clustering

Afin de regrouper les profils de température et salinité similaires et identifier des Domaines Océanographiques Fonctionnels, on effectue un GMM clustering sur la matrice des coefficients réduite c obtenue à l'étape précédente. Le fonctionnement de la méthode ne sera pas développée ici, se référer à [25] pour une explication. Le GMM clustering a été implémenté avec le package `mclust` [26], [27] disponible sous R. Le modèle le plus flexible (`model="VVV"`) a été utilisé, permettant un ajustement des ellipsoïde non contraint en volume, orientation et forme, cela au prix d'une augmentation du

nombre d'hyperparamètres. Avec les précédents travaux réalisés par Fonvieille N. et Molinet M. [21], [28], la recherche d'un nombre de cluster a été restreinte entre 4 et 6 clusters, réduisant ainsi le coût computationnel. Les clusters ont été définis lorsque la probabilité d'appartenance à un cluster était supérieure au seuil fixé à 0.75. Des classes de transitions ont été créées en fonction des deux clusters ayant une probabilité d'appartenance maximale. Sont obtenus 13 clusters distincts : 6 clusters de FOD et 7 clusters de dits de "transitions"⁶ (voir figure ??).




Figure 3.5 – (a) Carte du secteur Indien de l'Océan Austral et des courants [6] (b) Carte des Domaines Océanographiques Fonctionnels du 2023-01-26 générée par la méthode développée par Fonvieille N. et Nerini D. [21]. Identification du Front Polaire (FP, cluster T2-3), du Front Subantarctique (SAF, cluster T3-4) et du Front Subtropical (STF, clusters T4-5 et T4-6)

Les FOD correspondent alors à des masses d'eau ayant des propriétés thermohalines similaires et permettent de visualiser l'hydrodynamisme de la région (tourbillons emprisonnant les masses d'eau dans leurs coeur, filaments, fronts), voir figure 3.5.

3.1.3 Colocalisation NASC/PIG/FTLE/FOD

Afin d'étudier la relation entre la distribution des organismes détectés acoustiquement (NASC), la dynamique de surface, les conditions hydrologiques et l'activité phytoplanctonique ; les données de NASC ont été colocalisées avec les *Finite-Time Lyapunov Exponents* (FTLE), les *concentration pigmentaire* (PIGMeANN) et les *Domaine Océanographique Fonctionnel* (FOD).

6. La classe "NA" correspond aux clusters manquants sur le plateau de Kerguelen. Les profils de température et salinité allant de 20 à 500m, sont retirés des calculs tout profils ayant des données manquantes entre ces deux valeurs. Les zones où la bathymétrie est inférieure à 500m sont donc exclues de ces calculs.

Le jeu de données d'acoustique active contient, pour chaque unité élémentaire d'échantillonnage (ESU), la date et l'heure d'acquisition, ses coordonnées géographiques (latitude et longitude) et la valeur de NASC associée (calculée à partir du volume de rétropropagation S_v).

Les données environnementales sont fournies sous la forme de grilles spatiales, principalement organisées en fichiers NetCDF journaliers. Pour chaque fréquence acoustique considérée (38 et 120 kHz), les dates présentes dans le jeu de données acoustique sont identifiées. Pour chacune de ces dates, les données environnementales correspondantes sont recherchées et chargées afin d'être associées aux observations acoustiques.

La colocalisation repose sur une correspondance temporelle à l'échelle journalière et sur une association spatiale par la méthode du plus proche voisin. Pour chaque ESU, ses coordonnées géographiques sont comparées aux coordonnées de la grille spatiale de chacune des variables environnementales. Le pixel dont les coordonnées sont les plus proches de celles de l'ESU est alors sélectionné. Cette recherche est effectuée indépendamment selon les dimensions de latitude et de longitude :

$$i_{\text{lon}} = \underset{i}{\operatorname{argmin}} |\text{lon}_{X,i} - \text{lon}_{\text{ESU}}| \quad (3.15)$$

et

$$i_{\text{lat}} = \underset{i}{\operatorname{argmin}} |\text{lat}_{X,i} - \text{lat}_{\text{ESU}}| \quad (3.16)$$

où $\text{lon}_{X,i}$ et $\text{lat}_{X,i}$ correspondent respectivement aux coordonnées de longitude et de latitude de la grille de la variable environnementale X considérée.

La valeur environnementale associée à chaque ESU est ensuite extraite au niveau du pixel correspondant aux indices sélectionnés :

$$X(i_{\text{lon}}, i_{\text{lat}}), \quad (3.17)$$

où X représente l'une des variables environnementales considérées (FTLE, PIG-MeANN ou FOD).

Cette procédure est appliquée indépendamment à chaque variable environnementale. Les données finales permettent ainsi d'associer, à chaque ESU acoustique, sa position géographique, sa date d'acquisition, sa valeur de NASC ainsi que les valeurs des différentes variables environnementales correspondantes (FTLE, PIGMeANN et FOD). Ce jeu de données colocalisé constitue la base des analyses par machine learning visant à étudier les relations entre la distribution acoustique des organismes et les caractéristiques de leur environnement.

3.2 Arbres de Régression

"Depending on the problem, the basic purpose of a classification/regression study can be either to produce an accurate classifier or to uncover the predictive structure of the problem." (classif. and regression trees p.6) Notre objectif ici est chercher à connaître la prédictibilité du NASC en fonction de la structure des communautés phytoplanctoniques, en lien avec l'activité de mésoéchelle. The goal is to understand the structural relationship between the response and the measured variables. (p.221)

3.2.1 CART

3.2.1.1 Description du modèle

3.2.1.2 Importance des variables

3.2.1.3 Compromis biais-variance

3.2.2 Random Forest

3.2.2.1 Description du modèle

3.2.2.2 Importance des variables

3.2.2.3 Compromis biais-variance

3.2.3 Extreme Gradient Boosting

3.2.3.1 Description du modèle

3.2.3.2 Importance des variables

3.2.3.3 Compromis biais-variance

3.2.4 Tuning, entraînement, validation et prédiction

4 Résultats

4.1 distrib interanuelles générales

description des distribs de ftle nasc et pigs au global

4.2 FOD

Description des caractéristiques des masses d'eau (profil T/S moyen) et mise en relation avec leur propriétés physico-chimique potentielles, la provenance de l'eau etc mise en lien des FOD avec la structuration couremment utilisée du SO (Tréguer et Jacques 1992 et Sullivan et al 1998 : SAZ, SSIZ, MIZ, CZ (climate drivers of SO, Krumhardt2022))

Description des conentrations de pigments par fod, est ce qu'il y a des tendances ? déplacement des communauté phyto ? NASC par fod ftle par fod

4.3 Cluster de pigments

Description des classes de pigments identification des communautés phyto selon la ref de Ziad (Influence of the phyto community nature 2025) Description des tendances interanuelle en terme de concentration Description de la régionalisation des cluster de pigs et des fod (intersection entre les 2 ?) déplacement des communauté phyto ? (distrib des fod par an par cluster) Description du NASC par cluster de pigment

4.4 Résultats des régressions

5 Discussion

5.1 Influence des fréquences

Les NTI sont des poissons pourvu ou non de vessies natatoire¹. (mettre dans la partie)

5.2 Complétion des NAs et influence sur le NASC

5.3 FOD : nombre de composante principale, données modèles, non prise en compte des données chimique (fer) et sea ice

5.4 définition de communauté phyto à partir des bio-optical water types

however an increase in chl-a is not necessarily associated with an increase in biomass, particularly in the iron light co-limited SO where phytoplankton can adjust their cellular chl-a to carbon ratios in response to environmental stresses [9] (pas la ref n°1) beaucoup de valeurs manquantes a cause de couverture nuageuse complétion possible des données avec des méthodes de deep learning

5.5 effet du temps sur les corrélations mésoéchelle/phyto/zoo

- : commu phyto/nasc : effet du time gap entre les distributions des deux pouvant masquer les corrélations. On sait qu'un bloom de phyto donne + de biomasse des NTI supérieurs, mais + tard

- ftle/phyto/nasc du modèle : critiques

1. organe permettant à l'organisme de contrôler sa flottaison

5.6 test statistiques : effet du nombre de données et dispersion sur la significativité, tendance vs climate change trend

30-40 years of PP data are necessary to distinguish a climate trend change (pas la ref n°1) [9]

5.7 Influence sur la prédiction : gradient latitudinal, overfit, déséquilibre de l'échantillonnage

gradient latitudinal = hypothèse de stationnarité de 1er et second ordre pas respecté, plots pour analyser cet effet overfit du RS et capacité de transfer learning (spatial nested cv) : plots effet du déséquilibre de l'échantillonnage sur les cartes de prédictions

5.8 Choix des variables prédictives, manque de variables

variance, distance geo par fold et capacité prédictives -> hypothèse de manque de variable prédictive

5.9 Interprétation de l'importance des variables

comment XGB et RF et CART n'ont pas les mêmes algos et comment ça peut en fait dire des choses différentes, méfiance sur l'interprétation, bien se renseigner (lire les articles)

5.10 Evaluation des performances prédictives du modèle

résistance aux valeurs manquantes résistance au bruit d'échantillonnage

6 Conclusion

7 Annexes

7.1 Stratification verticale et horizontale des océans




Figure 7.1 – Stratification verticale de l'eau selon la pénétration de la lumière et de la pression, stratification horizontale selon la distance au plateau continental [3].

7.2 Réponse fréquentielle des organismes pélagiques




Figure 7.2 – Réponse fréquentielle des organismes pélagiques selon la fréquence de l'onde émise [17]

7.3 Valeurs manquantes sur le volume de rétropropagation acoustique S_v en fonction de la profondeur et de la fréquence de l'échosondeur




Figure 7.3 – Valeurs manquantes du coefficient de rétrodiffusion volumique S_v en fonction de la profondeur, pour les fréquences de fonctionnement de l'échosondeur de 38 kHz et 120 kHz.

7.4 Propriétés des B-Splines de degré m : Support, positivité et régularité

La B-spline $\phi_{i,m}(x)$ est un polynôme par morceau de degré m (et d'ordre $m + 1$) avec des points de rupture (noeuds) $\tau_i, \dots, \tau_{i+m+1}$ et les propriétés suivantes :

- Continuité : $\phi_{i,m}(x) \in C^{m-1}$ aux noeuds (les dérivées jusqu'à l'ordre $m - 1$ sont continues sur les noeuds). Pour une B-spline cubique ($m = 3$), $\phi_{i,3} \in \mathcal{C}^2$,
- Support compact : $\text{supp}(\phi_{i,m}) = [\tau_i, \tau_{i+m+1}]$, donc $\langle \phi_{i,m}, \phi_{j,m} \rangle = 0$ si $|i - j| \geq m + 1$.
- Positivité : $\phi_{i,m}(x) > 0$ sur (τ_i, τ_{i+m+1}) et $\phi_{i,m}(x) = 0$ sinon.

7.5 Influence du nombre de composantes principales sur la reconstruction des profils de température et salinité

PC	Eigenvalue	Prop. variance	Cumulative variance
1	981.66665873	0.9810935	0.9810935
2	12.52661452	0.0125193	0.9936128
3	4.16020812	0.0041578	0.9977705
4	0.92707153	0.0009265	0.9986971
5	0.56820781	0.0005679	0.9992649
6	0.41429271	0.0004141	0.9996790
7	0.13458956	0.0001345	0.9998135
8	0.05806269	0.0000580	0.9998715
9	0.05427009	0.0000542	0.9999258
10	0.02370249	0.0000237	0.9999495

Table 7.1 – Valeurs propres et variance expliquée par les composantes principales.




Figure 7.4 – Effet du nombre de composantes principales k sur la qualité de reconstruction des profils de température et salinité. Un nombre de PC permettant d'obtenir une variance expliquée > 0.99 ne permet pas nécessairement une reconstruction correcte des profils.

Liste d'abréviations

lon : Longitude lat : Latitude PSC : Phytoplankton Size Class (Classe de Taille du Phytoplankton) PFT : Phytoplankton Functional Type (Type fonctionnel de Phytoplankton) NASC : Nautical Area Scattering Coefficient (Coefficient de rétropropagation d'aire Nautique) ROI : Region Of Interest (Région d'intérêt) ESU : Elementary Sampling Unit (unité élémentaire d'échantillonnage)

Liste de symboles

Liste des figures et tableaux

Bibliographie

- [1] Michèle FIEUX. *L'Océan planétaire*. 2^e éd. Les Presses de l'ENSTA, 2019. ISBN : 978-2-7225-0960-3.
- [2] G. Evelyn HUTCHINSON. « Concluding Remarks ». In : *Cold Spring Harbor Symposia on Quantitative Biology* 22 (1957), p. 415-427. DOI : 10.1101/SQB.1957.022.01.039.
- [3] Frances DIPPER. « The seawater environment and ecological adaptations ». In : *Elements of Marine Ecology*. 5^e éd. Oxford : Butterworth-Heinemann, 2022, p. 37-151. DOI : 10.1016/B978-0-08-102826-1.00002-8.
- [4] Scott C. DONEY et al. « Climate Change Impacts on Marine Ecosystems ». In : *Annual Review of Marine Science* 4 (2012), p. 11-37. DOI : 10.1146/annurev-marine-041911-111611.
- [5] Jean-Baptiste SALLÉE. « Southern Ocean Warming ». In : *Oceanography* 31.2 (juin 2018), p. 52-62. DOI : 10.5670/oceanog.2018.215.
- [6] Suhas SHETYE, Rahul MOHAN et Abhilash NAIR. « Latitudinal shifts in the Polar Front in Indian sector of the Southern Ocean : evidences from silicoflagellate assemblage ». In : *Geosciences Journal* 18.2 (déc. 2013), p. 241-246. DOI : 10.1007/s12303-013-0061-8.
- [7] Nurmalia ADROLI et al. « Southern Ocean regime shift : divergent trends in surface phytoplankton community composition using a diagnostic pigment framework ». In : *Nature Communications* 17.1 (juill. 2026), p. 8607. DOI : 10.1038/s41467-026-75303-2.
- [8] Alexander HAYWARD et al. « Climate driven shifts in Antarctic phytoplankton groups : Implications of widespread diatom decline ». In : *Research Square* (2024). DOI : 10.21203/rs.3.rs-5188031/v1.
- [9] Sandy J. THOMALLA et al. « Widespread changes in Southern Ocean phytoplankton blooms linked to climate drivers ». In : *Nature Climate Change* 13.9 (2023), p. 975-984. DOI : 10.1038/s41558-023-01768-4.
- [10] Nerilie J. ABRAM et al. « Emerging evidence of abrupt changes in the Antarctic environment ». In : *Nature* 644.8077 (2025), p. 621-633. DOI : 10.1038/s41586-025-09349-5.

- [11] Ziad SARI EL DINE. *Regional Algorithm for Estimating Southern Ocean Phytoplankton Pigments : Multi-spectral Machine Learning Approach*. Presentation at the Atelier #7 CES Couleur de l'Océan. Presentation given on 17 March 2026. Nantes, France : ODATIS, mars 2026.
- [12] Ziad SARI EL DINE et al. « Influence of the phytoplankton community structure on the southern elephant seals' foraging activity within the Southern Ocean ». In : *Communications Biology* 8.1 (2025), p. 620. DOI : 10.1038/s42003-025-08049-0.
- [13] Asta C. HEIDEMANN et al. « Drivers of phytoplankton distribution, abundance and community composition off East Antarctica, from 55–80°E (CCAMLR Division 58.4.2 East) ». In : *Frontiers in Marine Science* 11 (2024), p. 1454421. DOI : 10.3389/fmars.2024.1454421.
- [14] COPERNICUS MARINE SERVICE. *What are the services and content provided by the Copernicus Marine Service ?* Copernicus Marine Help Center. Accessed September 6, 2026. 2026. URL : <https://help.marine.copernicus.eu/en/articles/5046713-what-are-the-services-and-content-provided-by-the-copernicus-marine-service>.
- [15] Shawn C. SHADDEN, Francois LEKIEN et Jerrold E. MARSDEN. « Definition and properties of Lagrangian coherent structures from finite-time Lyapunov exponents in two-dimensional aperiodic flows ». In : *Physica D : Nonlinear Phenomena* 212.3–4 (2005), p. 271-304. DOI : 10.1016/j.physd.2005.10.007.
- [16] Francesco D'OVIDIO et al. « Mixing structures in the Mediterranean Sea from finite-size Lyapunov exponents ». In : *Geophysical Research Letters* 31 (2004), p. L17203. DOI : 10.1029/2004GL020328.
- [17] Kelly J. BENOIT-BIRD et Gareth L. LAWSON. « Ecological Insights from Pelagic Habitats Acquired Using Active Acoustic Techniques ». In : *Annual Review of Marine Science* 8.1 (2016), p. 463-490. DOI : 10.1146/annurev-marine-122414-034001.
- [18] K. HARIS et al. « Sounding out life in the deep using acoustic data from ships of opportunity ». In : *Scientific Data* 8.1 (2021), p. 23. DOI : 10.1038/s41597-020-00785-8.
- [19] FLOTTE OCÉANOGRAPHIQUE FRANÇAISE. *Campagnes océanographiques*. URL : <https://campagnes.flotteoceanographique.fr/campaign> (visité le 06/09/2026).
- [20] INSTITUT DE RECHERCHE POUR LE DÉVELOPPEMENT (IRD). *MATECHO User Manual*. Version 03. Laboratory : UMR LEMAR. UMR LEMAR. Plouzané, France.

- [21] Nadège FONVIELLE. « Structure des paysages océaniques tridimensionnels par l'analyse de données issues d'éléphants de mer du Sud ». Thèse de doctorat. Marseille, France : Aix-Marseille Université, sept. 2024.
- [22] Carl de BOOR. « A Practical Guide to Splines ». In : Revised Edition. New York : Springer, 2001. Chap. B-splines, p. 87.
- [23] Paul H. C. EILERS et Brian D. MARX. « Flexible Smoothing with B-splines and Penalties ». In : *Statistical Science* 11.2 (mai 1996), p. 89-102. DOI : 10.1214/ss/1038425655.
- [24] Matthew P. WAND et John T. ORMEROD. « On Semiparametric Regression with O'Sullivan Penalized Splines ». In : *Australian & New Zealand Journal of Statistics* 50.2 (2008), p. 179-198. DOI : 10.1111/j.1467-842X.2008.00507.x.
- [25] Christopher M. BISHOP. *Pattern Recognition and Machine Learning*. Information Science and Statistics. New York : Springer, 2006. ISBN : 978-0-387-31073-2.
- [26] Luca SCRULLA et al. « mclust 5 : Clustering, Classification and Density Estimation Using Gaussian Finite Mixture Models ». In : *The R Journal* 8.1 (2016), p. 289-317.
- [27] Chris FRALEY et Adrian E. RAFTERY. « Model-Based Clustering, Discriminant Analysis, and Density Estimation ». In : *Journal of the American Statistical Association* 97.458 (2002), p. 611-631.
- [28] Marius MOLINET et al. « Linking oceanographic conditions to foraging behaviour of southern elephant seals by characterising mid-trophic levels with an animal-borne echosounder ». In : *Journal of Marine Systems* (2025).