

UNIVERSITÉ PARIS CITÉ

Département de mathématiques et d'informatique

**Comment la structure des communautés
phytoplanctoniques influence t-elle la distribution du
zooplancton et du micronecton ?**

Une étude dans le secteur Indien de l'Océan Austral

Rapport de stage

Résumé

Rapport réalisé par

Elise NICOLAS

Encadrants

Marius MOLINET, David NERINI, Christophe GUINET, Cédric
COTTE

Professeure référente

FISHER Aurélie

Table des matières

1	Introduction	3
1.1	Généralités	3
1.2	Secteur Indien de l’Océan Austral	6
1.2.1	Contexte physico-chimique de la région	6
1.2.2	Contexte biologique	7
1.2.3	Et dans un contexte de changement climatique?	7
1.3	Question scientifique	8
1.4	il manque	8
2	Matériel	10
2.1	Données Pigmentaires (PIGMeANN)	10
2.2	Données hydrologiques (Copernicus)	10
2.3	Données hydrodynamiques : FTLE	10
2.4	Données d’acoustique active (OBSAUSTRAL)	10
3	Méthode	11
3.1	Pré-traitement des données	11
3.1.1	Calcul du NASC	11
3.1.2	Calcul des Functional Oceanographic Domain (FOD)	11
3.1.3	Filtrage des pigments	21
3.1.4	Colocalisation NASC/PIG/FTLE/FOD	21
3.2	Arbres de Régression	21
3.2.1	CART	21
3.2.2	Random Forest	21
3.2.3	Extreme Gradient Boosting	21
3.2.4	Tuning, entraînement, validation et prédiction	21
4	Résultats	22
4.1	distrib interanuelles générales	22
4.2	FOD	22
4.3	Cluster de pigments	22
4.4	Résultats des régressions	22

5	Discussion	23
5.1	Influence des fréquences	23
5.2	Complétion des NAs et influence sur le NASC	23
5.3	FOD : nombre de composante principale, données modèles, non prise en compte des données chimique (fer) et sea ice	23
5.4	définition de communauté phyto à partir des bio-optical water types . .	23
5.5	effet du temps sur les corrélations mésoéchelle/phyto/zoo/nti	23
5.6	test statistiques : effet du nombre de données et dispersion sur la significativité, tendance vs climate change trend	24
5.7	Influence sur la prédiction : gradient latitudinal, overfit, déséquilibre de l'échantillonnage	24
5.8	Choix des variables prédictives, manque de variables	24
5.9	Interprétation de l'importance des variables	24
5.10	Evaluation des performances prédictives du modèle	24
6	Conclusion	25
7	Annexes	26
7.1	Propriétés des B-Splines de degré m : Support, positivité et régularité .	26
7.2	Stratification verticale et horizontale des océans	26
7.3	Distribution verticale des valeurs manquantes des ESU	27
7.4	Influence du nombre de composantes principales sur la reconstruction des profils de température et salinité	27

1 Introduction

1.1 Généralités

L'**océan** couvre 70% de la surface terrestre. La répartition des terres émergées n'est pas équivalente selon les deux hémisphères : l'hémisphère Sud est composé à 80.9% de mer, contre 60.7% pour l'hémisphère Nord. Dans l'hémisphère Sud, dans le bassin Antarctique, les océans Atlantique, Pacifique et Indien se connectent. Une seule masse d'eau liquide se déplace alors dans les différents bassins. L'océan est un **milieu continu**.




Figure 1.1 – Illustration de l'Océan Austral et de la connexion entre tous les océans ([1])

Un **biotope** correspond à l'espace physique et les conditions abiotiques associées dans lesquelles vit une biocénose. Une **biocénose** est l'ensemble des populations d'organismes qui occupent une zone donnée et interagissent entre elles. L'océan étant un milieu continu, seuls la distance géographique et les paramètres physiques de l'eau (abiotiques) conditionnent la régionalisation en biotopes. La connaissance des paramètres physiques de l'eau est donc particulièrement importante pour l'étude des distributions des organismes et **niches écologiques**¹ marines.

1. **Niche écologique** : ensemble des conditions environnementales permettant à une espèce de survivre et de se reproduire [2].

Les principaux **paramètres abiotiques** structurant les écosystèmes sont : les propriétés hydrologiques et hydrodynamiques de l'eau, la pression et la lumière [3]. Les **propriétés hydrologiques** (température, salinité, composition chimique) de l'eau dépendent du climat : la chaleur et le vent induisent une évaporation rendant l'eau de mer plus salée, les précipitations induisent un adoucissement de la salinité. La composition chimique de l'eau de mer est fortement dépendante des apports du littoral (fer, nitrates, etc). **L'hydrodynamisme** inclue les marées et les divers courants induits par des gradients de température, de pressions. Ces derniers dépendent majoritairement du vent et de l'ensoleillement. **L'éclairement** (intensité et spectre) est structuré verticalement selon la profondeur à cause des propriétés d'absorption de l'eau (Annexe 7.2, figure 7.1). On parle de milieu eutrophe (épipelagique) entre 0 et 200m, de milieu dysphotique (mésopélagique) entre 200 et 1000m, de milieu aphotique (bathypélagique) entre 1000 et 4000m et de milieu abyssal au delà de cette dernière. La pression croît avec la profondeur et une stratification arbitraire est également appliquée selon cette variable (Annexe 7.2, figure 7.1). La proximité au littoral participant grandement à la modification de ces paramètres abiotiques, on sépare arbitrairement l'océan horizontalement selon sa distance au plateau continental. On parle de **zone pélagique** au delà du plateau continental. Le contexte actuel de changement global induit des modifications importantes de l'expression de ces paramètres et induit en conséquence des changements de structuration des écosystèmes océaniques [4], [5].

L'écologie est une discipline qui s'intéresse aux interactions entre les différentes espèces d'un même biotope. Parmi elles, les **relations trophiques** (alimentaires) jouent un rôle fondamentale dans la structuration des écosystèmes (figure 1.2).




Figure 1.2 – Schéma du réseau trophique océanique [3].

Les **producteurs primaires** supportent tout le réseau trophique. Leur capacité à transformer la matière inorganique en matière organique (organismes autotrophes) les positionnent à la base du réseau. En effet, de nombreux organismes (hétérotrophes) n'ont pas cette capacité et dépendent uniquement des apports organiques de leur alimentation pour survivre. Le producteur primaire du milieu pélagique est le **phytoplancton**. Ce terme désigne tous les organismes végétaux ("*phyto*") n'ayant pas la capacité de se déplacer contre le courant ("*plancton*"). Ce sont des organismes **photo-autotrophes**, c'est-à-dire, qu'ils peuvent soutenir leur métabolisme uniquement grâce à l'énergie lumineuse. Le processus bio-chimique permettant la transformation de l'énergie lumineuse en énergie chimique utilisable par le métabolisme est la **photosynthèse**. Ce processus nécessite la présence de **pigments photosynthétiques** chez les organismes l'effectuant. Les **consommateurs primaires** sont les organismes s'alimentant des producteurs primaires. Dans le contexte du milieu pélagique, c'est le **zooplancton**² et le **micronecton**³. Les **niveaux trophiques intermédiaires** sont tous les étages de la chaîne alimentaire, correspondent à tous les organismes situés entre les producteurs primaires et les prédateurs supérieurs (dernier niveau du réseau trophique).

2. "*Zoo*" : animal, "*Plancton*" : n'ayant pas la possibilité de se déplacer à contre-courant.

3. Petits poissons pélagiques.




Figure 1.3 – Positions moyennes du Front subtropical (STF), du Front subantarctique (SAF), du Front sud du Courant circumpolaire antarctique (SACCF), de la Divergence antarctique (AD), ainsi que des trois gyres cycloniques du bassin de Weddell-Enderby, du bassin Antarctique-Australien et de la mer de Ross [1].

1.2 Secteur Indien de l’Océan Austral

L’océan Austral (ou Antarctique) forme un anneau autour de l’Antarctide. Il représente 22% de la surface totale des océans. Contrairement aux autres océans, il n’est pas délimité par des frontières continentales. En regardant une carte (voir figure 1.1), on pourrait penser qu’il est simplement la prolongation du bassin Atlantique, Pacifique et Indien. En réalité, il est délimité par une frontière océanographique : le Front Subtropical (approximativement à 40°S), caractérisé par de très forts gradients de températures (figure 1.3). L’océan Austral se distingue également des autres océans par l’uniformité de son climat, de son hydrodynamisme et de ses propriétés hydrologiques.

parler du sous échantillonnage de la région, de sa vasteté et de son importance dans le carbon uptake etc

1.2.1 Contexte physico-chimique de la région

Le secteur indien de l’Océan Austral est situé entre 20° et 80°E de longitude et s’étend de 30° à 70°S de latitude (figure 1.3, 1.4). Dans notre étude, la région d’intérêt (ROI) correspond au secteur Indien restreint en longitude (45-90°E, 30-60°S). Cette zone est caractérisée par plusieurs éléments : un fort gradient latitudinal de température, des changements bathymétriques importants (plateau de Crozet) et un fort hydrodynamisme (Courant des Agulhas, front subtropical, front subantarctique, front polaire) (voir figure 1.4).

parler du faible éclaircissement, des concentrations en fer nitrates etc limitante, de la couverture de glace et de l'apport en fer de kerguelen




Figure 1.4 – Carte du secteur Indien de l’Océan Austral et des courants [6]

1.2.2 Contexte biologique

D’un point de vue écologique, le réseau trophique de la région contient peu de niveaux. Le producteur primaire du milieu pélagique est le phytoplancton. Les communautés phytoplanctoniques⁴ sont structurées selon un axe latitudinal. **recherches sur les structures phytoplanctoniques de base** Les consommateurs primaires sont le zooplancton et le micronecton. Plus particulièrement, la région est marquée par une forte abondance de Krill et d’euphosiacés. **parler des communautés phyto observées (pcq plus tard on présentera les chgms) la forte productivité primaire de la région et de la forte saisonnalité**

Les prédateurs supérieurs sont les éléphants de mer, manchots,..

1.2.3 Et dans un contexte de changement climatique ?

Dans un contexte de changement global, les caractéristiques physico-chimiques de l’eau et de l’atmosphère changent également. Des études récentes ont annoncé par exemple des changements de régime de vent, une diminution de la profondeur de la couche de mélange⁵, une altération des courants de circulation, une migration au sud du front polaire, un réchauffement de la température de surface, un changement du flux du fer et des changements dans la proportion de couverture de la glace induisant une diminution de la salinité de l’eau (adoucissement). [5],

4. Composition taxonomique en phytoplancton du milieu

5. text

Ces changements affectent les organismes habitant ces milieux, comme le phytoplancton. Des études récentes font l'hypothèse d'une augmentation de la production primaire totale et d'une restructuration des communautés phytoplanctonique ([7] : la contribution relative des diatomées dans la production primaire diminuerait. Au contraire, la contribution relative des haptophytes et des cryptophytes (nano/picophytoplankton ?) [8]

+ des changements de temporalité des blooms et de leur durée et amplitude (être + précise dans quel sens) [9]

6

développer les observations de ces changements et les hypothèses + long terme

développer les hypothèses sur les effets sur les NTI (trophic cascade) changements de temporalité/durée/amplitude des blooms => dictate the amount of biomass being generated within a season that can be exported to the ocean's interior or transferred to higher trophic levels [9]

1.3 Question scientifique

Ce projet de recherche s'intéresse à l'influence du type phytoplanctonique sur les niveaux trophiques intermédiaires du secteur Indien de l'Océan Austral

1.4 il manque

RESTREINDRE LES HYPOTHESES A L'ETE et a la ROI si possible
la présence de l'importance de l'atmosphère dans les params physicochimique (vent mixing water, increase in CO₂, more clouds = less light, etc) l'importance du so dans le contexte de changement global (carbon uptake, ..) réseau trophique + détaillé du so
Le changement climatique dans l'océan austral phytoplancton du so : énorme vers kerguelen, limité par lumière et iron Les changements de commu phyto observés Les hypothèses de changements /les changements observés dans les niveaux trophiques supérieurs (étude avec le carbone, article de ziad) : ramifications trophodynamique (southern ocean in a changing climate, climate drivers of so phytoplankton community)
hypothèses claires des changements physiques de la zone (changement de flux d'iron (avec sea ice zone différentes) , chgmt de régime de vent, stratification, chgmt de mld (decreased), stratification alteration des pattern de circulation, southward migration of ocean fronts, increase in sst, changes in sea ice cover) hypothèses claires des changements

6. "In marine climate systems, a regime shift refers to a persistent reorganisation of physical and ecological system structure, variability and feedback processes that results in a transition toward a new dominant state rather than a short term interannual fluctuation [10]

de commu phyto induits (augmentation chla totale diminution contribution des diatoms, auglntation de contribution des petits phyto) hypothèses claires des changements de nti induits (ramification)

2 Matériel

2.1 Données Pigmentaires (PIGMeANN)

article ziad Influence of the phytoplankton community structure on the southern elephant seals nature

2.2 Données hydrologiques (Copernicus)

2.3 Données hydrodynamiques : FTLE

2.4 Données d'acoustique active (OBSAUSTRAL)

3 Méthode

3.1 Pré-traitement des données

3.1.1 Calcul du NASC

3.1.2 Calcul des Functional Oceanographic Domain (FOD)

3.1.2.1 Présentation des Domaines Océanographiques Fonctionnels

Les Domaines Océanographiques Fonctionnels (ou Functional Oceanographic Domain) sont des masses d'eau ayant des caractéristiques thermohalines similaires. La méthode d'identification des FOD a été développée par Fonvieille N. et Nerini D. [11]. Les données thermohalines (des modèles de Copernicus dans notre cas) sont, dans un premier temps (1), estimées dans un espace fonctionnel par projection sur une base de B-spline. Dans un second temps (2), la dimension de la matrice des coefficients de pondération des B-splines est réduite par une Analyse par Composante Principale (ACP ou PCA en anglais). Dans un dernier temps (3), un clustering (GMM) est appliqué à cette nouvelle matrice de coefficients de pondération des B-splines. Ces trois étapes seront développées dans les paragraphes suivants.

3.1.2.2 Estimation fonctionnelle sur des bases de B-splines Estimation semi-paramétrique des profils de température et salinité

Basis-splines de degré m [12]

Les Basis-splines (B-splines) peuvent servir de base pour l'estimation par projection (estimation semi-paramétrique ou fonctionnelle). Ce sont des fonctions à support local pouvant être définies par la récurrence de Cox-de-Boor [12] :




Figure 3.1 – Illustration d’une B-spline isolée et de B-splines chevauchantes, de degré 1 (a) et de degré 2 (b) [13]

Soit $\phi_{i,m}(x)$ la B-spline de degré m dont le support est $\text{supp}(\phi_{i,m}(x)) = [\tau_i, \tau_{i+m+1}]$. Avec $\tau_i, \dots, \tau_{i+m+1}$ les noeuds (équi-espacés ou non). On peut définir la B-spline $\phi_{i,m}(x)$ comme suis [12] :

1. Initialisation d’une fonction porte par noeud (degré 0, ordre 1)

$$\phi_{i,0}(x) = \begin{cases} 1 & \text{si } \tau_i \leq x < \tau_{i+1} \\ 0 & \text{sinon} \end{cases} \quad (3.1)$$

2. Réccurence : combinaison convexe de B-splines de degré inférieur à deux noeuds consécutifs

$$\phi_{i,m}(x) = \omega_{i,m}(x) \phi_{i,m-1}(x) + (1 - \omega_{i+1,m}(x)) \phi_{i+1,m-1}(x) \quad (3.2)$$

avec

$$\omega_{j,m}(x) := \frac{x - \tau_j}{\tau_{j+m} - \tau_j}, \forall j \quad (3.3)$$

(le poids de chaque terme est normalisé par le support de la B-spline de degré $m-1$ qu’il pondère : $\text{supp}(\phi_{i,m-1}) = [\tau_i, \tau_{i+m}]$ et $\text{supp}(\phi_{i+1,m-1}) = [\tau_{i+1}, \tau_{i+1+m}]$).

Espace des splines et base de B-splines

Soit $\tau = (\tau_1, \dots, \tau_{2m+L+2})$ une suite de noeuds définie par

$$\underbrace{a = \tau_1 = \tau_2 = \dots = \tau_{m+1}}_{m+1 \text{ noeuds répétés en } a} < \underbrace{\tau_{m+2} < \dots < \tau_{m+L+1}}_{L \text{ noeuds intérieurs}} < \underbrace{\tau_{m+L+2} = \dots = \tau_{2m+L+2} = b}_{m+1 \text{ noeuds répétés en } b} \quad (3.4)$$

On note $\mathbb{S} * m, \tau$ l’espace des fonctions splines de degré m associées à cette suite de noeuds. Une spline $f \in \mathbb{S} * m, \tau$ est une fonction polynomiale par morceaux de degré au plus m , définie sur les intervalles délimités par les noeuds τ , et satisfaisant les conditions de continuité imposées par les multiplicités des noeuds (Voir Annexe 7.1)..

Les B-splines de degré m associées à la suite de noeuds τ , notées $\{\phi_{i,m}\}_{i=1}^{L+m+1}$ constituent une base de l'espace $\mathbb{S}_{m,\tau}$ ($\dim(\mathbb{S}_{m,\tau}) = L + m + 1$).

Par conséquent, toute fonction spline $f \in \mathbb{S}_{m,\tau}$ peut s'écrire de manière unique comme une combinaison linéaire des B-splines :

$$f(x) = \sum_{i=1}^{L+m+1} \alpha_i \phi_{i,m}(x), \quad \alpha_i \in \mathbb{R}. \quad (3.5)$$

Estimation fonctionnelle par minimisation des moindres carrés pénalisée (O-Splines) [14], [13]

Appliquons maintenant ce cadre à l'estimation fonctionnelle des profils de température et de salinité. Soit l un indice spatio-temporel (combinaison d'un instant, d'une longitude et d'une latitude) et $v \in T, S$ la variable considérée. Le profil brut $\mathbf{v}_l \in \mathbb{R}^{n_{depths}}$ correspond aux valeurs de v issues du modèle Copernicus aux profondeurs discrètes $z_1, \dots, z_{n_{depths}}$. On suppose que ces observations proviennent de l'évaluation d'une fonction sous-jacente f_l aux profondeurs considérées :

$$v_l(z_k) = f_l(z_k) + \varepsilon_k, \quad k = 1, \dots, n_{depths}, \quad (3.6)$$

où ε_k représente le terme d'erreur associé à l'observation du profil à la profondeur z_k .

L'objectif est d'estimer f_l sur l'intervalle de profondeur $[a, b]$, qui correspond ici à $[20, 500]$ m. On cherche pour cela une approximation $\hat{f}_l \in \mathbb{S}_{m,\tau}$ sous la forme d'une combinaison linéaire des B-splines définies précédemment :

$$\hat{f}_l(z) = \sum_{i=1}^K \alpha_{l,i} \phi_{i,m}(z), \quad K = L + m + 1. \quad (3.7)$$

où L désigne le nombre de noeuds intérieurs et K le nombre total de B-splines. Les coefficients $\boldsymbol{\alpha}_l = (\alpha_{l,1}, \dots, \alpha_{l,K})^\top$ déterminent ainsi entièrement la spline estimée pour le profil l . Pour un profil donné, les coefficients $\boldsymbol{\alpha}_l$ sont déterminés en minimisant l'erreur d'ajustement entre les observations et la spline. La fonction objectif des moindres carrés est

$$S_l = \sum_{k=1}^{n_{depths}} \left(v_l(z_k) - \hat{f}_l(z_k) \right)^2 \quad (3.8)$$

$$= \sum_{k=1}^{n_{depths}} \left(v_l(z_k) - \sum_{i=1}^K \alpha_{l,i} \phi_{i,m}(z_k) \right)^2. \quad (3.9)$$

Cependant, lorsque le nombre de noeuds est élevé, l'ajustement peut devenir excessivement flexible et conduire à un sur-ajustement (*overfitting*). Afin de contrôler la

complexité de la fonction estimée, on introduit une pénalisation de sa rugosité¹. La matrice de pénalisation Ω est définie par

$$\Omega_{i,j} = \int_a^b \phi''_{i,m}(z) \phi''_{j,m}(z) dz, \quad 1 \leq i, j \leq K. \quad (3.10)$$

Le critère pénalisé à minimiser pour le profil l est alors

$$S_{l,\lambda} = \underbrace{\sum_{k=1}^{n_{depths}} \left(v_l(z_k) - \sum_{i=1}^K \alpha_{l,i} \phi_{i,m}(z_k) \right)^2}_{\text{erreur d'ajustement}} + \lambda \underbrace{\alpha_l^\top \Omega \alpha_l}_{\text{pénalisation de la rugosité}}. \quad (3.11)$$

où $\lambda \geq 0$ est le paramètre de lissage contrôlant le compromis entre fidélité aux observations et régularité de la fonction estimée. Dans notre cas, le nombre de splines K et le paramètre de lissage λ ont été choisis par validation croisée leave-one-out (CV-LOO). On trouve $\lambda = 0.25$ pour $K = 25$ splines




Figure 3.2 – Estimation fonctionnelle des profils de Température/Salinité ($\lambda = 0.25$, $K = 25$) issu de Copernicus (E.U. Copernicus Marine Service Information (CMEMS). Global Ocean Physics Reanalysis. Marine Data Store (MDS). DOI : 10.48670/moi-00021) le 2023-01-26 aux coordonnées 450E,-60°N.

1. mesure le degré d'irrégularité d'une fonction, est quantifié par l'intégrale du carré de sa dérivée seconde

3.1.2.3 Réduction de dimension par Analyse en Composante Principale

Suite à l'estimation fonctionnelle réalisée à l'étape précédente, chaque profil l est désormais représenté par un couple de fonctions de la profondeur, la température et la salinité, estimées sur la même base de B-splines $(\Phi_k)_{1 \leq k \leq K}$ définie sur $[d_{min}, d_{max}]$:

$$T_l(z) = \sum_{k=1}^K \alpha_{l,k}^T \Phi_k(z), \quad S_l(z) = \sum_{k=1}^K \alpha_{l,k}^S \Phi_k(z), \quad z \in [d_{min}, d_{max}]$$

On considère alors chaque profil comme une observation **bivariée** $X_l = (T_l, S_l) \in \left(L^2([d_{min}, d_{max}])\right)^2$, muni du produit scalaire

$$\langle (f_1, g_1), (f_2, g_2) \rangle = \langle f_1, f_2 \rangle_{L^2} + \langle g_1, g_2 \rangle_{L^2}$$

L'objectif de cette étape est de réduire conjointement la dimension des profils de température et de salinité, afin de capturer les modes de variabilité communs aux deux variables.

Une approche pour réduire la dimension des données est l'analyse par composante principale (ACP ou PCA pour Principal Component Analysis). Puisque les données sont dans un espace fonctionnel $\mathbb{S}_{m,\tau}$, on parle alors d'Analyse par Composante Principale *fonctionnelle* (ACPf ou FPCA). La logique est identique à celle d'une PCA classique mais les outils sont adaptés pour manipuler les fonctions. Ici, la fPCA est réalisée conjointement sur les deux variables, on parle de fPCA bivariée.

Construction du vecteur de coefficients bivarié

Pour chaque profil l , on concatène les coefficients de B-spline de température et de salinité en un unique vecteur $\alpha_l \in \mathbb{R}^{2K}$:

$$\alpha_l = \begin{pmatrix} \alpha_l^T \\ \alpha_l^S \end{pmatrix}, \quad \alpha_l^T = (\alpha_{l,1}^T, \dots, \alpha_{l,K}^T)^\top, \quad \alpha_l^S = (\alpha_{l,1}^S, \dots, \alpha_{l,K}^S)^\top$$

En empilant les N profils, on obtient la matrice $\alpha \in \mathbb{R}^{N \times 2K}$.

Centrage des données

Soit $\bar{\alpha} \in \mathbb{R}^{2K}$ la moyenne empirique, sur l'ensemble des N profils, des coefficients de chaque B-spline pour la partie température et pour la partie salinité :

$$\bar{\alpha} = \frac{1}{N} \sum_{l=1}^N \alpha_l$$

On obtient ainsi les coefficients bivariés centrés $\tilde{\alpha} = \alpha_l - \bar{\alpha}$, avec $\tilde{\alpha} \in \mathbb{R}^{N \times 2K}$. Pour

$l \in N$:

$$\tilde{\alpha}_l = \begin{pmatrix} \tilde{\alpha}_l^T \\ \tilde{\alpha}_l^S \end{pmatrix} \in \mathbb{R}^{2K}$$

Calcul de la covariance empirique

On définit la matrice bivariée de fonctions de base $\Phi(z) \in \mathbb{R}^{2 \times 2K}$ comme la concaténation de la base Φ utilisée pour chacune des deux composantes :

$$\Phi(z) = \begin{pmatrix} \Phi(z)^\top & 0 \\ 0 & \Phi(z)^\top \end{pmatrix} \in \mathbb{R}^{2 \times 2K},$$

de sorte que le profil bivarié centré s'écrit $\tilde{X}_l(z) = \Phi(z)\tilde{\alpha}_l = \begin{pmatrix} \tilde{T}_l(z) \\ \tilde{S}_l(z) \end{pmatrix}$.

La covariance empirique entre deux profondeurs s et t est alors une matrice 2×2 donnée par

$$\hat{V}(s, t) = \frac{1}{N} \sum_{l=1}^N \tilde{X}_l(s) \tilde{X}_l(t)^\top.$$

En introduisant la matrice de covariance empirique des coefficients

$$C = \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} \in \mathbb{R}^{2K \times 2K},$$

on obtient

$$\boxed{\hat{V}(s, t) = \Phi(s) C \Phi(t)^\top.}$$

Cette matrice contient à la fois les covariances intra-variables, correspondant aux blocs température-température et salinité-salinité, et les covariances croisées température-salinité.

Décomposition en valeurs propres et vecteurs propres de la matrice de covariance

On effectue la décomposition spectrale de l'opérateur de covariance $\hat{V}$:

$$\int \hat{V}(s, t) \xi(t) dt = \rho \xi(s)$$

avec la contrainte d'orthonormalité des fonctions propres bivariées : $\|\xi\|_{L^2} = 1$ et $\langle \xi_i, \xi_j \rangle = 0$ si $i \neq j$.

On fait l'hypothèse que la fonction propre bivariée $\xi(t)$ se décompose dans la même

base bivariée que nos profils :

$$\xi(t) = \Phi^\top(t) b, \quad b \in \mathbb{R}^{2K}$$

On a alors :

$$\begin{aligned} \int \hat{V}(s, t) \xi(t) dt &= \int \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} \Phi(t) \Phi^\top(t) b dt \\ &= \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} \underbrace{\int \Phi(t) \Phi^\top(t) dt}_=W b \\ &= \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} W b \end{aligned}$$

où $W = \int \Phi(t) \Phi^\top(t) dt \in \mathbb{R}^{2K \times 2K}$ est la matrice de Gram de la base bivariée. Comme $\Phi(t)$ répète deux fois la même base $\Phi(t)$, W prend la forme bloc-diagonale

$$W = \begin{pmatrix} W_0 & 0 \\ 0 & W_0 \end{pmatrix}, \quad W_0 = \int \Phi(t) \Phi^\top(t) dt \in \mathbb{R}^{K \times K}$$

les blocs hors-diagonale étant nuls car la partie température et la partie salinité de ξ n'interagissent qu'au travers de la covariance des coefficients $\tilde{\alpha}^\top \tilde{\alpha}$, pas au travers de la base elle-même.

On peut donc réécrire la décomposition spectrale comme suit :

$$\begin{aligned} \int \hat{V}(s, t) \xi(t) dt &= \rho \xi(s) \\ \iff \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho \Phi^\top(s) b \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho b \end{aligned}$$

La matrice $\tilde{\alpha}^\top \tilde{\alpha}$ est symétrique (c'est un produit de la forme $A^\top A$), mais le produit $\tilde{\alpha}^\top \tilde{\alpha} W$ ne l'est pas en général : le problème aux valeurs propres n'est donc pas directement résoluble par une décomposition spectrale standard. Pour contourner ce problème, on utilise le changement de variable $b = W^{-\frac{1}{2}} u$:

$$\begin{aligned} \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho b \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W W^{-\frac{1}{2}} u &= \rho W^{-\frac{1}{2}} u \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W^{\frac{1}{2}} u &= \rho W^{-\frac{1}{2}} u \\ \iff \frac{1}{N} \underbrace{W^{\frac{1}{2}} \tilde{\alpha}^\top \tilde{\alpha} W^{\frac{1}{2}}}_{\text{symétrique}} u &= \rho u \end{aligned}$$

La matrice $W^{1/2}\tilde{\alpha}^\top\tilde{\alpha}W^{1/2}$ est bien symétrique (elle est de la forme $M^\top M$ avec $M = \tilde{\alpha}W^{1/2}$), ce qui garantit des valeurs propres réelles ρ et des vecteurs propres u orthogonaux. Une fois u obtenu, on retrouve $b = W^{-1/2}u$, puis la fonction propre bivariée $\xi(t) = \Phi^\top(t)b$, dont les deux moitiés de b (les K premiers et les K derniers coefficients) donnent respectivement la composante "température" ξ^T et la composante "salinité" ξ^S de la fonction propre.

Calcul des scores (projections), reconstruction dans l'espace propre et variance expliquée

Une fois les fonctions propres bivariées $\xi_j = (\xi_j^T, \xi_j^S)$ et valeurs propres ρ_j calculées, on peut calculer les projections $c_{l,j}$ des profils bivariés centrés $\tilde{X}_l = (\tilde{T}_l, \tilde{S}_l)$ sur l'espace propre. On note $c_{l,j}$ le score du profil l sur la j -ème composante principale (commun à la température et à la salinité, puisque la composante principale est bivariée) :

$$\begin{aligned} c_{l,j} &= \langle \tilde{X}_l, \xi_j \rangle \\ &= \int \tilde{\alpha}_l^\top \Phi(t) \Phi^\top(t) b_j dt \\ &= \tilde{\alpha}_l^\top W b_j \in \mathbb{R} \end{aligned}$$

On choisit ensuite $J \ll 2K$ composantes à partir de la variance expliquée cumulée. La variance expliquée cumulée des J premières composantes principales est calculée comme suit :

$$VE = \frac{\sum_{j=1}^J \rho_j}{\sum_{k=1}^{2K} \rho_k}$$

avec ρ_k la valeur propre associée à la k -ième composante principale, les composantes étant triées par ordre **décroissant** de valeur propre ($\rho_1 \geq \rho_2 \geq \dots$), de sorte que les J premières composantes soient celles qui expliquent le plus de variance conjointe des profils de température et de salinité. On peut ainsi sélectionner par exemple les J premières composantes principales qui expliquent 90% de la variance.

Finalement, on peut reconstruire conjointement les profils de température et de salinité du profil l comme la combinaison linéaire des J premières fonctions propres bivariées et des scores associés (les mêmes scores $c_{l,j}$ pilotant simultanément la reconstruction des deux variables) :

$$T_l(t) = \bar{T}(t) + \sum_{j=1}^J c_{l,j} \xi_j^T(t), \quad S_l(t) = \bar{S}(t) + \sum_{j=1}^J c_{l,j} \xi_j^S(t)$$

où $\bar{T}$ et $\bar{S}$ sont les profils moyens de température et de salinité, obtenus à partir des composantes correspondantes de $\bar{\alpha}$.




Figure 3.3 – Réduction de la matrice de coefficients de pondération des B-splines par PCA et reconstruction des profils de Température/Salinité issu de Copernicus (E.U. Copernicus Marine Service Information (CMEMS). Global Ocean Physics Reanalysis. Marine Data Store (MDS). DOI : 10.48670/moi-00021) le 2023-01-26 aux coordonnées 450E,-60°N. $k=6$ composantes principales sont conservées (>99% de variance expliquée (voir Table 7.1, Annexe 7.4))

3.1.2.4 Gaussian Model Mixture Clustering

Afin de regrouper les profils de température et salinité similaires et identifier des Domaines Océanographiques Fonctionnels, on effectue un GMM clustering sur la matrice des coefficients réduite c obtenue à l'étape précédente. Le fonctionnement de la méthode ne sera pas développée ici, se référer à [15] pour une explication. Le GMM clustering a été implémenté avec le package `mclust` [16], [17] disponible sous R. Le modèle le plus flexible (`model="VVV"`) a été utilisé, permettant un ajustement des ellipsoïde non contraint en volume, orientation et forme, cela au prix d'une augmentation du

nombre d'hyperparamètres. Avec les précédents travaux réalisés par Fonvieille N. et Molinet M. [11], [18], la recherche d'un nombre de cluster a été restreinte entre 4 et 6 clusters, réduisant ainsi le coût computationnel. Les clusters ont été définis lorsque la probabilité d'appartenance à un cluster était supérieure au seuil fixé à 0.75. Des classes de transitions ont été créées en fonction des deux clusters ayant une probabilité d'appartenance maximale. Sont obtenus 13 clusters distincts : 6 clusters de FOD et 7 clusters de dits de "transitions"² (voir figure ??).




Figure 3.4 – (a) Carte du secteur Indien de l'Océan Austral et des courants [6] (b) Carte des Domaines Océanographiques Fonctionnels du 2023-01-26 générée par la méthode développée par Fonvieille N. et Nerini D. [11]. Identification du Front Polaire (FP, cluster T2-3), du Front Subantarctique (SAF, cluster T3-4) et du Front Subtropical (STF, clusters T4-5 et T4-6)

Les FOD correspondent alors à des masses d'eau ayant des propriétés thermohalines similaires et permettent de visualiser l'hydrodynamisme de la région (tourbillons emprisonnant les masses d'eau dans leurs coeur, filaments, fronts), voir figure 3.4.

3.1.3 Filtrage des pigments

3.1.4 Colocalisation NASC/PIG/FTLE/FOD

3.2 Arbres de Régression

"Depending on the problem, the basic purpose of a classification/regression study can be either to produce an accurate classifier or to uncover the predictive structure

2. La classe "NA" correspond aux clusters manquants sur le plateau de Kerguelen. Les profils de température et salinité allant de 20 à 500m, sont retirés des calculs tout profils ayant des données manquantes entre ces deux valeurs. Les zones où la bathymétrie est inférieure à 500m sont donc exclues de ces calculs.

of the problem." (classif. and regression trees p.6) Notre objectif ici est chercher à connaître la prédictibilité du NASC en fonction de la structure des communautés phytoplanctoniques, en lien avec l'activité de mésoéchelle. The goal is to understand the structural relationship between the response and the measured variables. (p.221)

3.2.1 CART

3.2.1.1 Description du modèle

3.2.1.2 Importance des variables

3.2.1.3 Compromis biais-variance

3.2.2 Random Forest

3.2.2.1 Description du modèle

3.2.2.2 Importance des variables

3.2.2.3 Compromis biais-variance

3.2.3 Extreme Gradient Boosting

3.2.3.1 Description du modèle

3.2.3.2 Importance des variables

3.2.3.3 Compromis biais-variance

3.2.4 Tuning, entraînement, validation et prédiction

4 Résultats

4.1 distrib interanuelles générales

description des distribs de ftle nasc et pigs au global

4.2 FOD

Description des caractéristiques des masses d'eau (profil T/S moyen) et mise en relation avec leur propriétés physico-chimique potentielles, la provenance de l'eau etc mise en lien des FOD avec la structuration couremment utilisée du SO (Tréguer et Jacques 1992 et Sullivan et al 1998 : SAZ, SSIZ, MIZ, CZ (climate drivers of SO, Krumhardt2022))

Description des conentrations de pigments par fod, est ce qu'il y a des tendances ? déplacement des communauté phyto ? NASC par fod ftle par fod

4.3 Cluster de pigments

Description des classes de pigments identification des communautés phyto selon la ref de Ziad (Influence of the phyto community nature 2025) Description des tendances interanuelle en terme de concentration Description de la régionalisation des cluster de pigs et des fod (intersection entre les 2 ?) déplacement des communauté phyto ? (distrib des fod par an par cluster) Description du NASC par cluster de pigment

4.4 Résultats des régressions

5 Discussion

5.1 Influence des fréquences

Les NTI sont des poissons pourvu ou non de vessies natatoire¹. (mettre dans la partie)

5.2 Complétion des NAs et influence sur le NASC

5.3 FOD : nombre de composante principale, données modèles, non prise en compte des données chimique (fer) et sea ice

5.4 définition de communauté phyto à partir des bio-optical water types

however an increase in chl-a is not necessarily associated with an increase in biomass, particularly in the iron light co-limited SO where phytoplankton can adjust their cellular chl-a to carbon ratios in response to environmental stresses [9] (pas la ref n°1) beaucoup de valeurs manquantes a cause de couverture nuageuse complétion possible des données avec des méthodes de deep learning

5.5 effet du temps sur les corrélations mésoéchelle/phyto/zoo

- : commu phyto/nasc : effet du time gap entre les distributions des deux pouvant masquer les corrélations. On sait qu'un bloom de phyto donne + de biomasse des NTI supérieurs, mais + tard

- ftle/phyto/nasc du modèle : critiques

1. organe permettant à l'organisme de contrôler sa flottaison

5.6 test statistiques : effet du nombre de données et dispersion sur la significativité, tendance vs climate change trend

30-40 years of PP data are necessary to distinguish a climate trend change (pas la ref n°1) [9]

5.7 Influence sur la prédiction : gradient latitudinal, overfit, déséquilibre de l'échantillonnage

gradient latitudinal = hypothèse de stationnarité de 1er et second ordre pas respecté, plots pour analyser cet effet overfit du RS et capacité de transfer learning (spatial nested cv) : plots effet du déséquilibre de l'échantillonnage sur les cartes de prédictions

5.8 Choix des variables prédictives, manque de variables

variance, distance geo par fold et capacité prédictives -> hypothèse de manque de variable prédictive

5.9 Interprétation de l'importance des variables

comment XGB et RF et CART n'ont pas les mêmes algos et comment ça peut en fait dire des choses différentes, méfiance sur l'interprétation, bien se renseigner (lire les articles)

5.10 Evaluation des performances prédictives du modèle

résistance aux valeurs manquantes résistance au bruit d'échantillonnage

6 Conclusion

7 Annexes

7.1 Propriétés des B-Splines de degré m : Support, positivité et régularité

La B-spline $\phi_{i,m}(x)$ est un polynôme par morceau de degré m (et d'ordre $m + 1$) avec des points de rupture (noeuds) $\tau_i, \dots, \tau_{i+m+1}$ et les propriétés suivantes :

- Continuité : $\phi_{i,m}(x) \in C^{m-1}$ aux noeuds (les dérivées jusqu'à l'ordre $m - 1$ sont continues sur les noeuds). Pour une B-spline cubique ($m = 3$), $\phi_{i,3} \in \mathcal{C}^2$,
- Support compact : $\text{supp}(\phi_{i,m}) = [\tau_i, \tau_{i+m+1}]$, donc $\langle \phi_{i,m}, \phi_{j,m} \rangle = 0$ si $|i - j| \geq m + 1$.
- Positivité : $\phi_{i,m}(x) > 0$ sur (τ_i, τ_{i+m+1}) et $\phi_{i,m}(x) = 0$ sinon.

7.2 Stratification verticale et horizontale des océans




Figure 7.1 — Stratification verticale de l'eau selon la pénétration de la lumière et de la pression, stratification horizontale selon la distance au plateau continental [3].

7.3 Distribution verticale des valeurs manquantes des ESU

7.4 Influence du nombre de composantes principales sur la reconstruction des profils de température et salinité

PC	Eigenvalue	Prop. variance	Cumulative variance
1	981.66665873	0.9810935	0.9810935
2	12.52661452	0.0125193	0.9936128
3	4.16020812	0.0041578	0.9977705
4	0.92707153	0.0009265	0.9986971
5	0.56820781	0.0005679	0.9992649
6	0.41429271	0.0004141	0.9996790
7	0.13458956	0.0001345	0.9998135
8	0.05806269	0.0000580	0.9998715
9	0.05427009	0.0000542	0.9999258
10	0.02370249	0.0000237	0.9999495

Table 7.1 – Valeurs propres et variance expliquée par les composantes principales.




Figure 7.2 – Effet du nombre de composantes principales k sur la qualité de reconstruction des profils de température et salinité. Un nombre de PC permettant d'obtenir une variance expliquée > 0.99 ne permet pas nécessairement une reconstruction correcte des profils.

Liste d'abréviations

Liste de symboles

Liste des figures et tableaux

Bibliographie

- [1] Michèle FIEUX. *L'Océan planétaire*. 2^e éd. Les Presses de l'ENSTA, 2019. ISBN : 978-2-7225-0960-3.
- [2] G. Evelyn HUTCHINSON. « Concluding Remarks ». In : *Cold Spring Harbor Symposia on Quantitative Biology* 22 (1957), p. 415-427. DOI : 10.1101/SQB.1957.022.01.039.
- [3] Frances DIPPER. « The seawater environment and ecological adaptations ». In : *Elements of Marine Ecology*. 5^e éd. Oxford : Butterworth-Heinemann, 2022, p. 37-151. DOI : 10.1016/B978-0-08-102826-1.00002-8.
- [4] Scott C. DONEY et al. « Climate Change Impacts on Marine Ecosystems ». In : *Annual Review of Marine Science* 4 (2012), p. 11-37. DOI : 10.1146/annurev-marine-041911-111611.
- [5] Jean-Baptiste SALLÉE. « Southern Ocean Warming ». In : *Oceanography* 31.2 (juin 2018), p. 52-62. DOI : 10.5670/oceanog.2018.215.
- [6] Suhas SHETYE, Rahul MOHAN et Abhilash NAIR. « Latitudinal shifts in the Polar Front in Indian sector of the Southern Ocean : evidences from silicoflagellate assemblage ». In : *Geosciences Journal* 18.2 (déc. 2013), p. 241-246. DOI : 10.1007/s12303-013-0061-8.
- [7] Nurmalia ADROLI et al. « Southern Ocean regime shift : divergent trends in surface phytoplankton community composition using a diagnostic pigment framework ». In : *Nature Communications* 17.1 (juill. 2026), p. 8607. DOI : 10.1038/s41467-026-75303-2.
- [8] Alexander HAYWARD et al. « Climate driven shifts in Antarctic phytoplankton groups : Implications of widespread diatom decline ». In : *Research Square* (2024). DOI : 10.21203/rs.3.rs-5188031/v1.
- [9] Sandy J. THOMALLA et al. « Widespread changes in Southern Ocean phytoplankton blooms linked to climate drivers ». In : *Nature Climate Change* 13.9 (2023), p. 975-984. DOI : 10.1038/s41558-023-01768-4.
- [10] Nerilie J. ABRAM et al. « Emerging evidence of abrupt changes in the Antarctic environment ». In : *Nature* 644.8077 (2025), p. 621-633. DOI : 10.1038/s41586-025-09349-5.

- [11] Nadège FONVIELLE. « Structure des paysages océaniques tridimensionnels par l'analyse de données issues d'éléphants de mer du Sud ». Thèse de doctorat. Marseille, France : Aix-Marseille Université, sept. 2024.
- [12] Carl de BOOR. « A Practical Guide to Splines ». In : Revised Edition. New York : Springer, 2001. Chap. B-splines, p. 87.
- [13] Paul H. C. EILERS et Brian D. MARX. « Flexible Smoothing with B-splines and Penalties ». In : *Statistical Science* 11.2 (mai 1996), p. 89-102. DOI : 10.1214/ss/1038425655.
- [14] Matthew P. WAND et John T. ORMEROD. « On Semiparametric Regression with O'Sullivan Penalized Splines ». In : *Australian & New Zealand Journal of Statistics* 50.2 (2008), p. 179-198. DOI : 10.1111/j.1467-842X.2008.00507.x.
- [15] Christopher M. BISHOP. *Pattern Recognition and Machine Learning*. Information Science and Statistics. New York : Springer, 2006. ISBN : 978-0-387-31073-2.
- [16] Luca SCRULLA et al. « mclust 5 : Clustering, Classification and Density Estimation Using Gaussian Finite Mixture Models ». In : *The R Journal* 8.1 (2016), p. 289-317.
- [17] Chris FRALEY et Adrian E. RAFTERY. « Model-Based Clustering, Discriminant Analysis, and Density Estimation ». In : *Journal of the American Statistical Association* 97.458 (2002), p. 611-631.
- [18] Marius MOLINET et al. « Linking oceanographic conditions to foraging behaviour of southern elephant seals by characterising mid-trophic levels with an animal-borne echosounder ». In : *Journal of Marine Systems* (2025).