

UNIVERSITÉ PARIS CITÉ

Département de mathématiques et d'informatique

**Influence du type phytoplanctonique et des structures de
méso échelle sur la distribution des organismes
mésopélagiques**

Rapport de stage

Abstract

Rapport réalisé par

Elise NICOLAS

Encadrants

Marius MOLINET, David NERINI, Christophe GUINET, Cédric COTTET

Professeure référente

FISHER Aurélie

Contents

1	Introduction	2
1.1	L'Océan Austral	2
1.2	Contexte Biologique	3
1.2.1	Stratification Verticale	3
1.2.2	Réseau Trophique	3
1.3	Contexte Physique	3
1.3.1		3
2	Matériel	4
2.1	Données issue de campagnes océanographiques/in situ (Marion Dufresnes II)	4
2.2	Données Environnementales	4
3	Méthode	5
3.1	Pré-traitement des données	5
3.1.1	Gestion des valeurs manquantes	5
3.1.2	Estimation semi-paramétrique des profils d'intensité de rétropropagation Sv	5
3.2	Réduction de dimension par Functional Principal Component Analysis	7
3.2.1	Motivation	8
3.2.2	Étape 0 : Construction du vecteur de coefficients bivarié	8
3.2.3	Étape 1 : Centrage des données	8
3.2.4	Étape 2 : Calcul de la covariance empirique	8
3.2.5	Étape 3 : Décomposition en valeurs propres et vecteurs propres de la matrice de covariance	8
3.2.6	Étape 4 : Calcul des scores (projections), reconstruction dans l'espace propre et variance expliquée	9
3.3	Gaussian Mixture Model Clustering	10
3.4	Sélection de variables (Feature Selection)	10
3.4.1	Arbres de régression	10
4	Conclusion	11
5	Discussion	12

1 Introduction

L'océan couvre 70% de la surface terrestre. La répartition des terres émergées n'est pas équivalente selon les deux hémisphères: l'hémisphère Sud est composé à 80.9% de mer, contre 60.7% pour l'hémisphère Nord. Dans l'hémisphère Sud, dans le bassin Antarctique, les océans Atlantique, Pacifique et Indien se connectent. Une seule masse d'eau liquide se déplace alors dans les différents bassins. L'océan planétaire est un milieu continu.




Figure 1: Représentation des différents bassins océaniques et de leurs continuité.

Un biotope correspond à l'espace physique et les conditions abiotiques associées dans lesquelles vit une biocénose. Une biocénose est l'ensemble des populations d'organismes qui occupent une zone donnée et interagissent entre elles. L'océan étant un milieu continu, seuls les paramètres physiques de l'eau (abiotiques) conditionnent la régionalisation en biotopes. La connaissance des paramètres physiques de l'eau est donc particulièrement importante pour l'étude de la distribution des organismes et des niches écologiques marines. Les principaux paramètres abiotiques structurant les écosystèmes sont : la lumière (longueur d'onde et proportion d'éclairement), les propriétés hydrologiques (température et salinité) et l'hydrodynamisme. **il faut une source.** L'océan est stratifié verticalement selon la pénétration de la lumière : celle-ci dépendant de la profondeur. On parle de milieu eutrophe (épipélagique) entre 0 et 200m, de milieu dysphotique (mésopélagique) entre 200 et 1000m, de milieu aphotique (bathypélagique) entre 1000 et 4000m et de milieu abyssal au delà de cette dernière. Les propriétés hydrologiques de l'eau dépendent du climat : la chaleur et le vent induisent une évaporation rendant l'eau de mer plus salée, les précipitations induisent un adoucissement de la salinité. La composition chimique de l'eau de mer est fortement dépendante des apports du littoral (fer, nitrates, etc). L'hydrodynamisme inclue les marées et les divers courants induits par des gradients de température, de pressions. Ces derniers dépendent majoritairement du vent et de l'ensoleillement. La proximité au littoral participant grandement à la modification de ces paramètres abiotiques, on sépare l'océan horizontalement selon sa distance au plateau continental. On parle de zone pélagique au delà du plateau continental.

L'écologie est une discipline qui s'intéresse aux interactions entre les différentes espèces d'un même biotope. Parmi elles, les relations trophiques (alimentaires) jouent un rôle fondamentale dans la structuration des écosystèmes. Dans le milieu océanique, le réseau trophique peut généralement être simplifié comme suit :

- les producteurs primaires sont le phytoplancton

1.1 L'Océan Austral

L'océan Austral (ou Antarctique) forme un anneau autour de l'Antarctide. Il représente 22% de la surface totale des océans. Contrairement aux autres océans, il n'est pas délimité par des frontières

continentales. En regardant une carte (voir figure ??), on pourrait penser qu'il est simplement la prolongation du bassin Atlantique, Pacifique et Indien. En réalité, il est délimité par une frontière océanographique : le Front Subtropical (approximativement à 40°S), caractérisé par de très forts gradients de températures. L'océan Austral se distingue également des autres océans par l'uniformité de son climat, de son hydrodynamisme et de ses propriétés hydrologiques.

1.2 Contexte Biologique

1.2.1 Stratification Verticale

1.2.2 Réseau Trophique

1.3 Contexte Physique

1.3.1

2 Matériel

- 2.1 Données issue de campagnes océanographiques/in situ (Marion Dufresnes II)**
- 2.2 Données Environnementales**

3 Méthode

3.1 Pré-traitement des données

3.1.1 Gestion des valeurs manquantes

3.1.2 Estimation semi-paramétrique des profils d'intensité de rétropropagation Sv

3.1.2.a Motivation Les profils d'intensité de rétropropagation $Sv \in \mathbb{R}^{n_{freqs} \times n_{pings} \times n_{depths}}$, $Sv_{l,i} \in \mathbb{R}^{n_{depths}}$ issus des campagnes océanographique sont bruités et fortement irréguliers : $Sv_{l,i} = x_{l,i}(t) + \epsilon_i$. Afin de faciliter l'étude de ces profils (gestion de valeurs manquantes, dérivations, étude sur des grilles différentes, FPCA, etc), on estime la fonction $x_i(t_j) : \tau \rightarrow \mathbb{R}$ par projection sur des bases de B-splines.

3.1.2.b B-splines d'ordre k (deBoor) Les B-splines sont des fonctions pouvant servir de base pour l'estimation fonctionnelle (B pour "Basis"). Ce sont des polynômes par morceaux pourvus de certaines conditions de régularités aux noeuds (ou points de rupture). La Figure ?? montre un exemple simple de B-splines (**eilers1996**) : en (a) est montrée une B-spline de degré 1 et en (b) une B-spline de degré 2.




Figure 2: Illustration d'une B-spline isolée de B-splines chevauchantes, de degré 1 (a) et de degré 2 (b) (**eilers1996**)

Soit $\tau_i, \dots, \tau_{i+m+1}$ noeuds (équi-espacés ou non) avec m le degré de la B-spline (on a donc un ordre valant $m + 1$)

Soit $\phi_{i,m}(x)$ la B-spline d'ordre m dont le support est $\text{supp}(\phi(x)) = [\tau_i, \tau_{i+m+1}]$. On peut définir la B-spline $\phi_{i,m}(x)$ par la formule de récurrence de Cox-de-Boor (**deBoor**) :

1. Initialisation d'une fonction porte par noeud (ordre 1)

$$\phi_{i,1} = \begin{cases} 1 & \text{si } \tau_i \leq x < \tau_{i+1} \\ 0 & \text{sinon} \end{cases} \quad (1)$$

2. Récurrence : combinaison convexe de la B-spline d'ordre inférieur à différents noeuds

$$\phi_{i,m} = \omega_{i,m}(x)\phi_{i,m-1} + (1 - \omega_{i,m}(x))\phi_{i+1,m-1} \quad (2)$$

avec

$$\omega_{i,m}(x) := \frac{x - \tau_i}{\tau_{i+m-1} - \tau_i} \quad (3)$$

Propriétés des B-Splines de degré m : Support, positivité et régularité La B-spline $\phi_{i,m}(x)$ est un polynôme par morceau de degré m (et d'ordre $m + 1$) avec des points de rupture (noeuds) $\tau_i, \dots, \tau_{i+m}$ à les propriétés suivantes :

- Continuité : $\phi_{i,m}(x) \in C^{m-1}$ au noeuds (les dérivées jusqu'à l'ordre $m-1$ sont continues sur les noeuds). Pour une B-spline cubique ($m = 3$), $\phi_{i,3} \in C^2$,
- Support compact : $\text{supp}(\phi_{i,m}) = [\tau_i, \tau_{i+m+1}]$, donc $\langle \phi_{i,m}, \phi_{j,m} \rangle = 0$ si $|i - j| \geq m + 1$.
- Positivité : $\phi_{i,m}(x) > 0$ sur (τ_i, τ_{i+m+1}) et $\phi_{i,m}(x) = 0$ sinon.

3.1.2.c Espace des splines $\mathbb{S}_{m,\tau}$ Une fonction spline $f : [a, b] \rightarrow \mathbb{R}, f \in \mathbb{S}_{m,\tau}$ de degré m avec suite de noeuds τ est toute combinaison linéaire de B-splines de degré m pour la suite de noeuds τ . La suite de noeuds τ est la suivante :

$$\underbrace{a = \tau_1 = \tau_2 = \dots = \tau_{m+1}}_{m+1 \text{ noeuds répétés en } a} < \underbrace{\tau_{m+2} < \dots < \tau_{m+L+1}}_{L \text{ noeuds intérieurs}} < \underbrace{\tau_{m+L+1} = \dots = \tau_{2 \times L + m + 1} = b}_{m+1 \text{ noeuds répétés en } b} \quad (4)$$

La collection de toutes ces fonctions est notée $\mathbb{S}_{m,\tau}$. Les B-splines $\{\phi_{i,m}\}_{i=0}^{m+L+1}$ forment alors une base de cet espace de dimension $\dim(\mathbb{S}_{m,\tau}) = L + m + 1$, avec L le nombre de noeuds intérieurs..

$$\mathbb{S}_{m,\tau} := \left\{ \sum_{i=1}^{L+m+1} \alpha_i \phi_{i,m} : \alpha_i \in \mathbb{R} \right\} \quad (5)$$

3.1.2.d Estimation fonctionnelle par minimisation des moindres carrés pénalisée (O-Splines) (wand2008, eilers1996) Considérons une régression non-paramétrique simple :

$$y_k = f(x_k) + \varepsilon_k, \quad \forall k \in \{1, \dots, n\} \quad (6)$$

où $(x_k, y_k) \in \mathbb{R} \times \mathbb{R}$ et n le nombre de données.

Supposons qu'une estimation de f est nécessaire sur $[a, b]$, un intervalle contenant les x_i . Soit $\hat{y} : [a, b] \rightarrow \mathbb{R}, \hat{y} \in \mathbb{S}_{m,\tau}$ une spline (combinaison linéaire de B-splines de degré m) estimée de f :

$$\hat{y}(x_k) = \sum_{i=1}^{m+L+1} \alpha_i \phi_{i,m}(x_k), \quad (7)$$

où $\phi_1, \dots, \phi_{m+L+1}$ sont les B-splines de degré m , et L le nombre de noeuds intérieurs, avec $\text{supp}(\phi_{i,m}) = [\tau_i, \tau_{i+m}]$.

La fonction objective des moindres carrés (MSE pour "Mean Square Error" à minimiser est :

$$S = \sum_{k=1}^n \left(y_k - \hat{f}(x_k) \right)^2 \quad (8)$$

$$= \sum_{k=1}^n \left(y_k - \sum_{i=1}^{L+m+1} \alpha_i \phi_{i,m}(x_k) \right)^2 \quad (9)$$

Choisir le nombre de noeuds $K = m + L$ des B-splines peut s'avérer difficile, et peut induire de l'overfitting (un grand nombre de noeuds permet de capturer toutes les variations des données d'entraînements mais donne de mauvaises performances de régressions sur des nouvelles données tests, les données tests étant différentes des données d'entraînement). Plusieurs techniques de pénalisation (Paul H. C. Eilers, Brian D. Marx, O'Sullivan) ont été mises en place pour choisir les hyper-paramètres des B-splines (nombre de noeuds) de manière optimale. On présentera ici la régression pénalisée de O'Sullivan (1986). Se référer aux travaux de (wand2008, eilers1996) pour d'avantages de détails sur les autres méthodes.

La régression de O'Sullivan pénalise la rugosité de la fonction estimée, c'est à dire à quel point elle oscille ou est irrégulière.

Le terme de pénalisation de O'Sullivan (matrice de rugosité) ajouté à la MSE (Mean Square Error) est définie par :

$$\Omega_{i,j} = \int_a^b \phi_{i,m}''(x) \phi_{j,m}''(x) dx, \quad 1 \leq i, j \leq K \quad (10)$$

La MSE pénalisée (O-Sullivan, Ridge fonctionnel) est alors :

$$S_\lambda = \underbrace{\sum_{k=1}^n \left(y_k - \sum_{i=1}^K \alpha_i \phi_{i,m}(x_k) \right)^2}_{\text{MSE}} + \lambda \underbrace{\boldsymbol{\alpha}^\top \boldsymbol{\Omega} \boldsymbol{\alpha}}_{\text{rugosité}} \quad (11)$$

où $\lambda \geq 0$ est le paramètre de lissage contrôlant le compromis entre fidélité aux données (MSE) et régularité de $\hat{y}$.

Forme matricielle. En posant $\mathbf{y} = (y_1, \dots, y_n)^\top$, $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_K)^\top$ et la matrice de design $\phi \in \mathbb{R}^{n \times K}$ telle que $\phi_{k,i} = \phi_i(x_k)$, on réécrit :

$$S_\lambda = (\mathbf{y} - \phi \boldsymbol{\alpha})^\top (\mathbf{y} - \phi \boldsymbol{\alpha}) + \lambda \boldsymbol{\alpha}^\top \Omega \boldsymbol{\alpha} \quad (12)$$

Solution analytique. Puisque S_λ est convexe en α , on peut trouver les coefficients α minimaux en annulant la dérivée de S_λ par rapport à $\boldsymbol{\alpha}$:

$$\frac{\partial S_\lambda}{\partial \boldsymbol{\alpha}} = -2\phi^\top (\mathbf{y} - \phi \boldsymbol{\alpha}) + 2\lambda \Omega \boldsymbol{\alpha} = \mathbf{0} \quad (13)$$

On obtient l'estimateur :

$$\hat{\boldsymbol{\alpha}} = (\phi^\top \phi + \lambda \Omega)^{-1} \phi^\top \mathbf{y} \quad (14)$$

et les valeurs ajustées :

$$\hat{\mathbf{y}} = \phi \hat{\boldsymbol{\alpha}} = \underbrace{\phi (\phi^\top \phi + \lambda \Omega)^{-1} \phi^\top}_{\mathbf{H}(\lambda)} \mathbf{y} \quad (15)$$

où $\mathbf{H}(\lambda)$ est la *matrice d'influence*, similaire à la projection orthogonale de la régression linéaire classique.

Choix du paramètre de lissage λ par validation croisée leave-one-out (CV-LOO). Le paramètre λ contrôle la régularité de la courbe estimée : un λ trop petit conduit à de l'overfitting, un λ trop grand à de l'underfitting. La validation croisée leave-one-out consiste à estimer l'erreur de prédiction en retirant tour à tour chaque observation i :

$$\text{CV}(\lambda) = \frac{1}{n} \sum_{i=1}^n \left(y_i - \hat{f}^{(-i)}(x_i) \right)^2 \quad (16)$$

où $\hat{f}^{(-i)}$ est l'estimateur calculé sans l'observation i . Grâce à la hat matrix $\mathbf{H}(\lambda)$, on dispose d'une formule analytique évitant de refaire n régressions :

$$\text{CV}(\lambda) = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - H_{ii}(\lambda)} \right)^2 \quad (17)$$

où $H_{ii}(\lambda)$ est le i -ème élément diagonal de $\mathbf{H}(\lambda)$. Le paramètre optimal est alors :

$$\hat{\lambda} = \arg \min_{\lambda > 0} \text{CV}(\lambda) \quad (18)$$

Dans notre cas, le nombre d'observations étant très important, on se limite à une validation croisée sur un sous-ensemble d'observations.

3.1.2.e Réduction de dimension par Functional Principal Component Analysis l'Analyse par Composante Principale Fonctionnelle (ACPF ou *FPCA* pour Functional Principal Component Analysis)

Suite à l'estimation fonctionnelle réalisée à l'étape précédente, chaque profil l est désormais représenté par un couple de fonctions de la profondeur, la température et la salinité, estimées sur la même base de B-splines $(\Phi_k)_{1 \leq k \leq K}$ définie sur $[d_{\min}, d_{\max}]$:

$$T_l(z) = \sum_{k=1}^K \alpha_{l,k}^T \Phi_k(z), \quad S_l(z) = \sum_{k=1}^K \alpha_{l,k}^S \Phi_k(z), \quad z \in [d_{\min}, d_{\max}]$$

On considère alors chaque profil comme une observation **bivariée** $X_l = (T_l, S_l) \in (L^2([d_{\min}, d_{\max}]))^2$, muni du produit scalaire

$$\langle (f_1, g_1), (f_2, g_2) \rangle = \langle f_1, f_2 \rangle_{L^2} + \langle g_1, g_2 \rangle_{L^2}$$

L'objectif de cette étape est de réduire conjointement la dimension des profils de température et de salinité, afin de capturer les modes de variabilité communs aux deux variables (par exemple une thermocline associée à une halocline).

Motivation Réduire la dimension des données permet d'effectuer des analyses avec une plus grande facilité en diminuant par exemple les temps de calculs.

Une approche pour réduire la dimension des données est l'analyse par composante principale (ACP ou PCA pour Principal Component Analysis). Puisque les données sont fonctionnelles, on parle alors d'Analyse par Composante Principale fonctionnelle (ACPf ou FPCA). La logique est identique à celle d'une PCA classique mais les outils sont adaptés pour manipuler les fonctions. Ici, la FPCA est réalisée conjointement sur les deux variables, on parle de FPCA **bivariée**.

Étape 0 : Construction du vecteur de coefficients bivarié Pour chaque profil l , on concatène les coefficients de B-spline de température et de salinité en un unique vecteur $\alpha_l \in \mathbb{R}^{2K}$:

$$\alpha_l = \begin{pmatrix} \alpha_l^T \\ \alpha_l^S \end{pmatrix}, \quad \alpha_l^T = (\alpha_{l,1}^T, \dots, \alpha_{l,K}^T)^\top, \quad \alpha_l^S = (\alpha_{l,1}^S, \dots, \alpha_{l,K}^S)^\top$$

En empilant les N profils, on obtient la matrice $\alpha \in \mathbb{R}^{N \times 2K}$.

Étape 1 : Centrage des données Soit $\bar{\alpha} \in \mathbb{R}^{2K}$ la moyenne empirique, sur l'ensemble des N profils, des coefficients de chaque B-spline pour la partie température et pour la partie salinité :

$$\bar{\alpha} = \frac{1}{N} \sum_{l=1}^N \alpha_l$$

On obtient ainsi les coefficients bivariés centrés $\tilde{\alpha} \in \mathbb{R}^{N \times 2K}$, où pour un profil l donné :

$$\tilde{\alpha}_l = \alpha_l - \bar{\alpha}$$

Étape 2 : Calcul de la covariance empirique On définit la matrice bivariée de fonctions de base $\Phi(z) \in \mathbb{R}^{2K}$ comme la concaténation de la base Φ utilisée pour chacune des deux composantes :

$$\Phi(z) = \begin{pmatrix} \Phi(z) \\ \Phi(z) \end{pmatrix}, \quad \Phi(z) = (\Phi_1(z), \dots, \Phi_K(z))^\top$$

de sorte que le profil bivarié centré s'écrive $\tilde{X}_l(z) = \tilde{\alpha}_l^\top \Phi(z) \in \mathbb{R}$ (une combinaison scalaire mêlant la partie température et la partie salinité). La fonction de covariance empirique associée est :

$$\hat{V}(s, t) = \frac{1}{N} \sum_{l=1}^N \tilde{X}_l(s) \tilde{X}_l(t) = \frac{1}{N} (\tilde{\alpha} \Phi(s))^\top (\tilde{\alpha} \Phi(t)) \in \mathbb{R} = \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} \Phi(t)$$

où $\tilde{\alpha}^\top \tilde{\alpha} \in \mathbb{R}^{2K \times 2K}$ est la matrice de covariance empirique des coefficients bivariés.

Étape 3 : Décomposition en valeurs propres et vecteurs propres de la matrice de covariance On effectue la décomposition spectrale de l'opérateur de covariance $\hat{V}$:

$$\int \hat{V}(s, t) \xi(t) dt = \rho \xi(s)$$

avec la contrainte d'orthonormalité des fonctions propres bivariées : $\|\xi\|_{L^2} = 1$ et $\langle \xi_i, \xi_j \rangle = 0$ si $i \neq j$.

On fait l'hypothèse que la fonction propre bivariée $\xi(t)$ se décompose dans la même base bivariée que nos profils :

$$\xi(t) = \Phi^\top(t) b, \quad b \in \mathbb{R}^{2K}$$

On a alors :

$$\begin{aligned} \int \hat{V}(s, t) \xi(t) dt &= \int \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} \Phi(t) \Phi^\top(t) b dt \\ &= \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} \underbrace{\int \Phi(t) \Phi^\top(t) dt}_W b \\ &= \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} W b \end{aligned}$$

où $W = \int \Phi(t) \Phi^\top(t) dt \in \mathbb{R}^{2K \times 2K}$ est la matrice de Gram de la base bivariée. Comme $\Phi(t)$ répète deux fois la même base $\Phi(t)$, W prend la forme bloc-diagonale

$$W = \begin{pmatrix} W_0 & 0 \\ 0 & W_0 \end{pmatrix}, \quad W_0 = \int \Phi(t) \Phi^\top(t) dt \in \mathbb{R}^{K \times K}$$

les blocs hors-diagonale étant nuls car la partie température et la partie salinité de ξ n'interagissent qu'au travers de la covariance des coefficients $\tilde{\alpha}^\top \tilde{\alpha}$, pas au travers de la base elle-même.

On peut donc réécrire la décomposition spectrale comme suit :

$$\begin{aligned} \int \hat{V}(s, t) \xi(t) dt &= \rho \xi(s) \\ \iff \frac{1}{N} \Phi^\top(s) \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho \Phi^\top(s) b \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho b \end{aligned}$$

La matrice $\tilde{\alpha}^\top \tilde{\alpha}$ est symétrique (c'est un produit de la forme $A^\top A$), mais le produit $\tilde{\alpha}^\top \tilde{\alpha} W$ ne l'est pas en général : le problème aux valeurs propres n'est donc pas directement résoluble par une décomposition spectrale standard. Pour contourner ce problème, on utilise le changement de variable $b = W^{-\frac{1}{2}} u$:

$$\begin{aligned} \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W b &= \rho b \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W W^{-\frac{1}{2}} u &= \rho W^{-\frac{1}{2}} u \\ \iff \frac{1}{N} \tilde{\alpha}^\top \tilde{\alpha} W^{\frac{1}{2}} u &= \rho W^{-\frac{1}{2}} u \\ \iff \frac{1}{N} \underbrace{W^{\frac{1}{2}} \tilde{\alpha}^\top \tilde{\alpha} W^{\frac{1}{2}}}_{\text{symétrique}} u &= \rho u \end{aligned}$$

La matrice $W^{1/2} \tilde{\alpha}^\top \tilde{\alpha} W^{1/2}$ est bien symétrique (elle est de la forme $M^\top M$ avec $M = \tilde{\alpha} W^{1/2}$), ce qui garantit des valeurs propres réelles ρ et des vecteurs propres u orthogonaux. Une fois u obtenu, on retrouve $b = W^{-1/2} u$, puis la fonction propre bivariée $\xi(t) = \Phi^\top(t) b$, dont les deux moitiés de b (les K premiers et les K derniers coefficients) donnent respectivement la composante "température" ξ^T et la composante "salinité" ξ^S de la fonction propre.

Étape 4 : Calcul des scores (projections), reconstruction dans l'espace propre et variance expliquée Une fois les fonctions propres bivariées $\xi_j = (\xi_j^T, \xi_j^S)$ et valeurs propres ρ_j calculées, on peut calculer les projections $c_{l,j}$ des profils bivariés centrés $\tilde{X}_l = (\tilde{T}_l, \tilde{S}_l)$ sur l'espace propre. On note $c_{l,j}$ le score du profil l sur la j -ème composante principale (commun à la température et à la salinité, puisque la composante principale est bivariée) :

$$\begin{aligned} c_{l,j} &= \langle \tilde{X}_l, \xi_j \rangle \\ &= \int \tilde{\alpha}_l^\top \Phi(t) \Phi^\top(t) b_j dt \\ &= \tilde{\alpha}_l^\top W b_j \in \mathbb{R} \end{aligned}$$

On choisit ensuite $J \ll 2K$ composantes à partir de la variance expliquée cumulée. La variance expliquée cumulée des J premières composantes principales est calculée comme suit :

$$VE = \frac{\sum_{j=1}^J \rho_j}{\sum_{k=1}^{2K} \rho_k}$$

avec ρ_k la valeur propre associée à la k -ième composante principale, les composantes étant triées par ordre **décroissant** de valeur propre ($\rho_1 \geq \rho_2 \geq \dots$), de sorte que les J premières composantes soient celles qui expliquent le plus de variance conjointe des profils de température et de salinité. On peut ainsi sélectionner par exemple les J premières composantes principales qui expliquent 90% de la variance.

Finalement, on peut reconstruire conjointement les profils de température et de salinité du profil l comme la combinaison linéaire des J premières fonctions propres bivariées et des scores

associés (les mêmes scores $c_{l,j}$ pilotant simultanément la reconstruction des deux variables) :

$$T_l(t) = \bar{T}(t) + \sum_{j=1}^J c_{l,j} \xi_j^T(t), \quad S_l(t) = \bar{S}(t) + \sum_{j=1}^J c_{l,j} \xi_j^S(t)$$

où $\bar{T}$ et $\bar{S}$ sont les profils moyens de température et de salinité, obtenus à partir des composantes correspondantes de $\bar{\alpha}$.

3.1.2.f Gaussian Mixture Model Clustering Une manière de regrouper les données qui se ressemblent est le clustering. Le clustering par mélange de gaussiennes (GMM) est l'une de ces méthodes. Elle repose sur l'hypothèse que les données suivent un mélange de K distributions normales multivariées, une par cluster. Cette hypothèse paramétrique forte contraint l'espace de solutions et peut s'avérer avantageuse lorsque les données s'y conforment réellement. Notons cependant que selon le modèle de GMM, le nombre de paramètres peut s'avérer important.

On a donc des données $X = \{x_1, \dots, x_N\} \in \mathbb{R}^{N \times D}$. On suppose qu'elles suivent un mélange de K distributions normales multivariées. La loi de probabilité de X peut donc être représentée par la marginale des K lois normales multivariées :

$$p(x) = \sum_k^K \pi_k \mathcal{N}(x; \mu_k; \Sigma_k)$$

où

- K est le nombre de distributions normales supposée
- π_k est la probabilité du cluster k (prior ou poids du mélange), $\sum_k^K \pi_k = 1$
- $\mathcal{N}(x; \mu_k; \Sigma_k) = \frac{1}{(2\pi)^{\frac{D}{2}} \det(\Sigma_k)^{\frac{1}{2}}} \exp\left(-\frac{(x-\mu_k)^T \Sigma_k^{-1} (x-\mu_k)}{2}\right)$ est la k -ième distribution gaussienne multivariée avec μ_k sa moyenne et Σ_k sa matrice de covariance.

On peut introduire une variable aléatoire (VA) latente Z où chacune de ses réalisations indique le cluster/distribution gaussienne d'appartenance de chaque donnée X_i .

$$Z_i \sim \text{Cat}(\pi) \text{ ou } P(Z_i = k) = \pi_k$$

avec $Z_i \in \{1, \dots, K\}$ et $\pi = \{\pi_1, \dots, \pi_K\}$
et donc

$$x_i | Z_i = k \sim \mathcal{N}(\mu_k, \Sigma_k)$$

On obtient donc bien $p(x)$ comme Marginale en Z :

$$p(x) = \sum_{k=1}^K p(Z_i = k) p(x | Z_i = k)$$

3.2 Sélection de variables (Feature Selection)

La sélection de variable (ou *feature selection*) est un champ du machine learning / deep learning consistant à rechercher les variables X permettant de maximiser la prédiction d'une variable de sortie Y . L'idée étant de limiter le plus possible le nombre de variables d'entrées.

Plusieurs méthodes permettent de faire de la sélection de variables. Nous nous intéresserons ici aux arbres de régressions.

3.2.1 Arbres de régression

Les arbres de régressions sont

4 Conclusion

5 Discussion

Annexes